Step 7 — Piano degli esperimenti

Obiettivo

Arrivare alla configurazione finale con il minimo numero di corse, cambiando **una cosa alla volta** e decidendo con criteri fissati prima. Ogni esperimento si fa prima su **JPT-9B** (più veloce); le scelte vincenti si ripetono su **Winnow-12B**.

Regole generali

1. Ogni esperimento ha un ID, una configurazione di riferimento e una sola variazione.
2. Si giudica su `dev_select`, sui test comportamentali e sui benchmark di oblio (06_valutazione.md). I test (test_id, test_ood, AggreFact) solo alla fine; LLM-AggreFact non guida nessuna scelta.
3. Una variazione si adotta se migliora la BAcc macro su `dev_select` di almeno **0,5 punti** (sotto, è nel rumore fra seed) **senza** peggiorare oblio (> 2 punti) o calibrazione (ECE +0,02).
4. Ogni esperimento si registra nella tabella di §8.

Fase 0 — Baseline (senza training)

ID	Cosa	Domanda	Costo
B0	Regola di Jev a 3 domande, soglia 0,30	numeri già noti	0
B1	Soglia fittata sul dev	già fatto: +0,7 JPT, +0,4 Winnow	0
B2	Soglia + temperatura sul dev	quanto vale ricalibrare	0 (dalle cache)
B3	Solo `support_simple`	quanto vale la regola a 3 domande	0 (dalle cache)
B4	Modelli base (Gemma-4-12B, Qwen3.5-9B)	punto di partenza del controllo C1	~2 h GPU
B5	Blocchi C e D sui modelli di partenza	baseline di robustezza e oblio	~2 h GPU

Uscita: la baseline vera = migliore fra B1–B3 su `dev_select`, confermata su `dev_confirm`. B1–B3 si fittano sul nostro dev, non più su quello di AggreFact (01_baseline.md).

Fase 1 — Pilota (JPT, `pilot_text`, S1)

Configurazione di riferimento **P0**: LoRA r16, lr 2e-5, 1 epoca, CE sulle lettere, replay 10% ($\lambda = 1$), varianti di domanda 30%, 4.096 token.

ID	Variazione	Domanda	Decisione
P0	—	il fine-tuning funziona?	se non batte la baseline su `dev_select`, **fermarsi** e controllare rendering e loss prima di tutto il resto
P1	lr 1e-5 / 5e-5	sensibilità al learning rate	tenere il migliore
P2	Brier al posto della CE	calibrazione e BAcc	Brier se ECE migliora senza perdere BAcc
P3	SFT classico sul token di risposta	quanto vale la loss sulle lettere	conferma della scelta (atteso: peggiore in ECE)
P4	senza replay	quanto oblio evita il replay	se l'oblio senza replay è < 1 punto, ridurre il replay

ID	Variazione	Domanda	Decisione
P5	senza varianti di domanda	quanto valgono per la stabilità	tenere se riducono la varianza fra formulazioni

Costo: ~6 corse × 5–10 h.

Fase 2 — Dati (JPT, configurazione migliore della Fase 1)

ID	Variazione	Domanda
D1	Leave-one-source-out (una corsa per fonte tolta)	quale fonte aiuta e quale danneggia
D2	Solo MiniCheck + ANLI (≈ ricetta di Bespoke-MiniCheck)	confronto con il miglior modello aperto
D3	+ FactKG trasformato in prosa (02b, §3)	i ragionamenti di FactKG aiutano se il formato è giusto?
D4	+ FactKG in triple (com'è oggi)	solo come confronto con D3
D5	Scala: 10k / ~29k / ~85k coppie	curva di apprendimento: conviene la corsa piena?
D6	+ WiCE decontaminato	guadagno sospetto su WiCE? riportare a parte
D7	FEVER senza claim con negazioni esplicite	il modello impara "not → falso"? (test "solo claim")
D8	bilanciamento 50/50 contro distribuzione naturale	effetto su soglia e BAcc
D9	+ coppie generate (`remove_evidence`, `contradict_claim`)	i negativi difficili migliorano coppie minime e rimozione dell'evidenza?
D10	+ dati CG2C	il multi-hop sintetico aiuta HoVer e i domini nuovi?

D1 è costoso (7 corse): si può fare sul sottoinsieme da 10k per risparmiare.

Come leggere D1. Se togliendo AVeriTeC la BAcc macro su `dev_select` (calcolata sulle fonti rimaste, per confrontare a parità di fonti) sale di 0,6 e i test comportamentali non cambiano, AVeriTeC (formato domanda–risposta) probabilmente disturba: ridurne la quota.

Fase 3 — Formato e capacità (Winnow)

Si porta su Winnow la configurazione migliore di JPT (ricetta e iperparametri), poi:

ID	Variazione	Domanda
W0	configurazione migliore di JPT, su Winnow	il risultato si trasferisce?
F1	S3 (tre domande) invece di S1	la regola a 3 domande migliora dopo il training?
F2	8.192 token invece di 4.096	aiuta sui documenti lunghi (LFQA, MediaSum, MeetingBank)?
F3	rank 8 / 32 / 64	capacità dell'adapter
F4	2 epoche	sovra-adattamento e calibrazione
F5	nomi dei campi variati	robustezza a integrazioni diverse

Fase 4 — Loss contrastive (opzionale)

Solo dopo aver fissato la configurazione della Fase 3 (04_loss.md, §8):

ID	Variazione	Domanda
X1	+ ranking logistico sulle coppie VitaminC ($\mu = 0{,}3$)	migliorano coppie minime e riassunti?
X2	X1 + coppie generate	più tipi di coppia aiutano?
X3	+ coerenza fra varianti	la stabilità migliora senza perdere BAcc?
X4	$\mu \in \{0{,}1; 0{,}3; 0{,}5\}$	quanto peso dare alla loss di coppia

Controlli finali (obbligatori)

ID	Cosa	Perché
C1	stesso training finale su Gemma-4-12B e Qwen3.5-9B base	se il modello base arriva allo stesso punto, il vantaggio è nei dati, non nel decision model
C2	3 seed della configurazione finale	varianza
C3	Bespoke-MiniCheck-7B e FactCG con la stessa suite	riferimenti esterni nelle stesse condizioni

Calendario indicativo

Settimana	Lavoro
1	Step 0 (split congelati, 00b); Fase 0 (baseline sul nostro dev); codice di rendering, loss e training (03–05); generazione di replay e varianti dal solo train
2	Fase 1 su JPT
3	Fase 2 su JPT (D2, D5, D9 prima; D1 sul sottoinsieme)
4	Fase 3 su Winnow (L40S)
5	controlli C1–C3, congelamento, test, export (08)
poi	Fase 4 e dati CG2C se restano margini

8. Registro degli esperimenti (modello)

Un file `finetune/experiments.md` (o un foglio) con una riga per corsa:

ID	Modello	Mix	Variazione	BAcc dev_select	AUC dev_select	ECE dev_select	KL replay	Oblio (Jev/Kev/tyclad)	Solo claim	Durata	Decisione
B1	JPT	—	soglia da `dev_select`				—	— / — / —		0	baseline
P0	JPT	pilot_text	—								