Fine-tuning per un solo compito: “il documento supporta il claim?” — panoramica

Versione riassuntiva del piano: decisioni e numeri. La guida operativa completa, con comandi e codice, è nei file con lo stesso numero nella cartella superiore (../00_overview.md).

1. La domanda e la risposta in breve

Domanda: come si specializza un decision model in un fact checker binario documento–claim, migliore dei checker esistenti (Bespoke-MiniCheck-7B: 77,4 su LLM-AggreFact)?

Risposta: si parte dai decision model dello studio focalizzato (../../paper_idea/15_focused_10_tdm_experiment_guide.md), si fa **una sola domanda sì/no**, si addestra una LoRA con la cross-entropy **sui soli punteggi delle due opzioni** che il modello legge già, con dati pubblici più dati generati alla MiniCheck/FactCG, in due stadi. Ogni modello si addestra e si serve con il codice dei suoi autori (prompt, maschera di attenzione, lettura).

2. Da dove partiamo

Modello	Base	Ruolo
KnowLine-4B	Qwen3.5-4B, causale, lettura dalla testa del vocabolario	si itera qui (entra in 24 GB anche per il training)
elephant-1	Qwen3.5-9B, bidirezionale a blocchi	modello principale a 9B; coppia principale di B-ctrl
StartLux-9B, d3-flash, OneJev1.6-9B, Nimble-9B-v3, Clef-Flash	Qwen3.5-9B	ricetta finale, per B-ctrl
StartLux-4B, pplx-decider-flash, Jeffan-4B	Qwen3.5-4B	ricetta finale, per B-ctrl
Qwen3.5-9B, Qwen3.5-4B	—	controlli: stessa ricetta sul backbone (B-ctrl)

Tutti hanno la stessa architettura (32 layer, 24 Gated DeltaNet + 8 ad attenzione piena): stessi moduli LoRA per tutti. Cambiano prompt, maschera (causale o bidirezionale sul prompt) e lettura (due righe della testa del vocabolario, o una testa propria per pplx e Clef).

Numeri già noti (regola a tre domande, soglia 0,30): elephant-1 76,70, KnowLine-4B 75,65. I numeri a una domanda dei 10 modelli arrivano dai run dello studio (RUN-01…05).

3. Il percorso in 10 step

Step	Cosa	File
0	split nostri, congelati	00b
0a	perché questo approccio	00a
1	baseline sul nostro dev, con `benchmark.py`	01
2a–2e	dati: fonti, generazione, niente replay, domanda, mix	02a … 02e
3	rendering con il codice degli autori	03
4	loss sulle due opzioni	04
5	training LoRA	05
6	valutazione	06

Step	Cosa	File
7	esperimenti, poi B-ctrl su tutte le ricette	07
8	fusione, soglia, servizio con il runtime degli autori	08

4. Le decisioni chiave

1. Decision model, **una domanda**, lettura che il modello già usa (nessuna testa nuova).
2. **Si itera su KnowLine-4B**, si conferma su elephant-1, poi tutti gli altri e i backbone (B-ctrl).
3. **Prompt, maschera e lettura degli autori**, verificati con un test di identità contro l'adapter del benchmark prima di ogni training.
4. Dati MiniCheck/FactCG + fonti pubbliche, curriculum in due stadi; niente replay.
5. Tutte le scelte sul nostro dev; AggreFact solo come test finale, zero-shot, con e senza RAGTruth.

5. Obiettivi misurabili

Obiettivo	Soglia
LLM-AggreFact zero-shot, BAcc macro, una domanda	> 77,4; puntare a ≥ 78,5
AUC macro su AggreFact	> 85,0
Soglia ottimale sul nostro dev	fra 0,3 e 0,7
ECE e test_ood	non peggiori della baseline
"Solo claim" / "rimozione dell'evidenza"	P media < 0,15 / scende sotto soglia in > 80%
B-ctrl	decision model e backbone fine-tunati con la stessa ricetta, sulle due coppie principali e poi sulle altre

6. Relazione con gli altri documenti

- ../../paper_idea/04_parte_B_finetuning.md: l'esperimento B-ctrl del paper usa questo piano.
- ../../fine_tuning_factcheck_evidence/: estensione con l'evidenza evidenziata, sullo stesso verdetto.