Step 0a — Quale approccio: decision model, classificatore stile FactCG/MiniCheck, o backbone?

Obiettivo

Decidere da dove partire e che cosa addestrare. Dettagli in ../00a_scelta_approccio.md.

1. Le opzioni

Opzione	Pro	Contro
Decision model, una domanda, lettura esistente	parte già bene; probabilità concentrate sulle due opzioni; un forward	prompt, maschera e lettura diversi per ogni modello: vanno riprodotti
Backbone (Qwen3.5) con la stessa ricetta	semplice, licenza Apache 2.0	parte più in basso: è il controllo di B-ctrl
Testa nuova `Linear(d → 2)`	—	stessa capacità della lettura esistente, ma parte da pesi casuali
Encoder stile FactCG (0,4B)	velocissimo	contesto corto, tetto ~75–76

2. Perché non una testa nuova

Con la lettura dalla testa del vocabolario, P(vero) = σ((w_vero − w_falso) · h / T): è già una regressione logistica su h, con pesi inizializzati da ciò che il modello sa. Una testa nuova non aggiunge capacità e parte al 50%. Per pplx-decider-flash e Clef-Flash, che hanno una testa propria, si tiene la loro testa e la si addestra insieme alla LoRA.

3. Decision model o backbone (B-ctrl)

Nessuno ha misurato se, a parità di dati e ricetta, un checker ottenuto da un decision model sia migliore di uno ottenuto dal suo backbone. Si misura sulle coppie elephant-1 / Qwen3.5-9B e KnowLine-4B / Qwen3.5-4B, poi sugli altri 8 decision model.

4. Raccomandazione

1. **KnowLine-4B per iterare** (causale, due token della testa del vocabolario, 24 GB bastano).
2. **elephant-1 come modello principale a 9B** (MIT).
3. Gli altri 8 decision model e i due backbone con la ricetta finale (B-ctrl).
4. Domanda scelta sul nostro dev fra Q1, Q2 e Q4 dello studio.
5. Controllo encoder (A5) e distillazione facoltativa.

5. Cosa si perde specializzando

Il modello non è più un decision model generale (nome `-fc`, model card); l'uscita è binaria; StartLux e Nimble restano non commerciali (CC BY-NC).

Criteri per passare allo step successivo

- Ruoli dei modelli registrati; controlli (B-ctrl, encoder) in programma.