Step 1 — Baseline: quanto valgono i candidati prima del training

Obiettivo

Misurare, con lo stesso protocollo (00b), tutti i punti di partenza fra cui si sceglie in 00a: decision model con una e con tre domande, modelli base, classificatori stile FactCG/MiniCheck. Ogni guadagno successivo si misura contro queste righe.

1. Cosa si sa già (dalle cache, senza nuova inferenza)

Calcolato in questa sessione da `results/runs/<modello>{,-dev}/answers.jsonl`: soglia fittata sui 4.520 righe del dev di AggreFact (`dev_split.py`), applicata al test. Sono numeri **secondari** (dev-tuned), utili per orientarsi.

Modello	Domande	Soglia	BAcc dev	BAcc test	AUC test
Winnow-12B-BF16	3 (`min`)	0,22	77,77	77,42	85,02
Winnow-12B-BF16	solo `support_simple`	0,95	76,76	**76,69**	84,03
JPT-9B (T = 1,087)	3 (`min`)	0,72	77,76	76,71	84,57
JPT-9B (T = 1,087)	solo `support_simple`	0,90	76,87	**76,20**	84,07
FactCG-DeBERTa-v3-L	—	0,5		75,64	

Script usato (fuori dalla repo, da rendere permanente in `finetune/`): per Winnow `P = σ((z_B − z_A)/T)` dai logit di `support_simple`; per JPT la probabilità già in cache; stessa `tune_threshold` e stessa `metrics` di metrics.py. La regola a 3 domande riproduce esattamente i numeri di `results/runs/dev_threshold_summary.md`, quindi il calcolo è coerente.

Lettura: - **Costo della domanda singola**: −0,7 (Winnow) e −0,5 (JPT) di BAcc, −1,0 e −0,5 di AUC. Piccolo, e il training lavora proprio su questa domanda. - **Soglia 0,90–0,95**: zero-shot `support_simple` dice "sì" troppo facilmente. Le domande 2 e 3 della regola di Jev servivano proprio a correggere questo. Il fine-tuning deve riportare la soglia ottimale verso il centro.

2. Le baseline da misurare

ID	Modello	Regola	Perché
B1	Winnow-12B-BF16, JPT-9B	1 domanda (`support_simple`)	**punto di partenza vero** del piano
B2	idem	3 domande	per sapere quanto la domanda singola deve recuperare
B3	idem	1 domanda, formulazione alternativa (quella di `packs/binary_support.json`: "Does the document establish the entire claim? …")	la domanda migliore zero-shot si sceglie qui, una volta, sul dev
B4	Gemma-4-12B, Qwen3.5-9B **base**	1 domanda, stesso prompt	punto di partenza del controllo C1 (opzione L2 di 00a)
B5	FactCG-DeBERTa-v3-L (`FactCG/benchmark.py`)	chunk 550, `max`, soglia 0,5 e fittata	riferimento encoder (opzione E1)

ID	Modello	Regola	Perché
B6	MiniCheck-Flan-T5-L, MiniCheck-DeBERTa-L	idem	riferimento della ricetta MiniCheck
B7	Bespoke-MiniCheck-7B	prompt e aggregazione ufficiali	riferimento LLM con la stessa ricetta di dati

B5–B7 servono a confrontare **sulla nostra suite** (test_id, test_ood, test_long), non solo su AggreFact dove i numeri sono già pubblici.

3. Procedura

1. Inferenza su `dev_select` e `dev_confirm` per B1–B7 (B2 è gratuita se si fa B1 con tutte e tre le domande: stessa cache).
2. Per ciascuno, su `dev_select`: temperatura (minimo log-loss), poi soglia (BAcc macro, griglia 0,01–0,99). Riportare anche la BAcc a soglia 0,5.
3. Conferma su `dev_confirm` (calo $\leq$ ~1 punto).
4. Una sola esecuzione su test_id, test_ood, test_long; AggreFact dalle cache dove esistono.
5. Test comportamentali (06, §4).

Scelta della domanda (B1 contro B3). Si sceglie la formulazione con AUC più alta su `dev_select`. Da lì in poi è **la** domanda del modello: training, valutazione e produzione la usano identica.

4. Tabella attesa

Blocco	Metrica	Winnow 1D	JPT 1D	Gemma-4-12B base	Qwen3.5-9B base	FactCG-DBT	Bespoke-7B
dev_select	BAcc / AUC						
dev_select	BAcc a 0,5						
test_id	BAcc macro						
test_ood	BAcc macro						
test_long	BAcc macro						
AggreFact (soglia dal nostro dev)	BAcc / AUC		/ 84,03				
AggreFact (secondaria)	BAcc	76,69	76,20			75,64 (0,5)	77,4
Solo claim	P media						
Costo	ms per claim, GPU						

Criteri per passare allo step successivo

- B1, B4, B5 misurati su dev e test; domanda scelta (B1 o B3).
- Configurazione di partenza (domanda, temperatura, soglia) congelata per JPT e Winnow.

Errori comuni

- Confrontare il modello fine-tunato a una domanda con la baseline a tre domande senza dirlo: la differenza di regola vale ~0,5–0,7 punti da sola.
- Usare la soglia della baseline (0,90–0,95) sul modello fine-tunato: va sempre rifittata.