Step 2e — Il mix: curriculum a due stadi, come MiniCheck e FactCG

Obiettivo

Mettere insieme le fonti (02a) e i dati generati (02b) in **due training set ordinati**: prima i dati che insegnano la logica del supporto, poi quelli che riportano il modello alla distribuzione d'uso. È la struttura usata da entrambi i paper e, insieme ai dati, è la parte della loro ricetta che si trasferisce a qualsiasi backbone.

1. Perché due stadi

Paper	Stadio 1	Stadio 2
MiniCheck	21k ANLI difficili + 7k C2D, 2 epoche, lr 5e-5 (1e-5 per RoBERTa)	7k D2C, 1 epoca, lr 1e-5
FactCG	NLI + C2D + CG2C-MHQA, 1 epoca	D2C + CG2C-Doc, 1 epoca, ottimizzatore nuovo

Motivo dichiarato da MiniCheck: i documenti sintetici (C2D) hanno uno stile riconoscibile; se il training finisce su quelli, il modello si adatta allo stile. Il secondo stadio su testi reali corregge lo spostamento.

2. Le ricette

Formato: lo stesso JSON di `make_mix.py` (`{fonte: {"cap": N, "balance": bool}}`), una ricetta per stadio. Il mix legge solo `data/finetune/splits/train/`.

`fc_pilot` — pilota a uno stadio (~25k coppie)

Serve a verificare che il training funzioni, prima di generare dati nuovi.

```
{"minicheck": {"cap": 0, "balance": false},
 "anli_hard": {"cap": 6000, "balance": true},
 "summedits": {"cap": 0, "balance": false},
 "hover": {"cap": 2000, "balance": true},
 "vitaminc": {"cap": 1500, "balance": true},
 "fever": {"cap": 1500, "balance": true}}
```

`fc_stage1` — logica del supporto (~45–60k coppie)

```
{"minicheck_c2d": {"cap": 0, "balance": false},
 "c2d_ext": {"cap": 15000, "balance": false},
 "anli_hard": {"cap": 20000, "balance": true},
 "cg2c_mhqa": {"cap": 10000, "balance": true},
 "hover": {"cap": 6000, "balance": true},
 "vitaminc": {"cap": 5000, "balance": true},
 "fever": {"cap": 4000, "balance": true}}
```

`fc_stage2` — distribuzione d'uso (~25–40k coppie)

```
{"minicheck_d2c": {"cap": 0, "balance": false},
 "d2c_ext": {"cap": 20000, "balance": false},
 "summedits": {"cap": 0, "balance": false},
 "cg2c_doc": {"cap": 6000, "balance": true},
 "remove_evidence_long": {"cap": 5000, "balance": false},
 "averitec": {"cap": 0, "balance": false}}
```

(`minicheck` è da dividere in `minicheck_c2d` e `minicheck_d2c` usando `meta.subset` (`c2d` / `d2c`), già presente in ogni riga; `anli_hard` viene da 02a §3.)

Variante a uno stadio (controllo)

`fc_stage1 ∪ fc_stage2` mescolati, 1 epoca: esperimento D-CUR in 07. Se il risultato è uguale entro 0,5 punti, si tiene la versione a uno stadio (più semplice).

3. Principi per le proporzioni

1. **Dati costruiti per il compito al centro.** MiniCheck, C2D/D2C estesi e CG2C sono ≥ 50% di ciascuno stadio.
2. **Fonti grandi con tetti bassi.** FEVER e VitaminC hanno centinaia di migliaia di righe ma insegnano scorciatoie: ≤ 10% ciascuna.
3. **Negativi "non stabilito" ≥ 40% dei negativi.** Sono il caso che i nostri modelli sbagliano di più (soglia 0,90–0,95 di `support_simple`: dicono "sì" quando manca un pezzo).
4. **Documenti lunghi nello stadio 2.** Almeno ~20% delle righe con documento > 2.000 token (D2C su notizie e trascrizioni, SummEdits, `remove_evidence` su documenti lunghi).

4. Bilanciamento

50/50 per fonte di default; le famiglie generate si bilanciano con le loro coppie positive (stesso `doc_id`). Controllo finale per stadio: positivi 45–55%.

5. Controlli sul mix prodotto

Controllo	Valore atteso
Positivi per stadio	45–55%
Negativi "non stabilito" / negativi	≥ 40%
`doc_id` in comune con dev/test dello Step 0	0
Righe generate da righe non di train	0
Documenti oltre il budget di token (troncati)	< 1% per fonte, oppure chunking (03, §4)
Fonti escluse	RAGTruth sempre; WiCE salvo esperimento dedicato

6. Comandi

```
conda run -n factcheck python data_prep/make_mix.py --recipe fc_pilot.json  --name fc_pilot
conda run -n factcheck python data_prep/make_mix.py --recipe fc_stage1.json --name fc_stage1
conda run -n factcheck python data_prep/make_mix.py --recipe fc_stage2.json --name fc_stage2
```

Criteri per passare allo step successivo

- `mix_fc_pilot` prodotto e verificato (§5); `fc_stage1`/`fc_stage2` prodotti dopo lo step 2b.
- Statistiche di lunghezza in token (p50, p95) per stadio registrate.