Step 6 — Valutazione di un fact checker binario specializzato

Obiettivo

Misurare se il modello fine-tunato è un fact checker binario migliore della baseline e dei riferimenti esterni (FactCG, MiniCheck, Bespoke), su domini visti e non visti, su documenti lunghi, con probabilità utilizzabili con una soglia fissa e a un costo noto. Rispetto al piano generale (../fine_tuning/06_valutazione.md) sparisce l'oblio e aumentano calibrazione, documenti lunghi e costo.

1. La suite

Blocco	Contenuto	Cosa misura	Quando	Usato per decidere?
dev_select	~60% del dev delle fonti di training	soglia, temperatura, checkpoint, esperimenti, dimensione dei chunk	sempre	**sì**
dev_confirm	~40% del dev	conferma	una volta per fase	solo conferma
test_id	test delle fonti di training	apprendimento	baseline e fine	no
test_ood	SciFact, Climate-FEVER, HealthVer/COVID-Fact, HaluBench, HalluMix, LLM-Oasis	generalizzazione	baseline e fine	no
test_long	righe di test_id e test_ood > 4.000 token	chunking, documenti lunghi	baseline e fine	no
AggreFact test	11 fonti	confronto con la leaderboard, zero-shot	baseline e fine	no
Comportamentali	generati da `dev_select`	il modello guarda il documento?	ogni esperimento	come vincolo
Costo	1.000 righe miste	latenza e throughput	modello finale	no

2. Metriche

Metrica	Perché
BAcc per fonte, media per blocco, media dei blocchi	metrica principale, come la leaderboard
AUC	ordinamento, indipendente dalla soglia
BAcc a soglia 0,5	se è vicina a quella a soglia fittata, il modello è usabile senza dev (obiettivo MiniCheck)
ECE (10 intervalli), Brier	calibrazione
Soglia ottimale su `dev_select`	segnale diretto del bias: baseline 0,90–0,95
Recall dei supportati e dei non supportati, separatamente	dove sbaglia: "sì" troppo facili o "no" troppo facili
BAcc per tipo di negativo (`contradicted` / `not_established`)	i "non stabilito" sono il punto debole atteso
Latenza p50/p95 per claim, claim/s	costo d'uso

Incertezza: bootstrap per documento (`document_cluster_bootstrap` in core/metrics.py); differenze sotto ~0,5 punti di media non conclusive.

3. Soglia

1. Temperatura (minimo log-loss) e soglia (BAcc macro, griglia 0,01–0,99) su `dev_select`; conferma su `dev_confirm`; applicate a tutti i test.
2. Riportare **anche** la soglia fissa 0,5.
3. Soglia secondaria, dichiarata, fittata sul dev di AggreFact: solo per confronto con i numeri esistenti.
4. Niente soglie per fonte.

4. Test comportamentali

Test	Trasformazione	Atteso	Obiettivo
Solo claim	documento vuoto	non supportato	P media < 0,15
Rimozione dell'evidenza	righe supportate con evidenza nota (FEVER, HoVer, C2D): tolte le frasi gold	la probabilità scende sotto soglia	> 80% delle righe (baseline da misurare: con soglia 0,95 il modello di partenza dice spesso "sì" comunque)
Claim parziale	claim supportato + un fatto in più non presente nel documento (da C2D: power set)	non supportato	> 80%
Distrattori	paragrafi irrilevanti aggiunti	decisione invariata	> 95%
Posizione	evidenza all'inizio, a metà, alla fine di un documento lungo	decisione invariata	differenza < 2 punti
Evidenza divisa fra chunk	documento lungo con le due frasi necessarie in chunk diversi	supportato se C è abbastanza grande	misura del limite della regola `max`
Coppie minime	numero/data/entità cambiati	decisione invertita	migliore della baseline

"Claim parziale" ed "evidenza divisa" sono nuovi rispetto al piano generale: misurano proprio ciò che C2D/CG2C dovrebbero insegnare.

5. Confronto con i riferimenti

Tutti con lo stesso protocollo (soglia dal nostro dev, più soglia 0,5):

Modello	Taglia	Ruolo
Baseline a una domanda (stesso modello prima del training)	4B / 9B	punto di partenza
Baseline a tre domande	4B / 9B	quanto si è recuperato della regola di Jev
Backbone fine-tunato con la stessa ricetta (B-ctrl)	4B / 9B	valore dell'inizializzazione da decision model

Modello	Taglia	Ruolo
Encoder E1 fine-tunato sugli stessi dati	0,4B	valore della taglia
FactCG-DeBERTa-v3-L, MiniCheck-FT5	0,4B / 0,8B	riferimenti pubblici
Bespoke-MiniCheck-7B	7B	miglior modello aperto con la stessa ricetta di dati

6. Report finale (formato)

Blocco	Metrica	Baseline 1D	Baseline 3D	Fine-tunato	Δ vs 1D	IC 95%
test_id	BAcc					
test_ood	BAcc					
test_long	BAcc					
AggreFact (zero-shot)	BAcc / AUC					
Media dei blocchi	BAcc					
AggreFact, soglia 0,5	BAcc					
AggreFact (secondaria)	BAcc	76,69 / 76,20	77,42 / 76,71			
Calibrazione	ECE, soglia ottimale					
Comportamentale	std	claim / rimozione / parziale				
Costo	ms per claim					

Più le tabelle per fonte e la tabella AggreFact nel formato della leaderboard.

7. Codice

Esiste: benchmark dei modelli, `calibrate_transfer.py`, `metrics.py`, `FactCG/benchmark.py`. Da scrivere: lettura degli split dello Step 0 e opzione `--model-dir` per i pesi fusi; supporto della domanda singola e di `question.json` nei benchmark; chunking per i decision model (oggi i benchmark troncano a `max_doc_chars`); `finetune/behavioral.py` con i test di §4; script `support_simple`-only (il calcolo di 01 §1, oggi fuori dalla repo).