Rischi e checklist

1. Rischi principali

Rischio	Come si riconosce	Prevenzione	Rimedio
Bias verso “sì” non corretto	soglia ottimale ancora > 0,85; “rimozione dell’evidenza” < 80%	negativi “non stabilito” ≥ 40% dei negativi; C2D, `remove_evidence`	più negativi per cancellazione; domanda Q3 con descrizioni esplicite
Sovra-confidenza	ECE in aumento; probabilità tutte 0/1	loss sulle lettere, 1 epoca per stadio	Brier, smoothing, β·KL, temperatura rifittata
Stile sintetico imparato	ottimo su C2D/CG2C, nessun guadagno su test_ood/AggreFact	stadio 2 su testi reali (D2C, SummEdits)	più D2C reale; meno sintetico nello stadio 1
Contaminazione	guadagno forte su una sola fonte di AggreFact	D2C solo con documenti non presenti in AggreFact (13-grammi); RAGTruth escluso	togliere la fonte e riportare con e senza
Etichette generate sbagliate	campione con errori; giudice che scarta > 40%	etichetta dall’operazione + giudice diverso	Brier/smoothing; rivedere i prompt
ANLI difficile = ANLI rumoroso	molti errori “sicuri” con etichette discutibili	errori sicuri ≤ 30% del sottoinsieme	smoothing su quelle righe; tetto più basso
Chunking che spezza le catene	“evidenza divisa” fallisce; LFQA/ExpertQA peggiori	chunk grandi per l’LLM (≥ 4k)	`min×max` sulle frasi del claim (K2)
Positivi troncati in training	evidenza tagliata → etichetta sbagliata	i positivi non si spezzano (03 §4)	budget più alto o scarto
Prompt diverso da quello di produzione	calo appena cambia una parola	domanda unica congelata in `question.json`	normalizzare l’input nel codice chiamante
Lettere invertite	la loss non scende o sale	test di rendering (A = sì in KnowLine ed elephant-1; A = no in d3-flash, Jeffan, pplx)	correggere i target
Maschera bidirezionale persa in training	passo zero diverso dalla baseline per elephant-1, StartLux, d3-flash, pplx, Jeffan	test della maschera (03)	usare il forward degli autori
Margine ridotto ≠ forward completo	probabilità del training diverse dall’inferenza	test di 05 §6 (softcapping incluso)	applicare la stessa trasformazione ai logit
Conclusione sbagliata sull’architettura	si sceglie il decision model senza sapere se il backbone farebbe uguale	fase A e fase B (B-ctrl)	—
Specializzazione non dichiarata	qualcuno usa il modello per altre domande	nome `-fc`, model card	—
Overfitting del dev	ottimo su `dev_select`, peggio su `dev_confirm`	criteri di adozione ≥ 0,5 punti	conferma su `dev_confirm`
Test guardato troppo presto	—	test solo dopo `frozen.json`	dichiararlo
Licenze	—	08 §7	ricetta con dati permissivi

2. Checklist per step

Step 0 — Split

- ☐ Split congelati (riuso di `data/finetune/splits/` se esiste già per il piano generale).
- ☐ `test_long` definito.
- ☐ Decontaminazione contro AggreFact e test_ood; nessun `doc_id` condiviso.

Step 0a — Approccio

- ☐ Backbone principale e controlli (A2, A3, A5) decisi.
- ☐ Deciso se la distillazione è un requisito.

Step 1 — Baseline

- ☐ B1 (una domanda) e B2 (tre domande) sul nostro dev; B3 per scegliere la domanda.
- ☐ B4 (modelli base), B5–B7 (FactCG, MiniCheck, Bespoke).
- ☐ Domanda di produzione scritta in `finetune/question.json`.

Step 2a — Fonti

- ☐ `anli_hard` prodotto solo dal train, con quota di errori sicuri registrata.
- ☐ (Se CG2C-MHQA) builder HotpotQA/MuSiQue decontaminati.

Step 2b — Generazione

- ☐ Generazione solo dal train; `doc_id` ereditato.
- ☐ Documenti D2C decontaminati contro AggreFact.
- ☐ Tasso di accettazione ≥ 200 esempi per famiglia; 30 letti a mano con < 3 errori.

Step 2c — Replay

- ☐ Confermato che il modello non deve restare generale (altrimenti → piano generale).
- ☐ (Se P-KL) probabilità del modello di partenza precalcolate.

Step 2d — Varianti

- ☐ Domanda unica fissata; varianti solo se P-VAR.

Step 2e — Mix

- ☐ `fc_pilot`, `fc_stage1`, `fc_stage2` prodotti; positivi 45–55%; "non stabilito" ≥ 40% dei negativi; ≥ 20% di righe lunghe nello stadio 2.

Step 3 — Rendering

- ☐ Prompt identici ai benchmark con la domanda scelta.
- ☐ Lettere e target verificati; positivi lunghi non spezzati.

Step 4 — Loss

- ☐ Funzioni testate sui casi numerici di 04.

Step 5 — Training

- ☐ Test "margine ridotto = forward completo", "passo zero = baseline", "overfit di 64 esempi".
- ☐ Monitoraggio: BAcc, AUC, soglia ottimale, BAcc a 0,5, ECE, solo claim, righe lunghe.
- ☐ Ottimizzatore nuovo allo stadio 2.

Step 6 — Valutazione

- ☐ Soglia da `dev_select`, confermata; soglia 0,5 riportata; secondaria dichiarata.
- ☐ Comportamentali, inclusi “claim parziale” ed “evidenza divisa”.
- ☐ Riferimenti esterni con lo stesso protocollo.

Step 7 — Esperimenti

- ☐ Fase A completata e interpretata.
- ☐ Fase B (B-ctrl) almeno sulle due coppie principali; C2–C3 eseguiti.

Step 8 — Export

- ☐ Fusione su bf16 verificata con l’adapter del benchmark sulla cartella fusa.
- ☐ `decision.json` con domanda unica, soglia, chunking.
- ☐ (Opzionale) testa estratta verificata; studente distillato valutato.
- ☐ `frozen.json` prima del test; model card che dichiara la specializzazione.