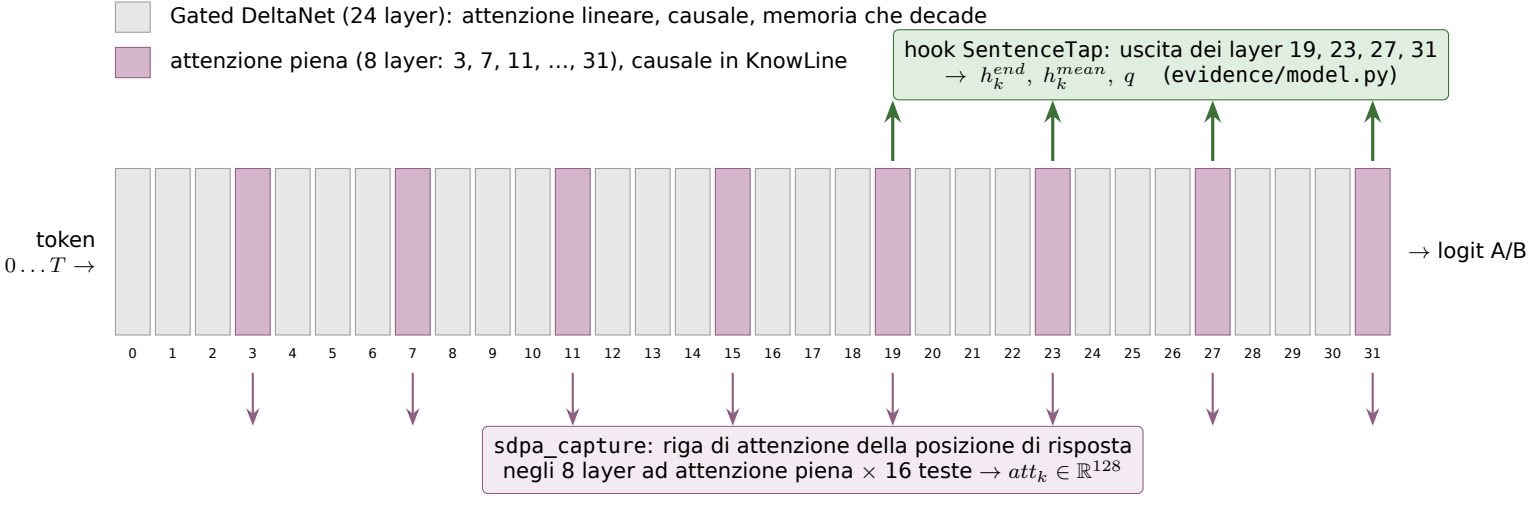
Gated DeltaNet (24 layer): attenzione lineare, causale, memoria che decade
attenzione piena (8 layer: 3, 7, 11, ..., 31), causale in KnowLine
hook SentenceTap: uscita dei layer 19, 23, 27, 31
$\rightarrow$ h_k^{end}, h_k^{mean}, q (evidence/model.py)
token
$0 \ldots T \rightarrow$
$\rightarrow$ logit A/B
0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31
sdpa_capture: riga di attenzione della posizione di risposta
negli 8 layer ad attenzione piena $\times$ 16 teste $\rightarrow$ $att_k \in \mathbb{R}^{128}$