# Step 0 — Split e protocollo, con l'evidenza

## Obiettivo

Riusare gli split congelati del piano binario (../fine_tuning_factcheck/00b_split_e_protocollo.md) e aggiungere i **sottoinsiemi con evidenza annotata a livello di frase**, su cui si misura e si sceglie tutto ciò che riguarda l'evidenziazione.

## 1. I blocchi

| Blocco | Contenuto | Uso |
|---|---|---|
| dev_select / dev_confirm | come nel piano binario | verdetto: soglia, temperatura, checkpoint |
| **dev_evid_select** | righe **supportate** di `dev_select` con evidenza gold (FEVER, HoVer, C2D) | soglia di evidenza `τ_e`, checkpoint della testa, esperimenti H |
| **dev_evid_confirm** | idem da `dev_confirm` | conferma |
| test_id, test_ood, AggreFact | come nel piano binario | verdetto, una volta alla fine |
| **test_evid_id** | righe supportate di test_id con evidenza gold (FEVER `paper_test`, metà del dev di HoVer, 10% di C2D) | evidenza in distribuzione |
| **test_evid_ood** | SciFact (rationale annotate), WiCE (frasi di evidenza annotate) | evidenza fuori dominio |
| **test_evid_sparse** | da test_evid_id: documenti in cui le frasi gold distano $\geq 10$ frasi, più versioni costruite con le frasi gold spostate agli estremi (§3) | evidenza sparsa |

Solo righe **supportate**: l'evidenza si misura dove esiste.

## 2. Fonti con evidenza a livello di frase

| Fonte | Evidenza gold | Split | Note |
|---|---|---|---|
| FEVER | insiemi di (pagina, riga); più insiemi alternativi per claim | train / paper_dev / paper_test | annotazioni **incomplete**: altre frasi possono supportare senza essere annotate (04 §3) |
| HoVer | `supporting_facts` (titolo, indice di frase), 2–4 pagine | train / dev diviso a metà | multi-hop: è il banco di prova dell'evidenza sparsa |
| MiniCheck C2D | le coppie di frasi `s_i,1`, `s_i,2` (se ricostruibili, 02a) | 80/10/10 per documento | |
| SciFact | frasi di *rationale* dell'abstract | solo test (OOD) | dominio biomedico |
| WiCE | frasi di evidenza della pagina citata | solo test (OOD) | è anche una fonte di AggreFact: mai in training, va bene come test di evidenza |

## 3. Il test di evidenza sparsa costruito

Da ogni riga di test_evid_id con almeno 2 frasi gold: 1. si prende il documento; 2. si sposta la prima frase gold all'inizio e l'ultima alla fine (le altre restano), oppure si inseriscono paragrafi irrilevanti da altri documenti dello **stesso split di test** fra le frasi gold; 3. si controlla che il testo resti coerente (le frasi spostate non devono dipendere da pronomi risolti dalla frase precedente; se lo fanno, la riga si scarta).

Il verdetto resta "supportato" e l'evidenza resta la stessa, con nuove posizioni. Si riportano i risultati per **distanza** fra le frasi gold: adiacenti, 2–9 frasi, 10–19, $\geq 20$.

## 4. Regole contro le fughe

Quelle del piano binario, più: - le etichette di evidenza generate o ricavate per ablazione (02b) si producono **solo sul train**; - i paragrafi distrattori di test_evid_sparse vengono da documenti di test, mai di train.

## 5. Aggregazione

- Verdetto: come nel piano binario.
- Evidenza: metriche per fonte (06), poi media non pesata per blocco (test_evid_id, test_evid_ood, test_evid_sparse).
- Le metriche di evidenza si calcolano sulle righe supportate **che il modello giudica supportate** (perché solo lì evidenzia), e si riporta a parte la quota di righe supportate giudicate non supportate (nessuna evidenza mostrata).

## 6. Output

```
data/finetune/splits/                # del piano binario
data/finetune/evidence/
  dev_evid_select/<fonte>.jsonl      # righe con "sentences" e "evidence"
  dev_evid_confirm/<fonte>.jsonl
  test_evid_id/<fonte>.jsonl
  test_evid_ood/{scifact,wice}.jsonl
  test_evid_sparse/<fonte>.jsonl
  manifest.json
```

## Criteri per passare allo step successivo

- Sottoinsiemi con evidenza congelati, con numero di righe e distribuzione della distanza fra frasi gold.
- Nessun documento di test usato come distrattore nel train e viceversa.