Step 1 — Baseline: verdetto con il nuovo ordine, evidenza senza training

Obiettivo

Sapere, prima di addestrare la testa: 1. quanto costa al verdetto mettere il claim prima del documento (zero-shot); 2. quanto si ottiene sull'evidenza **senza** training, con metodi in un forward; 3. un riferimento di qualità "alta" per l'evidenza, calcolato offline con molti forward.

1. Verdetto

ID	Cosa	Perché
B-1D	decision model, una domanda, ordine nativo (documento → claim)	baseline del piano binario (../fine_tuning_factcheck/01_baseline.md)
B-ORD	stesso modello, **claim → documento**	costo del cambio di formato prima del training
B-FT	modello fine-tunato del piano binario, se già disponibile	riferimento: la testa di evidenza non deve peggiorarlo

Lettura di B-ORD: un calo di qualche decimo è normale (formato mai visto) e viene recuperato dal fine-tuning, che in questo piano usa il nuovo ordine. Un calo di più punti va segnalato: vorrebbe dire che il modello di partenza dipende molto dall'ordine e che il fine-tuning dovrà spostarlo di più.

Per Winnow il cambio d'ordine è nel JSON dello stato (`{"claim":...,"document":...}`); per JPT nelle righe dello stato (`claim:` prima di `document:`). La domanda resta quella scelta nel piano binario.

2. Evidenza senza training (un forward)

Tutte valutate su `dev_evid_select` con le metriche di 06.

ID	Metodo	Costo in produzione	Cosa dice
E-RAND	k frasi a caso (k = numero medio di frasi gold)	0	pavimento
E-LEX	BM25 / sovrapposizione di parole fra claim e frase, top-k o sopra soglia	trascurabile	quanto si ottiene con la sola somiglianza superficiale
E-EMB	coseno fra embedding del claim e della frase (es. un modello di embedding piccolo)	un encoder in più	somiglianza semantica, senza ragionamento
E-ATT	attenzione dalla posizione `Answer:` verso i token di ogni frase, sommata per frase, sulle teste/layer migliori (scelti su metà di `dev_evid_select`, misurati sull'altra metà)	1 forward (serve accesso all'attenzione dell'ultima posizione)	quanto il modello "guarda" già l'evidenza

E-LEX è il riferimento da battere con margine: se la testa addestrata non fa molto meglio della somiglianza lessicale, l'utente potrebbe ottenere quasi lo stesso con un BM25.

E-LEX ed E-EMB falliscono per costruzione sulle frasi ponte (non condividono parole con il claim): su `test_evid_sparse` ci si aspetta un calo forte. È la misura di quanto il problema sia reale.

3. Evidenza di riferimento offline (molti forward)

ID	Metodo	Costo
E-ABL	ablazione greedy con il modello del verdetto: si parte dall'insieme vuoto e si aggiunge ogni volta la frase che alza di più P(supportato), finché si supera la soglia; poi si prova a togliere ogni frase dall'insieme e la si scarta se P resta sopra soglia	$O(n \cdot k)$ forward per riga: solo offline

Serve a due cose: - **riferimento** di qualità per la testa (quanto si avvicina a un metodo fedele per costruzione); - **etichettatore** di dati di training dove non c'è evidenza gold (02b §3).

Su documenti lunghi E-ABL è costoso ($n = 100$ frasi, $k = 3 \rightarrow$ ~300 forward): si calcola su un campione di 300 righe per fonte.

4. Tabella attesa

Metodo	F1 frase (FEVER)	F1 frase (HoVer)	Insieme completo (HoVer)	F1 su sparse	Costo
E-RAND					0
E-LEX					~0
E-EMB					encoder
E-ATT					1 forward
E-ABL (offline)					$O(n \cdot k)$ forward

Criteri per passare allo step successivo

- B-ORD misurato; deciso che il piano procede con il claim prima.
- E-LEX ed E-ATT misurati su `dev_evid_select`; E-ABL su un campione.