Step 2e — Il mix: verdetto per tutti, evidenza dove è nota

Obiettivo

Costruire il training set della fase di evidenza: le stesse righe del verdetto (piano binario) arricchite con `sentences` ed `evidence` dove disponibili, più le righe costruite per l'evidenza sparsa.

1. Composizione

Due mix, secondo la strategia di training (05):

Mix	Per cosa	Contenuto
`ev_head`	testa su backbone **congelato**	**solo righe supportate con evidenza** (gold, construct, ablation, sparse). Il verdetto non si addestra
`ev_joint`	training **congiunto** LoRA + testa	mix del piano binario (stadio 2 o unione) + righe con evidenza; la loss per frase è mascherata dove manca

`ev_head` — pilota (~20k righe)

Famiglia	Righe	`evidence_quality`	Peso nella loss per frase
FEVER SUPPORTS	6.000	gold	1,0
HoVer SUPPORTED	5.000	gold	1,0
C2D con posizioni	2.000	construct	1,0
MiniCheck / D2C / SummEdits per ablazione	3.000	ablation	0,5
Evidenza sparsa costruita	4.000	come la riga di origine	come la riga di origine

`ev_joint` — corsa piena

Il mix finale del piano binario (../fine_tuning_factcheck/02e_mix_finale.md), in cui: - le righe supportate di FEVER e HoVer portano l'evidenza gold; - si aggiungono CG2C con posizioni, C2D con posizioni e le righe sparse (~20–30% del totale); - le negative restano tutte (servono al verdetto).

2. Principi

1. **Molta evidenza multi-frase.** Almeno il 40% delle righe con evidenza deve averne ≥ 2 frasi; FEVER ha soprattutto evidenza a una frase, HoVer e CG2C a 2–4.
2. **Distanza variata.** Distribuzione della distanza fra la prima e l'ultima frase gold: almeno il 25% oltre 10 frasi (con le righe sparse costruite).
3. **Domini diversi da Wikipedia.** C2D, CG2C su notizie e righe per ablazione su D2C/SummEdits $\geq 30\%$ delle righe con evidenza: altrimenti la testa impara lo stile delle pagine Wikipedia.
4. **Documenti lunghi.** Righe con > 50 frasi $\geq 15\%$: in produzione la testa deve scegliere 2–3 frasi su centinaia.

3. Controlli

Controllo	Atteso
Frasi di evidenza per riga (media)	1,8–2,5
Quota di frasi evidenza sul totale delle frasi	~2–10% (classe molto sbilanciata: 04 §2)

Controllo	Atteso
Righe con `sentences` incoerenti con `document`	0
`doc_id` condivisi con dev/test	0
Distrattori delle righe sparse presi da documenti di dev/test	0

4. Comandi

```
conda run -n factcheck python data_prep/make_mix.py --recipe ev_head.json  --name ev_head
conda run -n factcheck python data_prep/make_mix.py --recipe ev_joint.json --name ev_joint
```

(`make_mix.py` va esteso per conservare `sentences`, `evidence`, `evidence_quality`.)

Criteri per passare allo step successivo

- `mix_ev_head` prodotto con le statistiche di §3.
- Distribuzione della distanza fra frasi gold registrata.