Step 6 — Valutazione: verdetto invariato, evidenza corretta, costo invariato

Obiettivo

Verificare tre cose: 1. il verdetto non è peggiorato rispetto al modello del piano binario; 2. le frasi evidenziate sono quelle giuste, anche quando sono lontane fra loro; 3. la latenza resta quella di un decision model.

1. La suite

Blocco	Cosa misura	Quando
dev_select, test_id, test_ood, AggreFact	verdetto (come nel piano binario)	dev sempre; test una volta
dev_evid_select / confirm	evidenza: scelte e conferma	sempre / una volta per fase
test_evid_id (FEVER, HoVer, C2D)	evidenza in distribuzione	una volta
test_evid_ood (SciFact, WiCE)	evidenza fuori dominio	una volta
test_evid_sparse	evidenza lontana	una volta
Latenza	1.000 richieste reali di lunghezza mista	modello finale

2. Metriche di evidenza

Calcolate sulle righe **supportate e giudicate supportate** dal modello (solo lì si evidenzia):

Metrica	Definizione	Perché
Precisione / recall / F1 per frase	sulle frasi mostrate (sopra `τ_e`)	qualità di base
Recall dell'insieme completo	quota di righe in cui **tutte** le frasi gold sono mostrate	un'evidenza multi-hop a metà non convince l'utente
Match esatto dell'insieme	frasi mostrate = frasi gold	molto severa; utile per confronti
AUPRC per frase	indipendente da `τ_e`	ordinamento delle frasi
F1 per fascia di distanza	adiacenti / 2–9 / 10–19 / ≥ 20 frasi	evidenza sparsa
Sufficienza	le sole frasi mostrate, come documento, danno P(supportato) sopra soglia	non dipende dalle annotazioni incomplete
Necessità	togliendo le frasi mostrate, P scende sotto soglia	indica se l'evidenza mostrata è davvero quella usata (con documenti ridondanti può fallire anche se l'evidenza è giusta: riportare, non vincolare)

Sufficienza e necessità costano 2 forward per riga: si calcolano solo in valutazione, mai in produzione.

Per FEVER con più insiemi gold: una riga conta come "insieme completo" se le frasi mostrate contengono **almeno uno** degli insiemi.

3. Metriche del verdetto

Identiche al piano binario (../fine_tuning_factcheck/06_valutazione.md), confrontate con il modello del piano binario **con lo stesso ordine** claim → documento. Con la fase 1 (backbone congelato) devono essere identiche: è un controllo che pipeline e rendering non siano cambiati.

4. Latenza

Misura	Come	Obiettivo
Latenza p50/p95	stesso server, stesse richieste, con e senza testa	$\leq +3\%$
Throughput	richieste/s con batching	$\leq -3\%$
Overhead della testa	tempo dell'aggregatore da solo	< 1 ms per richiesta
Trasferimento degli stati	$n \times d$ valori dalla GPU (solo posizioni di fine frase)	trascurabile; se il server restituisce tutti gli stati, non lo è: va evitato (08)

5. Comportamentali

Test	Atteso
Evidenza spostata (inizio/metà/fine)	stesse frasi evidenziate, nuove posizioni
Distrattori aggiunti	nessun distrattore evidenziato
Frase di evidenza duplicata altrove nel documento	entrambe evidenziate o almeno una; mai nessuna
Claim supportato da una frase che non condivide parole (parafrasi)	evidenziata comunque (E-LEX fallisce qui)

6. Report finale (formato)

Blocco	Metrica	E-LEX	E-ATT	E-ABL (offline)	Testa, fase 1	Testa, fase 2
test_evid_id	F1 / insieme completo					
test_evid_ood	F1 / insieme completo					
test_evid_sparse	F1 ≥ 20 frasi					
tutti	sufficienza					
verdetto	BAcc media dei blocchi	—	—	—	= piano binario	
latenza	p50 / p95			$n{\cdot}k$ forward		

7. Codice

Da scrivere: `finetune/eval_evidence.py` (metriche di §2, fasce di distanza, sufficienza e necessità con vLLM), estensione dei benchmark per l'ordine claim → documento, `finetune/latency.py`.