Step 7 — Piano degli esperimenti

Obiettivo

Arrivare alla testa di evidenza finale con il minimo di corse. Quasi tutti gli esperimenti si fanno in **fase 1** (backbone congelato, stati salvati): durano minuti, non ore. Solo la conferma finale e la fase 2 richiedono GPU per molte ore.

Regole

1. Una variazione per esperimento, registrata.
2. Si decide su `dev_evid_select` (F1 per frase, recall dell'insieme completo, F1 oltre 10 frasi) e, per la fase 2, anche sul verdetto in `dev_select`.
3. Si adotta una variazione se migliora l'F1 di ≥ 1 punto o la recall dell'insieme completo di ≥ 2 punti, senza peggiorare il verdetto.
4. Prima su JPT-9B, poi su Winnow-12B.

Fase 0 — Baseline

ID	Cosa
B-ORD	verdetto con claim → documento, zero-shot
E-RAND, E-LEX, E-EMB	evidenza senza modello
E-ATT	attenzione da `Answer:` (teste scelte su metà del dev)
E-ABL	ablazione greedy offline, su campione

Fase H — Testa di evidenza (fase 1, backbone congelato)

Riferimento **H0**: ultimo layer, aggregatore 2 layer, BCE pesata + ranking ($\gamma = 0{,}5$), mix `ev_head`.

ID	Variazione	Domanda
H0	—	la testa batte E-LEX ed E-ATT? Se no, controllare rendering e posizioni prima di tutto
H1	fase 2 (congiunto) invece di backbone congelato	quanto si guadagna sbloccando la LoRA, e quanto costa al verdetto
H2	layer: ultimo / ~2/3 / concatenazione	quale rappresentazione localizza meglio l'evidenza
H3a	testa lineare per frase (senza aggregatore)	quanto serve l'aggregatore (atteso: crollo sull'evidenza sparsa)
H3b	solo pointer $q^\top W h_k$	alternativa più semplice
H3c	aggregatore 1 / 2 / 4 layer	capacità necessaria
H4	ordine nativo documento → claim (con verdetto addestrato in quell'ordine)	quanto vale mettere il claim prima
H5	senza righe sparse costruite	l'augmentation serve? (atteso: calo oltre 10 frasi)
H6	λ nella fase 2: 0,1 / 0,3 / 1	equilibrio fra evidenza e verdetto
H7	$\gamma = 0$ / 0,5 / 1; ω FEVER 0,3 / 1; unione vs "almeno un insieme"	gestione delle annotazioni incomplete
H8	solo gold vs gold + construct vs + ablation	valore delle etichette generate e ricavate
H9	senza embedding della posizione della frase	la posizione aiuta o crea un bias verso inizio/fine?

Come leggere H3a contro H0. Se la testa lineare è vicina all'aggregatore su FEVER (evidenza di una frase) ma molto sotto su HoVer e sulle righe sparse, l'aggregatore sta facendo il lavoro previsto. Se è vicina anche sulle sparse, il claim prima del documento basta e l'aggregatore si può semplificare.

Fase W — Winnow e conferma

ID	Cosa
W0	configurazione migliore di JPT su Winnow (fase 1)
W1	fase 2 su Winnow, solo se su JPT H1 ha dato un guadagno chiaro
L1	misura di latenza con e senza testa sul server di produzione

Controlli finali

ID	Cosa
C1	3 seed della testa finale (fase 1: costo minimo)
C2	sufficienza e necessità su tutti i test di evidenza
C3	confronto con E-ABL: quanto la testa in un forward si avvicina al metodo da n forward

Calendario indicativo

Settimana	Lavoro
1	builder con evidenza (02a), segmentazione e rendering con posizioni (03), Fase 0
2	etichette construct/ablation e righe sparse (02b); estrazione degli stati; H0–H9
3	H1 (fase 2) se serve; Winnow (W0–W1); latenza
4	controlli, congelamento, test, export

Prerequisito: il modello del verdetto con claim → documento (../fine_tuning_factcheck/); può procedere in parallelo, la Fase H si rifà sul modello finale.

Registro

`finetune/experiments_evidence.md`:

ID	Modello	Fase	Variazione	F1 frase	Insieme completo	F1 ≥ 10 frasi	Sufficienza	Δ verdetto	Decisione
E-LEX	—	—	—					—	baseline
H0	JPT	1	—					0	