Stato dell'arte e novità

1. Tre filoni che si incontrano

1.1 Typed decision model (TDM)

Modelli che non generano testo: leggono uno stato e domande tipizzate (*choice*, *noul* sì/no, *score*) e restituiscono una probabilità per opzione in una sola passata.

Modello	Tipo	Note
Jev 1.13 (TypeSafe)	chiuso, API	rilasciato il 15/09/2026; riferimento del filone
Winnow-12B	aperto (Gemma-4-12B), Apache 2.0	GGUF + server llama.cpp
JPT-9B	aperto (Qwen3.5-9B + LoRA), CC BY-NC 4.0	implementazione `llm2jev`
Rune-26B-A4B	aperto (Gemma-4 MoE)	
Laya (421M), Kev-9B/4B, djev-0.1	aperti	citati in JevBench e nei benchmark di Winnow

Letteratura (settembre–ottobre 2026), tutta molto recente:

- **Audit dei primi 28 paper** (2609.32160): rassegna e **checklist di 14 punti** per valutare i TDM (baseline, disegno dei test, riproducibilità, calibrazione e deployment). Nessun paper si concentra su fact checking, allucinazioni, NLI o verifica di claim; il fine-tuning dei modelli aperti non è trattato.
- **JEV-as-a-Judge** (2609.26550): Jev come giudice economico con escalation; fra i compiti, **240 casi di HaluEval** con evidenza; trova rumore nelle etichette di HaluEval. Solo Jev, nessun modello aperto, nessun benchmark di grounding completo.
- **JevBench** (preprint): framework di valutazione generale dei TDM (Jev, djev-0.1, Laya).
- Altri: copertura delle opzioni candidate (2610.03387), agent harness (2610.02267), penetration testing (2609.28940), decisioni scientifiche (2609.24965).

1.2 Fact checker specializzati su documento

- **MiniCheck** (2404.10774, EMNLP 2024): introduce LLM-AggreFact e i dati sintetici C2D/D2C; Bespoke-MiniCheck-7B (77,4) è il miglior modello aperto della leaderboard.
- **FactCG** (2501.17144, NAACL 2025): dati multi-hop da grafi di contesto (CG2C); DeBERTa da 0,4B a 75,6.
- AlignScore, SummaC, HHEM, Granite Guardian, Lynx/HaluBench (2407.08488).

Questi modelli sono **addestrati per un solo compito**. I TDM sono generali e vanno adattati al compito solo con la domanda.

1.3 LLM come giudici e calibrazione

- LLM generici letti tramite le probabilità di "sì/no" in una passata (classificazione con label log-probability): idea vecchia, che i TDM rendono un prodotto.
- Lavori recenti sostengono che sui modelli proprietari post-2025 la confidenza verbalizzata sia più affidabile delle log-probabilità (2609.10996) e che la calibrazione vada trattata come criterio primario di valutazione (2609.26489). Sono temi che il nostro paper tocca direttamente: i TDM promettono probabilità calibrate per costruzione.

2. Il buco

Domanda	Coperta da qualcuno?
Quanto valgono i TDM (aperti e chiusi) come fact checker su documento, su un benchmark completo come LLM-AggreFact?	**No** (solo 240 casi HaluEval con Jev)

Domanda	Coperta da qualcuno?
Battono i checker specializzati di pari taglia? E un LLM generico letto allo stesso modo?	**No**
Le loro probabilità sono calibrate su questo compito? La soglia trasferisce fra domini?	**No** (calibrazione dei TDM studiata in generale, non sul grounding)
Scomporre la decisione in più domande tipizzate (supporto, dettaglio non stabilito, contraddizione) aiuta?	**No**
Sono robusti a formulazione della domanda, nomi dei campi, distrattori, rimozione dell'evidenza?	In parte per altri compiti (invarianza delle decisioni), non per il fact checking
Si possono specializzare con fine-tuning senza perdere le capacità generali?	**No**

3. Cosa rende il contributo difendibile

1. **Primo studio sistematico** dei TDM sul fact checking documento–claim, con modelli aperti e chiusi.
2. **Protocollo zero-shot pulito** su LLM-AggreFact (decisioni prese su dati nostri), quindi confrontabile con la leaderboard.
3. **Le baseline che un revisore chiederà**: checker specializzati e LLM generici con lo stesso prompt e la stessa lettura dei logit. Separano l'effetto dell'addestramento "da decision model" dall'effetto del semplice leggere le probabilità.
4. **Calibrazione e robustezza** misurate, non solo l'accuratezza.
5. **Metodo di specializzazione** con misura esplicita dell'oblio.
6. Rispetto della **checklist dell'audit** (§4): è un argomento forte in revisione, perché mostra che il lavoro segue gli standard del filone.

4. La checklist dell'audit (da rispettare)

ID	Requisito	Come lo copriamo
B1	baseline con log-probabilità delle etichette	LLM generici (Qwen3.5-9B, Gemma-4-12B, base dei TDM aperti) con lo stesso prompt
B2	cascate generative economiche	LLM piccolo che genera "Yes/No" (più eventuale ragionamento breve)
B3	modelli specifici del compito	MiniCheck, Bespoke-MiniCheck-7B, FactCG, AlignScore
T1	dispersione fra modelli	più TDM e più baseline; intervalli di confidenza
T2	invarianza delle decisioni	test comportamentali (formulazione, distrattori, posizione)
T3	scambio dei nomi delle opzioni	inversione e rinomina delle opzioni e dei campi
T4	provenienza dei dati	tabelle di provenienza e decontaminazione
R1	versioni e date esatte	revisioni dei pesi, versione di Jev, date delle chiamate
R2	intervalli di confidenza	bootstrap per documento
R3	scelte fatte dopo la valutazione	registro degli esperimenti; dichiarazione del controllo intermedio di Jev
C1	calibrazione su dati tenuti da parte	ECE e Brier su test fuori dominio
C2	accuratezza ad alta confidenza	copertura selettiva
C3	soglie congelate prima del test	protocollo dello Step 0
C4	latenza con e senza cache	misure su vLLM e sul server Winnow

5. Rischi per la novità

- **Scoop**: decine di paper sui TDM in un mese. Un lavoro sul fact checking può uscire in qualsiasi momento. Contromisura: preprint su arXiv della Parte A appena pronta, poi la versione completa.
- **"È solo una valutazione"**: per una conferenza principale serve qualcosa in più del benchmarking. La Parte B (metodo) e le analisi (calibrazione, scomposizione in domande, robustezza) rispondono a questa critica.
- **Modello chiuso (Jev)**: versioni che cambiano, prompt interno non noto. Va riportata la versione esatta, e le conclusioni principali vanno appoggiate ai modelli aperti.

Prima della sottomissione: rifare la ricerca bibliografica (arXiv, ACL Anthology, Semantic Scholar) con le chiavi "typed decision model", "System One", "Jev", "decision model fact", "LLM-AggreFact 2026".