Le opzioni di paper, a confronto

La domanda è: *creare un dataset nuovo e testarci i modelli? proporre un dataset? oppure altro?* Le opzioni realistiche sono cinque.

Opzione 1 — Solo valutazione ("benchmarking paper")

Cosa: valutare TDM aperti e chiusi sul fact checking documento–claim con benchmark esistenti (LLM-AggreFact + test fuori dominio), con calibrazione, robustezza e costi, contro checker specializzati e LLM generici.

Pro	Contro
Gran parte dei risultati c'è già (5 modelli su tutto il test di AggreFact)	i revisori delle conferenze principali tendono a considerarla un contributo debole se manca un'idea o un'analisi forte
Tempi brevi (4–6 settimane)	facile da superare: chiunque abbia accesso a Jev può fare qualcosa di simile
Costo basso (inferenza; Jev è costato ~2 $ per tutto)	

Adatta a: preprint rapido, workshop (FEVER, TrustNLP), Findings se l'analisi è profonda.

Opzione 2 — Valutazione + metodo di specializzazione (consigliata)

Cosa: l'Opzione 1, più il fine-tuning di Winnow-12B e JPT-9B con loss sulle lettere e replay, con la misura di quanto si perde sulle decisioni generali (oblio).

Pro	Contro
Contributo completo: "dove sono i TDM oggi" + "come migliorarli senza romperli"	più lavoro: codice di training, GPU (L40S), molte corse
Risponde a un buco esplicito dell'audit (fine-tuning dei modelli aperti, attribuzione dei guadagni)	rischio che il fine-tuning non batta i checker specializzati: il paper resta valido se l'analisi è onesta, ma è meno forte
Il controllo con i modelli base (stesso training su Gemma-4-12B e Qwen3.5-9B) dà un risultato scientifico netto, in un senso o nell'altro	

Adatta a: ACL / EMNLP (main o Findings).

Opzione 3 — Proporre un dataset nuovo

Cosa: costruire un benchmark nuovo di fact checking (documenti, claim, etichette umane) e valutarci i modelli.

Pro	Contro
Un buon dataset può avere molto impatto e molte citazioni	**costoso**: per ~2.000–5.000 esempi con doppia annotazione servono settimane di annotatori (o un budget di crowdsourcing qualificato) e un protocollo di accordo
Contributo chiaro e durevole	**i revisori sono severi**: chiedono motivazione del buco, guida di annotazione, accordo fra annotatori, analisi degli errori, datasheet, licenze, baseline forti
	il buco va dimostrato: LLM-AggreFact, HaluBench, HalluMix, RAGTruth, FaithBench coprono già molto
	allontana dalla domanda principale (i TDM)

Quando avrebbe senso: solo se c'è un buco che i dataset esistenti non coprono e che i TDM rendono importante. Due candidati:

- **etichette graduate o distribuzionali** (più annotatori per esempio, con probabilità di supporto): l'unico modo per valutare davvero la calibrazione, che è la promessa dei TDM;
- **domini o lingue non coperti** (es. documenti in italiano, documenti amministrativi o legali lunghi).

Adatta a: NeurIPS Datasets & Benchmarks, LREC-COLING, oppure come secondo paper dopo il primo.

Opzione 4 — Set diagnostico ricavato da test esistenti (contributo secondario consigliato)

Cosa: un insieme di test **controllati**, costruito trasformando esempi di test esistenti: coppie minime (si cambia un numero o un'entità nel claim), rimozione della frase di evidenza, distrattori aggiunti, evidenza spostata in un documento lungo, domande parafrasate, campi rinominati. Le trasformazioni sono automatiche (anche con LLM); un **campione viene validato a mano**.

Pro	Contro
Costa poco: niente annotazione da zero, solo validazione di un campione (es. 500 esempi, 2 annotatori, 2–3 giorni)	non è un "dataset nuovo" pieno: va presentato come risorsa diagnostica
Misura proprio le proprietà promesse dai TDM (sensibilità all'evidenza, invarianza, calibrazione)	va costruito solo da test (mai da dati di training) e con licenze compatibili
Riutilizzabile da tutta la comunità, anche per altri checker	

Dettagli: 05_set_diagnostico.md.

Opzione 5 — Due paper separati

1. **Subito**: Opzione 1 come preprint e poi workshop o Findings (fissa la priorità, dato che il campo corre).
2. **Dopo**: Opzione 2 (fine-tuning) + Opzione 4 (set diagnostico) per ACL o EMNLP 2027.

Pro	Contro
protegge dallo scoop	i due paper si sovrappongono: il secondo deve aggiungere molto per essere accettato
il primo esce in poche settimane	un preprint arXiv **non** impedisce la sottomissione a ACL/EMNLP; un paper già *accettato* a un workshop con atti sì, se il secondo è troppo simile: verificare le regole sulla doppia sottomissione

Tabella riassuntiva

Opzione	Novità	Costo	Tempo	Rischio di rifiuto (conferenza principale)	Venue tipica
1. Solo valutazione	media	basso	4–6 sett.	alto	workshop, Findings
2. Valutazione + metodo	alta	medio	3–4 mesi	medio	ACL/EMNLP main o Findings
3. Dataset nuovo	alta se il buco è reale	alto	4–6 mesi	medio-alto	D&B track, LREC
4. Set diagnostico	media (come aggiunta)	basso-medio	2–3 sett.	— (secondario)	dentro l'Opzione 2
5. Due paper	—	medio	preprint subito + 3–4 mesi	—	workshop + main

Raccomandazione

Opzione 2 con il set diagnostico dell'Opzione 4, più un preprint anticipato della sola parte di valutazione.

Motivi:

- usa il lavoro già fatto (cinque modelli valutati, infrastruttura, protocollo, dati di training pronti);
- risponde a tre buchi indicati dall'audit: fine-tuning dei modelli aperti, attribuzione dei guadagni (architettura/inizializzazione contro dati), stabilità della calibrazione fra domini;
- evita il costo e il rischio di un dataset nuovo, ma lascia una risorsa riutilizzabile (il set diagnostico);
- il preprint anticipato protegge dallo scoop.

Il dataset nuovo (Opzione 3) lo terrei come **secondo paper**, nella forma più distintiva: **etichette distribuzionali per la calibrazione** dei fact checker, eventualmente multilingue (inglese + italiano).

Una domanda da chiarire prima di partire

Contributo principale: "valutazione" o "metodo"? Il titolo, l'abstract e l'ordine delle sezioni cambiano molto:

- se il fine-tuning dà un guadagno netto (es. Winnow sopra 79 su AggreFact zero-shot, senza oblio), il paper è **di metodo**, con la valutazione come motivazione;
- se il guadagno è modesto, il paper è **di analisi** ("cosa sanno e non sanno fare i TDM come fact checker"), con il fine-tuning come uno degli esperimenti.

Conviene decidere dopo le prime corse del pilota (Fase 1 di ../fine_tuning/07_esperimenti.md), scrivendo intanto le sezioni comuni.