Parte A — Valutazione dei typed decision model come fact checker

1. Domande di ricerca

RQ	Domanda	Esperimento principale
RQ1	Quanto valgono i TDM (aperti e chiusi) come fact checker documento–claim, zero-shot, rispetto a checker specializzati e a LLM generici?	tabella principale su LLM-AggreFact + test fuori dominio
RQ2	Il vantaggio viene dall'addestramento "da decision model" o dal semplice leggere i logit di un LLM?	stesso prompt e stessa lettura su Gemma-4-12B e Qwen3.5-9B base (le basi di Winnow e JPT)
RQ3	Le probabilità sono calibrate? Una soglia scelta in un dominio trasferisce agli altri?	ECE/Brier; soglia dal nostro dev contro soglia dal dev di AggreFact
RQ4	Scomporre la decisione in più domande tipizzate aiuta?	una domanda contro la regola a tre domande `min(p1, 1−p2, 1−p3)`; contributo di ciascuna domanda
RQ5	I TDM guardano davvero il documento? Sono robusti a formulazione, nomi, distrattori?	set diagnostico (05)
RQ6	Qual è il compromesso qualità / costo / latenza?	token/s, costo per 1.000 claim, latenza con e senza cache del prefisso

2. Modelli

Gruppo	Modelli	Stato nella repo
TDM chiuso	Jev 1.13 (API)	valutato su tutto il test di AggreFact
TDM aperti	Winnow-12B (BF16, NVFP4; Q8_0 da aggiungere), JPT-9B, Rune-26B-A4B	valutati su tutto il test
TDM aperti da aggiungere	Laya (421M), Kev-9B / Kev-4B, djev-0.1	da fare (danno la dimensione: da 0,4B a 26B)
LLM generici, stessa lettura (B1)	Gemma-4-12B, Qwen3.5-9B (basi di Winnow e JPT); eventualmente Qwen3-8B, Gemma-4-31B	da fare
LLM generici, generazione (B2)	un LLM piccolo che risponde "Yes/No" generando; un LLM con breve ragionamento	da fare
Checker specializzati (B3)	FactCG-DeBERTa-L (fatto: 75,64), MiniCheck-Flan-T5-L, Bespoke-MiniCheck-7B (pesi già nella cache HF), AlignScore	in parte

Il confronto più informativo per RQ2 è **Winnow contro Gemma-4-12B** e **JPT contro Qwen3.5-9B**: stessa architettura, stesso prompt, stessa lettura dei logit. La differenza misura cosa ha aggiunto l'addestramento a decision model.

3. Dati

Blocco	Dataset	Uso
Sviluppo	`dev_select` / `dev_confirm` costruiti dalle nostre fonti (../fine_tuning/00b_split_e_protocollo.md)	soglia, temperatura, scelta delle domande
Test principale	**LLM-AggreFact test** (11 fonti, 29.320 righe), zero-shot	confronto con la leaderboard
Test fuori dominio	HaluBench (senza la parte RAGTruth, riportata a parte), HalluMix, SciFact, Climate-FEVER, HealthVer / COVID-Fact	generalizzazione
Test in distribuzione	test di FEVER, ANLI, VitaminC, HoVer, MiniCheck, SummEdits, AVeriTeC	riferimento per la Parte B
Diagnostico	05_set_diagnostico.md	RQ5

Per la Parte A da sola, il test in distribuzione è utile ma non indispensabile; i blocchi chiave sono AggreFact e fuori dominio.

4. Protocollo

1. **Prompt**: per ogni TDM il suo formato nativo (già riprodotto per Winnow, JPT, Rune nei benchmark della repo); per gli LLM generici lo stesso formato usato dal TDM corrispondente.
2. **Domande**: il pacchetto `packs/claim_support.json` (tre domande). Va dichiarato che è stato scelto, per Jev, sul dev di AggreFact. Per un'analisi pulita aggiungere anche una domanda "neutra" scritta prima di qualsiasi esperimento (es. la sola `support_simple`).
3. **Soglia e temperatura**: fittate su `dev_select`, confermate su `dev_confirm`, applicate a tutti i test. Come confronto secondario, la soglia fittata sul dev di AggreFact.
4. **Test**: una sola esecuzione per configurazione congelata.
5. **Jev**: riportare versione e date delle chiamate; dichiarare il controllo intermedio sul test fatto nel run originale (`results/INTERIM_AMENDMENT.md`). Rieseguire Jev con il protocollo zero-shot costa pochi dollari.
6. **Documenti lunghi**: stessa regola di troncamento per tutti i modelli (80.000 caratteri, 75% inizio e 25% fine); riportare quanti documenti sono stati troncati per modello e per fonte.

5. Metriche

- BAcc per fonte e media (LLM-AggreFact: media sulle 11 fonti, come la leaderboard); AUC.
- Brier, ECE (10 intervalli), diagrammi di affidabilità.
- Copertura selettiva: accuratezza contro percentuale di esempi coperti, al variare della confidenza.
- Stabilità: deviazione standard fra domande parafrasate.
- Costi: token di input, latenza per claim, throughput (con e senza cache del prefisso: le tre domande condividono il documento).
- Intervalli al 95% con bootstrap per documento; test appaiati fra modelli (bootstrap appaiato o test di permutazione).

6. Esperimenti e analisi

ID	Esperimento	Cosa mostra
A1	Tabella principale: tutti i modelli, AggreFact (11 fonti) + media fuori dominio	RQ1
A2	TDM contro la loro base generica, stessa lettura	RQ2: vale l'addestramento da decision model?
A3	Soglia dal nostro dev contro soglia dal dev di AggreFact; ECE per dominio	RQ3: trasferimento della calibrazione

ID	Esperimento	Cosa mostra
A4	Una domanda contro tre; ablazione di ciascuna domanda nella regola min; regola min contro media	RQ4
A5	Set diagnostico	RQ5
A6	Curva qualità–costo (BAcc contro costo per 1.000 claim)	RQ6
A7	Quantizzazione: Winnow BF16 / Q8_0 / NVFP4	effetto della compressione su accuratezza e calibrazione
A8	Analisi degli errori: 100 errori per modello, categorizzati (entità, numeri, attribuzione, multi-hop, etichetta dubbia)	dove sbagliano i TDM
A9	Accordo fra modelli: quanto gli errori dei TDM si sovrappongono a quelli dei checker specializzati	utile per ensemble e cascate

Spunto già visibile dai dati della repo per A2 e A8: Winnow è forte sui riassunti di notizie (CNN 72,1 alla soglia 0,30) e più debole su WiCE (77,4), JPT il contrario (CNN 62,3, WiCE 83,8). Profili di errore diversi a parità di media: argomento interessante per l'analisi.

7. Tabelle e figure previste

N.	Contenuto
Tab. 1	Modelli: tipo, parametri, licenza, formato, costo
Tab. 2	LLM-AggreFact zero-shot per fonte, tutti i modelli (formato leaderboard)
Tab. 3	Fuori dominio + media dei blocchi
Tab. 4	TDM contro la base generica (RQ2)
Tab. 5	Ablazione delle domande (RQ4)
Tab. 6	Set diagnostico (RQ5)
Fig. 1	Diagrammi di affidabilità (RQ3)
Fig. 2	Qualità contro costo (RQ6)
Fig. 3	Copertura selettiva
Fig. 4	Delta soglia trasferita contro soglia in dominio, per fonte

8. Lavoro e costi stimati

Voce	Stima
Split, dev e test fuori dominio	1 settimana (codice)
Inferenza dei modelli aperti su dev + test fuori dominio + diagnostico	~1–2 giorni su L40S
Nuovi modelli (Laya, Kev, basi generiche, Bespoke, MiniCheck) su AggreFact	~2–3 giorni su L40S
Jev con il protocollo zero-shot	pochi dollari
Analisi degli errori	2–3 giorni
Scrittura	2 settimane
Totale Parte A	**~4–6 settimane**