Parte B — Specializzare i decision model senza romperli

Il piano tecnico completo è in ../fine_tuning/. Qui c'è solo ciò che serve **per il paper**: l'ipotesi, gli esperimenti indispensabili e come presentarli.

1. L'ipotesi

> Un typed decision model si può specializzare sul fact checking documento–claim con un fine-tuning leggero (LoRA) che ottimizza **solo la decisione che si legge in inferenza** (il softmax sui logit delle lettere delle opzioni), più un **replay con target del modello di partenza**. Si ottiene un guadagno netto sul fact checking, zero-shot fuori dominio, mantenendo calibrazione e capacità di decisione generali.

2. Contributi tecnici (cosa c'è di nuovo)

1. **Loss sulle lettere** al posto dell'SFT classico: si ottimizza solo il softmax ristretto alle opzioni nella posizione della risposta. Mostrare con dati che l'SFT classico peggiora la calibrazione (ECE) a parità di accuratezza.
2. **Replay per self-distillation** per un modello i cui dati originali non sono pubblici: domande tipizzate generiche, con target uguali alle probabilità del modello congelato (KL). Misurare l'oblio su JevBench, Kev e typed-decisions.
3. **Dati solo testo contro testo, con negativi difficili**: fonti pubbliche + negativi generati per cancellazione dell'evidenza e modifica minima del claim, con etichette derivate dall'operazione e verificate da un secondo modello.
4. **Robustezza del formato**: varianti automatiche di domanda e nomi dei campi, per non trasformare il TDM in un classificatore a una sola stringa.

Nessuno di questi elementi da solo è radicalmente nuovo. La novità è **combinarli per una classe di modelli nuova (i TDM)** e **misurare il compromesso specializzazione / oblio / calibrazione**, che l'audit del filone indica come problema aperto.

3. Esperimenti indispensabili per il paper

ID	Esperimento	Perché un revisore lo chiederà
B-main	Winnow-FT e JPT-FT contro la baseline, su AggreFact zero-shot + fuori dominio + in distribuzione	il risultato principale
B-ctrl	**Stesso training su Gemma-4-12B e Qwen3.5-9B base**	separa il contributo dell'inizializzazione da decision model da quello dei dati
B-loss	Loss sulle lettere contro SFT classico; CE contro Brier	giustifica la scelta della loss
B-replay	Con e senza replay; quota di replay (0 / 10 / 20%)	misura l'oblio evitato
B-data	Leave-one-source-out (o almeno: solo MiniCheck+ANLI, + negativi generati, mix completo)	quali dati contano
B-var	Con e senza varianti di domanda	robustezza al wording
B-seed	3 seed per la configurazione finale	varianza
B-ext	Bespoke-MiniCheck-7B e FactCG con la stessa suite	confronto con lo stato dell'arte aperto

Facoltativi (se c'è tempo): loss contrastiva su coppie minime; S3 (tre domande) contro S1; rank LoRA; 8k contro 4k token.

4. Possibili esiti e come raccontarli

Esito	Lettura	Come impostare il paper
FT del TDM $\gg$ baseline e $\gg$ FT della base generica, oblio contenuto	l'inizializzazione da decision model aiuta	paper di **metodo**: "Specializing typed decision models for grounded fact checking"
FT del TDM $\approx$ FT della base generica	il valore è nei dati; il TDM non dà vantaggio di partenza	paper di **analisi**: risultato onesto e utile ("decision training does not transfer to grounding")
FT migliora AggreFact ma peggiora fuori dominio	sovra-specializzazione	analisi delle fonti di dati (B-data); paper di analisi
Oblio forte anche con replay	compromesso reale	curva specializzazione contro oblio come risultato centrale

Tutti gli esiti sono pubblicabili **se** il protocollo è pulito e i controlli ci sono. Il rischio vero è un paper senza B-ctrl o senza oblio misurato.

5. Calcolo e tempi (stime)

Voce	Stima
Codice (render, train, merge, valutatori)	2–3 settimane
Generazione di replay, varianti, negativi difficili (modello locale o API)	1 settimana
Corse su JPT (pilota + ablazioni, ~10 corse)	2–3 settimane su portatile o L40S
Corse su Winnow (~5 corse) + controlli sulle basi (2 corse)	2 settimane su L40S
Valutazione completa ed export	1 settimana
Totale Parte B	**~2–2,5 mesi** in parallelo con la scrittura

6. Cosa rilasciare

- Adapter LoRA (o pesi fusi) di Winnow-FT (licenza da verificare in base ai dati, vedi ../fine_tuning/08_merge_export.md) e JPT-FT (non commerciale).
- Codice di training e valutazione.
- Ricette dei dati (script, non i dati di terze parti, se le licenze non lo consentono) e set diagnostico.
- Cache delle previsioni sui test, come già fatto per Jev in questa repo: permettono di ricalcolare le metriche senza nuova inferenza.