Il set diagnostico (contributo secondario)

1. Perché un set diagnostico e non un dataset nuovo

Un benchmark come LLM-AggreFact dice **quanto** un modello sbaglia, non **perché**. I typed decision model promettono proprietà precise: leggono il documento, rispondono in modo stabile alla stessa domanda posta in modi diversi, danno probabilità calibrate. Un set diagnostico misura esattamente queste proprietà, con esempi costruiti in modo controllato. Costa una frazione di un dataset nuovo, perché parte da esempi già etichettati.

2. Da dove si parte

Solo da **test** di dataset con licenza compatibile e mai usati in training:

- test in distribuzione delle nostre fonti (FEVER `paper_test`, HoVer, VitaminC test, MiniCheck e SummEdits nella parte di test);
- fonti fuori dominio (SciFact, Climate-FEVER, HealthVer).

Non da LLM-AggreFact: la sua licenza permette la valutazione, ma derivare e ridistribuire un nuovo dataset dalle sue parti va verificato fonte per fonte. Se si vuole includerlo, distribuire solo gli script di trasformazione, non i testi.

3. Le famiglie di test

Famiglia	Trasformazione	Etichetta attesa	Costruzione	Validazione umana
Rimozione dell'evidenza	si cancellano dal documento le frasi gold che supportano il claim	da 1 a 0 (non stabilito)	automatica dove l'evidenza è annotata (FEVER, HoVer); con LLM altrove	sì: il documento non deve più supportare il claim, né contraddirlo
Coppia minima sul claim	si cambia un numero, una data, un'entità o un'attribuzione	da 1 a 0 (contraddetto)	LLM (`contradict_claim`) + verifica automatica	sì
Coppia minima sul documento	si cambia nel documento il valore che il claim cita	da 1 a 0	VitaminC (già contrastivo) + LLM	a campione
Distrattori	paragrafi irrilevanti (da altri documenti dello stesso dominio) prima e dopo	invariata	automatica	no (l'etichetta non cambia per costruzione)
Posizione dell'evidenza	la frase di supporto messa all'inizio, a metà o alla fine di un documento lungo	invariata	automatica	no
Solo claim	documento vuoto o non pertinente	0	automatica	no
Formulazione della domanda	10 parafrasi mai viste in training	invariata	LLM + filtro	a campione
Campi rinominati	`document/claim` → `passage/assertion`, `context/answer`, ...	invariata	automatica	no
Paraphrase del claim	stesso contenuto, parole diverse	invariata	LLM + verifica	sì

Esempio di coppia minima sul claim:

Documento: "Okeh Records is a subsidiary of Sony Music Entertainment and was founded by Otto Heinemann." Claim originale (1): "Okeh Records was founded by Otto Heinemann." Claim modificato (0): "Okeh Records was founded by **Thomas Edison**."

4. Validazione umana

- **Campione**: ~500 esempi delle famiglie in cui l'etichetta cambia (rimozione, coppie minime, parafrasi del claim).
- **Annotatori**: 2, indipendenti, con una guida di una pagina ("il documento supporta ogni parte del claim? sì / no / incerto").
- **Accordo**: kappa di Cohen fra annotatori e accuratezza delle etichette automatiche contro il giudizio umano. Obiettivo: $\geq 95\%$ di etichette automatiche confermate; le famiglie sotto il 90% vanno riviste o tolte.
- **Tempo**: ~500 esempi × ~40 secondi × 2 persone $\approx$ 11 ore di annotazione in totale.

5. Metriche del set

Proprietà	Metrica
Sensibilità all'evidenza	% di esempi in cui la decisione si inverte correttamente (rimozione, coppie minime)
Invarianza	% di decisioni invariate (distrattori, posizione, formulazione, campi, parafrasi del claim)
Dipendenza dal solo claim	P(supportato) media con documento vuoto
Calibrazione sotto perturbazione	variazione dell'ECE fra originale e perturbato

Un modello ideale ha sensibilità 100% e invarianza 100%. I due numeri insieme sono più informativi della sola accuratezza: un modello che dice sempre "no" ha invarianza alta ma sensibilità nulla.

6. Dimensione e formato

- ~300–1.000 esempi per famiglia, ~5.000–8.000 in tutto.
- Formato: JSONL con `id`, `family`, `parent_id`, `document`, `claim`, `label`, `expected_change` ("flip" / "invariant"), `source`, `license`, `validated` (true/false).
- Rilascio: dati derivati da fonti con licenza compatibile (CC BY / CC BY-SA / MIT; per le NC, solo uso non commerciale e dichiarato) + script per rigenerare il resto.

7. Documentazione richiesta dai revisori

Una scheda tipo *datasheet*: motivazione, composizione, processo di raccolta, trasformazioni, validazione, accordo, usi previsti e non previsti, licenze, contatti. Va in appendice del paper e nel repository del set.