Benchmark e modelli: cosa usano i paper del settore e cosa usare noi

Integra 03_parte_A_valutazione.md. Valutare solo su LLM-AggreFact sarebbe un punto debole: i paper di riferimento usano **più benchmark**, e i revisori se lo aspettano. Anche i modelli vanno ampliati: oggi la repo ne ha cinque.

1. Su cosa si valutano i paper di fact checking su documento

Paper / modello	Benchmark usati	Metrica	Fonte
TRUE (Honovich et al., NAACL 2022)	introduce TRUE: 11 dataset (FRANK, SummEval, MNBM, QAGS-CNNDM, QAGS-XSum, BEGIN, Q^2, DialFact, PAWS, FEVER, VitaminC) su riassunti, dialogo, parafrasi, verifica di claim	ROC-AUC	2204.04991
AlignScore (ACL 2023)	TRUE (11) + SummaC benchmark (6) + altri 6 dataset: 22 in tutto, 19 mai visti in training	AUC, BAcc, correlazioni	2305.16739
MiniCheck (EMNLP 2024)	LLM-AggreFact (introdotto lì)	BAcc media per fonte	2404.10774
FactCG (NAACL 2025)	LLM-AggreFact (+ analisi sul ragionamento multi-hop)	BAcc	2501.17144
Granite Guardian (IBM)	TRUE (AUC media 0,854 per la versione 3.0-8B) + benchmark di rischio	AUC	2412.07724
Lynx (Patronus)	HaluBench (introdotto lì): DROP, CovidQA, PubMedQA, FinanceBench, HaluEval, RAGTruth	accuratezza	2407.08488
LettuceDetect	RAGTruth (livello di risposta e di span)	F1	2502.17125
HalluGuard (Findings ACL 2026)	LLM-AggreFact intero (75,7) + focus su RAGTruth (84,0)	BAcc	2510.00880
FaithBench (NAACL 2025)	introduce FaithBench: allucinazioni di 10 LLM moderni nei riassunti, annotate da esperti; i rilevatori migliori sono vicini al 50%	BAcc, F1	2410.13210
JEV-as-a-Judge (TDM, 2026)	240 casi di HaluEval con evidenza (fra altri compiti non di fact checking)	accuratezza	2609.26550

La prassi: almeno **un benchmark aggregato** (LLM-AggreFact oppure TRUE/SummaC), più **un benchmark RAG** (RAGTruth o HaluBench), e nei lavori recenti **un benchmark difficile e moderno** (FaithBench). I lavori più solidi (AlignScore) dichiarano quanti dataset non sono mai stati visti in training.

2. La suite proposta

Livello 1 — indispensabile

Benchmark	Cosa copre	Dimensione	Metrica principale	Note
LLM-AggreFact (11 fonti)	riassunti, dialoghi, RAG, claim di LLM	29.320	BAcc media per fonte (come la leaderboard) + AUC	già valutato per 5 modelli
TRUE (11 dataset)	riassunti, dialogo, parafrasi, verifica di claim	~100.000 coppie (dominate da VitaminC e FEVER)	**ROC-AUC** per dataset (come nel paper originale e in AlignScore/Granite Guardian) + BAcc	campionare i dataset più grandi (es. massimo 5.000 per dataset) per contenere i costi
HaluBench (6 fonti)	QA con contesto: finanza, medicina, DROP	~15.000	accuratezza e BAcc per fonte	la parte RAGTruth si riporta a parte (è anche in LLM-AggreFact)
RAGTruth (test, livello di risposta)	risposte di LLM in RAG: QA, data-to-text, riassunti	~2.700 risposte (da verificare)	BAcc, F1	confronto diretto con LettuceDetect e HalluGuard
FaithBench	allucinazioni difficili di LLM moderni nei riassunti	~800 (da verificare)	BAcc	il più duro: i rilevatori attuali sono vicini al 50%

Livello 2 — consigliato

Benchmark	Perché
SummaC benchmark (6 dataset di riassunti)	standard storico; utile per il confronto con AlignScore e SummaC
HalluMix	multi-documento, documenti lunghi, più domini
Verifica di claim fuori dominio: SciFact, Climate-FEVER, HealthVer / COVID-Fact	domini scientifico, clima, salute; claim reali; evidenza data
LLM-Oasis (test annotato a mano)	testi di Wikipedia, se disponibile la variante con evidenza

Livello 3 — facoltativo

Benchmark	Perché
ContextualJudgeBench	giudizi contestuali, se si vuole parlare di LLM-as-judge
Benchmark multilingue (es. SEAHORSE per i riassunti)	solo se si vuole una sezione multilingue (Laya è multilingue)
FACTS Grounding	**non adatto così com'è**: valuta la generazione di risposte giudicata da LLM, non fornisce coppie (documento, claim) etichettate da persone

Sempre presenti

- **Set diagnostico** (05_set_diagnostico.md).
- **Oblio** (solo per la Parte B): JevBench pubblico, Kev-v9 clean, typed-decisions test.

3. Attenzione alle sovrapposizioni fra benchmark (e con il training)

Sovrapposizione	Problema	Come gestirla
TRUE, SummaC e LLM-AggreFact condividono dataset di riassunti (FRANK, SummEval, QAGS, XSumFaith compaiono in più aggregati)	la stessa coppia contata due volte, risultati correlati	deduplicare per documento + claim; riportare ogni aggregato da solo, non sommarli
RAGTruth è in LLM-AggreFact e in HaluBench	idem	blocco RAGTruth riportato una sola volta
TRUE contiene **FEVER e VitaminC**, che sono nel nostro training (Parte B)	per i modelli fine-tunati, quei due dataset diventano "in distribuzione"	per la Parte B riportare TRUE anche **senza FEVER e VitaminC** (TRUE-9); dichiararlo
HaluBench contiene HaluEval, già usato in JEV-as-a-Judge	—	non è un problema, ma va citato

Regola generale: nella tabella principale dichiarare per ogni benchmark se è **mai visto** in training, come fa AlignScore.

4. I modelli

4.1 Typed decision model / System One

Modello	Architettura	Accesso	Note
Jev 1.13 (TypeSafe)	chiuso	API (~0,042 $ per milione di token di input)	riferimento; già valutato
OpenAI Decisions API (`gpt-6-luna`)	chiuso	**preview limitata**; 0,10 $ per milione di token di input, output gratis	se si ottiene l'accesso, è il secondo TDM chiuso: confronto molto interessante
Winnow-12B	autoregressivo (Gemma-4-12B fine-tunato), GGUF	aperto, Apache 2.0	già valutato (BF16, NVFP4); aggiungere Q8_0
JPT-9B	autoregressivo (Qwen3.5-9B + LoRA)	aperto, CC BY-NC	già valutato
Rune-26B-A4B	autoregressivo MoE (Gemma-4)	aperto	già valutato
Kev-9B / Kev-4B (e taglie minori)	LoRA + "pointer head" su Qwen3.5	aperto, server compatibile System One	da fare; varie taglie → curva di scala
Laya (395M)	**encoder** (ModernBERT-large) + testa di decisione, non autoregressivo, multilingue	aperto	da fare; il più piccolo e veloce
djev-0.1	**diffusione** (DiffusionGemma 26B-A4B)	aperto	da fare
CLM-v0.1-8B (Stanford / NVIDIA)	**contrastivo**: encoder Qwen3-8B congelato + teste di stato e azione (InfoNCE)	aperto; server con schema System One	runner già pronto nella repo (`evaluate.py`), mai eseguito

Sono **nove TDM con quattro architetture diverse** (autoregressivo, encoder, diffusione, contrastivo) e taglie da 0,4B a 26B. È un asse di analisi a sé: *quale tipo di decision model funziona come fact checker?*

4.2 Checker specializzati

Modello	Taglia	Perché
MiniCheck-RoBERTa-L, MiniCheck-DeBERTa-L, MiniCheck-Flan-T5-L	0,4–0,8B	riferimento di LLM-AggreFact
Bespoke-MiniCheck-7B	7B	miglior aperto della leaderboard (77,4); pesi già nella cache HF di questa macchina
FactCG-DeBERTa-L	0,4B	già valutato (75,64)
AlignScore-large	0,4B	riferimento per TRUE e SummaC
HHEM-2.1-open (Vectara)	0,1B	molto usato in produzione
Granite Guardian 3.3	8B	forte su TRUE e AggreFact (76,5)
Lynx-8B (70B facoltativo)	8B / 70B	riferimento di HaluBench
HalluGuard-4B	4B	recente (2026), 75,7 su LLM-AggreFact
SummaC-ZS	0,1B	baseline storica (facoltativa)

4.3 LLM generici letti come un TDM (baseline B1 della checklist)

Stesso prompt del TDM corrispondente, si leggono i logit delle lettere, una passata:

Modello	Perché
Gemma-4-12B	base di Winnow → confronto diretto
Qwen3.5-9B	base di JPT e di Kev-9B → confronto diretto
Qwen3-8B	base di CLM
Gemma-4-26B-A4B	base di Rune (e affine a djev)
Una scala della stessa famiglia (es. Qwen3.5 piccoli → 9B, o Gemma-4 → 31B)	effetto della taglia a parità di metodo

4.4 LLM generici che generano (baseline B2, giudici)

Gruppo	Modelli	Come
Aperti	gpt-oss-20b, gpt-oss-120b, Qwen3-30B-A3B, Gemma-4-31B, Mistral-Small-3.2-24B, DeepSeek-V4.1-Flash	risposta "Yes/No" generata; con e senza ragionamento
Chiusi	un modello di punta e uno economico per fornitore: famiglia GPT-5.x/6 (OpenAI), Claude Sonnet 5.5 e Haiku 4.5 (Anthropic), Gemini 3.x Pro e Flash (Google)	**su un sottoinsieme** (es. 200 righe per fonte) per contenere i costi

Per i modelli più vecchi (GPT-4o, Claude 3.5 Sonnet, Llama-3.1-70B, ...) si citano i numeri della leaderboard di LLM-AggreFact invece di rifarli.

5. Selezione consigliata

Versione minima (paper solido, ~20 modelli)

Gruppo	Modelli
TDM (8)	Jev, Winnow-12B, JPT-9B, Rune-26B, Kev-9B, Laya, djev-0.1, CLM-8B (+ OpenAI Decisions se accessibile)

Gruppo	Modelli
Specializzati (6)	Bespoke-MiniCheck-7B, MiniCheck-Flan-T5-L, FactCG-DeBERTa-L, AlignScore-L, Granite Guardian 3.3, Lynx-8B
LLM letti come TDM (2)	Gemma-4-12B, Qwen3.5-9B
LLM generativi (4)	gpt-oss-20b, Qwen3-30B-A3B, un chiuso di punta, un chiuso economico

Benchmark: livello 1 completo, più i tre di verifica di claim fuori dominio.

Versione estesa (se c'è tempo)

Aggiungere: Kev-4B e taglie minori (curva di scala), HHEM, HalluGuard-4B, Lynx-70B, Qwen3-8B e Gemma-4-26B letti come TDM, gpt-oss-120b, Gemma-4-31B, DeepSeek-V4.1-Flash; livello 2 completo.

6. Costi stimati (da verificare)

Voce	Stima
Coppie della suite di livello 1 (TRUE campionato a 5.000 per dataset)	~90.000 coppie
Modello aperto da ~9–12B, tre domande per coppia, su L40S	~4–6 ore per modello (riferimento: Winnow NVFP4 ~4,3 coppie/s sul portatile)
15 modelli aperti	~60–90 ore GPU
Modelli piccoli (Laya, DeBERTa, RoBERTa, T5)	minuti o poche ore
Jev su tutta la suite	pochi dollari (l'intero test di LLM-AggreFact è costato ~1,5 $)
LLM chiusi su un sottoinsieme (~5.000 coppie)	da qualche decina a qualche centinaio di dollari secondo il modello; usare l'API batch

7. Cosa cambia nel paper

- La **tabella principale** diventa: modelli × {LLM-AggreFact, TRUE, HaluBench, RAGTruth, FaithBench, verifica di claim fuori dominio}, più la media.
- Nuova analisi: **architettura del TDM** (autoregressivo, encoder, diffusione, contrastivo) contro qualità e costo.
- Nuova analisi: **taglia** (Kev da piccolo a 9B, Laya 0,4B, Rune 26B).
- RQ2 (TDM contro la base generica) si fa su quattro coppie: Winnow/Gemma-4-12B, JPT e Kev/Qwen3.5-9B, CLM/Qwen3-8B, Rune/Gemma-4-26B.

Fonti

- TRUE: https://arxiv.org/abs/2204.04991 · AlignScore: https://arxiv.org/abs/2305.16739 · MiniCheck: https://arxiv.org/abs/2404.10774 · FactCG: https://arxiv.org/abs/2501.17144
- Granite Guardian: https://arxiv.org/abs/2412.07724 · Lynx / HaluBench: https://arxiv.org/abs/2407.08488 · LettuceDetect: https://arxiv.org/abs/2502.17125 · HalluGuard: https://arxiv.org/abs/2510.00880 · FaithBench: https://arxiv.org/abs/2410.13210
- TDM: Laya https://huggingface.co/convaiinnovations/laya · Kev https://github.com/jaredpalmer/kev · djev https://github.com/Davipar/djev-dev · CLM https://huggingface.co/Contrastive-LM/CLM-v0.1-8B · OpenAI Decisions API https://www.firecrawl.dev/blog/openai-decisions-api-vs-jev