# Idea di paper

Decision model tipizzati per il fact checking documento–claim

26 ottobre 2026 (rivista)

## Indice


**Idea di paper: decision model tipizzati per il fact checking documento–claim** **2**
La risposta breve . . . 2
I file . . . 3
Cosa abbiamo già (e cosa manca) . . . 4

**Stato dell'arte e novità** **4**
1. Quattro filoni che si incontrano . . . 4
2. Il buco, rivisto . . . 7
3. Cosa rende il contributo difendibile oggi . . . 7
4. La checklist dell'audit (da rispettare) . . . 7
5. Rischi per la novità . . . 8
6. Chiavi per la ricerca settimanale . . . 9

**Le opzioni di paper, a confronto** **9**
Opzione 1 — Benchmarking ampio ("tutti i TDM su AggreFact") . . . 9
Opzione 2 — Paper di analisi con domande scientifiche nette (**consigliata ora**) . . . 9
Opzione 3 — Valutazione + metodo di specializzazione (era la consigliata) . . . 10
Opzione 4 — Set diagnostico ricavato da test esistenti . . . 10
Opzione 5 — Proporre un dataset nuovo . . . 10
Tabella riassuntiva . . . 10
Raccomandazione . . . 11
Cosa decidere subito . . . 11

**Parte A — Il paper di analisi: cosa aggiungono i decision model al fact checking su documento** **11**
1. Domande di ricerca . . . 11
2. Indizi già visibili nei nostri dati . . . 12
3. Modelli . . . 13
4. Dati . . . 14
5. Protocollo . . . 14
6. Metriche . . . 15
7. Esperimenti e analisi . . . 15
8. Tabelle e figure previste . . . 16
9. Lavoro e costi stimati . . . 16

**Parte B — Fine-tuning: un esperimento nel primo paper, il metodo nel secondo** **17**
1. Cosa è cambiato . . . 17
2. Nel primo paper: B-ctrl . . . 17
3. Nel secondo paper: il metodo completo . . . 18
4. Cosa rilasciare . . . 19

**Il set diagnostico** **19**
1. Perché un set diagnostico e non un dataset nuovo . . . 19

2. Da dove si parte . . . 19
3. Le famiglie di test . . . 19
4. Validazione umana (versione completa) . . . 21
5. Metriche del set . . . 21
6. Dimensione e formato . . . 21
7. Documentazione richiesta dai revisori . . . 22

**Venue, calendario, rigore e rischi** **22**
1. Dove sottomettere . . . 22
2. Calendario a ritroso (obiettivo: ARR 4 gennaio 2027) . . . 23
3. Checklist di rigore (da completare prima della sottomissione) . . . 23
4. Rischi e contromisure . . . 24
5. Etica e limitazioni (bozza) . . . 25

**Scheletro del paper** **25**
1. Titoli possibili . . . 25
2. Abstract di prova (numeri da riempire) . . . 25
3. Sezioni (~8 pagine) . . . 25
4. Contributi (da scrivere nell'introduzione) . . . 27
5. Figure chiave . . . 27
6. Le obiezioni prevedibili dei revisori, e la risposta pronta . . . 27
7. Prossimi passi concreti . . . 27

**Benchmark e modelli: cosa usano i lavori del settore e cosa usare noi** **28**
1. Su cosa si valutano i lavori di fact checking su documento . . . 28
2. La suite proposta . . . 28
3. Attenzione alle sovrapposizioni (fra benchmark, con il training, con la Decision Index) . . . 30
4. I modelli . . . 30
5. Selezione consigliata . . . 32
6. Costi stimati . . . 32
Fonti . . . 33

**Aggiornamento del 26 ottobre 2026: cosa è uscito e cosa cambia** **33**
1. I cambiamenti che toccano direttamente il paper . . . 33
2. Nuovi TDM rilevanti per noi . . . 35
3. Altri lavori da citare . . . 35
4. Cosa non ho trovato (e va ricontrollato ogni settimana) . . . 36
5. Incertezze di questa ricerca . . . 36

# Idea di paper: decision model tipizzati per il fact checking documento–claim

Cartella di lavoro per decidere **che paper scrivere**, **con quali esperimenti** e **dove sottometterlo**. Prima versione: 8 ottobre 2026. **Rivista il 26 ottobre 2026** dopo una nuova ricerca bibliografica: in diciotto giorni il campo è cambiato molto, e alcune affermazioni della prima versione non reggono più. Il dettaglio di cosa è cambiato, con le fonti, è in 09_aggiornamento_ottobre_2026.md.

## La risposta breve

1. **"Primo studio dei TDM come fact checker" non è più vero.** Jev è già stato valutato su **tutto il test di LLM-AggreFact** (78,6 zero-shot, una domanda, soglia 0,5, ECE 0,128: 2609.37647) e su 495 claim di AggreFact contro un LLM di frontiera, con cascate (2610.20634). Quattro TDM sono stati usati come verificatori di premesse estratte da revisioni scientifiche (PremiseCheck, 2610.21046). Otto TDM sono stati confrontati su RAGTruth, con un test sulla formulazione della domanda (Arize). Sulla **leaderboard di LLM-AggreFact** i primi posti sono ora di decision model (nimble-v4-max 79,5, Clef 79,0, Decider v1.2 78,7, Jev 1.13 78,7, d1-ultra 78,5), inviati dai produttori con un protocollo non documentato.

2. **Anche il metodo della Parte B è in gran parte pubblicato in forma generale.** Fine-tuning LoRA sulle lettere delle opzioni con ancoraggio KL (LLM-as-Jev, 2610.02076), effetti del fine-tuning sulla calibrazione e nessuna perdita sulle conoscenze generali (Releasing the Inner Jev, 2610.17205), coppie contrastive con certificato di rimozione dell'evidenza (PACT, 2609.35865). E le letture **senza training** di un LLM qualsiasi (AnyJev, LLM-as-Jev) arrivano vicino ai TDM: l'audit del filone (2609.32160) conclude che la lettura tipizzata "non ha mostrato un vantaggio di accuratezza indipendente" rispetto alla lettura delle probabilità delle etichette.

3. **Il buco che resta è preciso, ed è quello dove questa repo è forte:**

   - nessuno ha valutato **i TDM aperti** (oggi ~15 nella repo, da 3B a 27B, cinque architetture di lettura) **con un unico protocollo controllato** sul grounding; le voci della leaderboard non dicono domanda, soglia, chunking;
   - nessuno ha sfruttato l'**esperimento naturale "stessa base, ricette diverse"**: almeno sei TDM su Qwen3.5-9B (elephant-1, Nimble-9B, JPT-9B, d3-flash, StartLux-9B, Kev-9B), due su Qwen3.8-27B (Clef, Nimble-v4-max), uno su Gemma-4-12B (Winnow), uno su Qwen3.5-4B (KnowLine). Confrontati con la loro base letta in modo ingenuo **e** con una lettura calibrata senza training, rispondono alla domanda aperta dell'audit **sul compito dove conta di più**;
   - nessuno ha misurato **quanto della classifica dipende dal protocollo** (soglia, formulazione e polarità della domanda, una o tre domande, composizione della richiesta, troncamento, contaminazione). Dai nostri dati, le scelte di protocollo spostano un modello di 1,5–3,6 punti, più della distanza fra i primi cinque della leaderboard (1 punto).

4. **Il paper consigliato cambia di conseguenza**: un **paper di analisi** (Parte A riorientata), con un solo esperimento di fine-tuning, quello che nessuno ha fatto e che costa poco: *a parità di dati di grounding, partire da un TDM è meglio che partire dalla sua base?* Il metodo completo (Parte B) e il set diagnostico completo diventano il secondo paper.

5. **Scadenza**: ACL 2027 (Kyoto, 17–22 agosto 2027), sottomissione ARR entro il **4 gennaio 2027** (data ufficiale, ora confermata): mancano circa 10 settimane. Il rischio di essere anticipati è alto: **preprint su arXiv entro fine novembre**.

## I file

| File | Contenuto |
|---|---|
| 01_stato_arte_e_novita.md | Cosa esiste oggi (TDM, lavori su TDM e grounding, checker specializzati, letture senza training), dove resta il buco |
| 02_opzioni_di_paper.md | Le alternative riviste, con pro, contro, costi e la nuova raccomandazione |
| 03_parte_A_valutazione.md | Domande di ricerca, modelli, baseline, dati, metriche, esperimenti del paper di analisi |
| 04_parte_B_finetuning.md | L'esperimento di fine-tuning del primo paper (B-ctrl) e il metodo completo per il secondo |
| 05_set_diagnostico.md | Il set diagnostico: versione ridotta per il primo paper, versione completa per il secondo |
| 06_venue_calendario_rischi.md | Conferenze, calendario a ritroso fino al 4 gennaio, checklist di rigore, rischi |
| 07_scheletro_paper.md | Titoli, abstract di prova, sezioni, figure, obiezioni dei revisori |
| 08_benchmark_e_modelli.md | La suite di benchmark e i modelli, aggiornati ai rilasci di ottobre |
| 09_aggiornamento_ottobre_2026.md | Registro della ricerca del 26 ottobre: cosa è uscito, cosa cambia per noi, fonti |

### Cosa abbiamo già (e cosa manca)

Numeri dal test di LLM-AggreFact (29.320 righe), regola a tre domande e soglia 0,30 fisse (quelle di Jev), media per fonte; da `table.md` e dai run locali in `results/`.

| Elemento | Stato |
|---|---|
| Jev-1.13 su tutto il test (79,09, dev-tuned) | fatto, con due limiti da dichiarare: domande e soglia scelte sul dev di AggreFact, e un controllo intermedio sul test (../../legacy/results/INTERIM_AMENDMENT.md) |
| TDM aperti su tutto il test, con cache di probabilità (e logit dove esistono) | fatto: Winnow-12B BF16 76,95, NVFP4 77,49, elephant-1 76,70, Rune-26B 76,24, JPT-9B 76,04, KnowLine-4B 75,65, d1-3B 71,84, CLM-8B 49,98 (la regola a tre domande non funziona per CLM: vedi `models/clm-8b/README.md`) |
| TDM aperti con adapter pronto, run completo da fare | d3-flash, d3-turbo (serve una GPU da 56 GiB+), StartLux-9B-Instant, StartLux-27B-AutoThink, Nimble-9B-v3 |
| TDM da aggiungere (usciti dopo l'8 ottobre) | Clef 27B (già nella cache HF), Nimble-v4 9B / v4-max 27B, pplx-decider v1.2 / flash, Drex v1.5, Kev-9B/27B; Jev 1.14 |
| Checker specializzati | FactCG 75,64 (fatto); Bespoke-MiniCheck-7B (adapter fatto, solo 32 righe) |
| Grid search su regola, temperatura e soglia, senza inferenza | fatto (`grid_search.py`): base dell'analisi di sensibilità al protocollo |
| Split nostri train/dev/test e test fuori dominio | da fare (../fine_tuning_factcheck/00b_split_e_protocollo.md); molti dataset sono già nella cache HF |
| Basi generiche lette allo stesso modo (ingenua e calibrata senza training) | da fare: è il cuore del paper (RQ2) |
| Calibrazione, robustezza, costi misurati in modo sistematico | latenza, throughput, memoria ed energia già misurati dal benchmark; calibrazione e robustezza da fare |
| Fine-tuning | da fare: solo B-ctrl per il primo paper (04) |

## Stato dell'arte e novità

Aggiornato al 26 ottobre 2026. Il registro completo della ricerca, con tutte le fonti, è in 09_aggiornamento_ottobre_2026.md.

### 1. Quattro filoni che si incontrano

#### 1.1 Typed decision model (TDM)

Modelli che non generano testo: leggono uno stato e domande tipizzate (*choice*, *noul* sì/no, *score*) e restituiscono una probabilità per opzione in una sola passata.

Il filone è esploso: su arXiv ci sono ~200 paper su Jev e i TDM dal 15 settembre, e la **Decision Index** (la classifica dei TDM, edizione 0.4 dal 20 ottobre) conta più di 200 sistemi. Ci sono TDM chiusi di quasi tutti i grandi fornitori e decine di TDM aperti, quasi tutti ottenuti post-addestrando poche basi (Qwen3.5-9B, Qwen3.8-27B, Gemma-4). Le famiglie che contano per noi:

| Modello | Tipo | Base | Note |
|---|---|---|---|
| Jev 1.13 / **1.14** (TypeSafe) | chiuso, API | — | 1.14 dal 14/10 (immagini, tipo `box`, contesto lungo "danger zone"); `jev-latest` passa a 1.14; 1.13 resta, con 60 giorni di preavviso prima del ritiro |
| OpenAI Decisions, Microsoft Decision-1, d1-ultra (Liquid) | chiusi, API | — | OpenAI ora in beta pubblica |
| **Clef / Clef-flash** (Cloudflare, 1/10) | aperti, Apache 2.0 | Qwen3.8-27B / 9B | testa congiunta sopra il backbone; 79,0 su LLM-AggreFact (leaderboard) |
| **Nimble-v4 / v4-max** (Bespoke Labs) | aperti, CC BY-NC | 9B (base da verificare) / Qwen3.8-27B | 77,8 / **79,5** su LLM-AggreFact (leaderboard, primo posto) |
| **pplx-decider v1.2 / flash** (Perplexity) | pesi aperti | 27B / 4B | 78,7 su LLM-AggreFact (leaderboard) |
| Drex v1.5 (nace-ai) | aperto, licenza RAIL | MiMo-V2.6-Distill-Qwen-9B | 76,5 su LLM-AggreFact |
| elephant-1 / mammoth-1 (Baseten) | aperto (MIT) / — | Qwen3.5-9B / — | elephant-1 nella repo: 76,70 |
| JPT-9B, Nimble-9B-v3, d3-flash, StartLux-9B, Kev-9B | aperti | Qwen3.5-9B | nella repo (Kev da aggiungere) |
| Winnow-12B | aperto, Apache 2.0 | Gemma-4-12B | nella repo: 76,95 (BF16) |
| KnowLine-4B, d1-3B, Laya (~0,4B, encoder), CLM-8B (contrastivo) | aperti | Qwen3.5-4B, LFM2.5, ModernBERT, Qwen3-8B | nella repo (Laya da aggiungere) |

Ricette pubblicate per costruire TDM aperti: AnyJev (2610.00831), LLM-as-Jev (2610.02076), Releasing the Inner Jev (2610.17205), SII-Decision (2610.03935), Our Own Jev (2610.29052), Intern-Decision (2610.22131).

**Valutazioni generali dei TDM** utili come cornice: - **Audit dei primi 28 paper** (2609.32160): la lettura tipizzata "non ha mostrato un vantaggio di accuratezza indipendente" rispetto alla lettura delle probabilità delle etichette; i vantaggi chiari sono latenza e costo; checklist di 14 punti (§4). - **Valutazione di Jev su 37 dataset** (2609.37647): buona calibrazione sulle *choice*; sulle *noul* buon ordinamento ma soglia 0,5 inadatta; soglie fittate su 1.000 esempi non sempre trasferiscono. - **JEVal** (2610.03935): i TDM vanno bene quando la decisione si ricava dall'evidenza disponibile, ma sovrastimano la probabilità dell'opzione scelta. - **Limiti della singola passata** (2610.24929): Jev e le repliche aperte falliscono quando la decisione richiede passi intermedi (più aggiornamenti dello stesso fatto) e seguono un riassunto vecchio dello stato. - **Fragilità**: un contesto naturale aggiunto ribalta il 61–73% delle decisioni corrette (JevOut, 2609.30243); aggiungere altre domande alla stessa richiesta cambia le risposte dei TDM aperti (2610.14631); la formulazione negata della stessa domanda inverte o annulla l'AUC di cinque TDM su otto (Arize). - **Calibrazione**: nelle risposte binarie Jev sembra sopprimere un terzo valore, "non so" (Sys1Cal, 2609.35342). Nel fact checking è esattamente la differenza fra "contraddetto" e "non stabilito".

### 1.2 TDM applicati al grounding e al fact checking (il nostro filone diretto)

| Lavoro | Cosa fa | Cosa **non** fa |
|---|---|---|
| **Evaluating and Benchmarking Jev** (2609.37647, 29/9) | Jev zero-shot su **tutto il test di LLM-AggreFact**: **78,6** [77,6–79,6], una domanda *noul*, soglia 0,5, ECE 0,128; Qwen3.8-27B (76,9) e Gemma-4-E4B (75,6) letti allo stesso modo | nessun TDM aperto, nessun checker specializzato, nessuna analisi per fonte (solo l'intervallo 59,8–90,6), nessun test fuori dominio, una sola formulazione |
| **Jev-as-a-Judge for RAG Claim Verification** (2610.20634, 30/9) | Jev contro un LLM di frontiera su **495 claim di AggreFact**: pari in BAcc a 1/187 del costo, ma Jev ammette il 23,2% dei claim non supportati contro il 14,1%; la cascata non batte un controllo con escalation casuale | campione piccolo, solo Jev |
| **PremiseCheck** (2610.21046, 15/10) | Jev, Kev-27B, Microsoft Decision-1, Perplexity Decider come verificatori di premesse estratte da revisioni scientifiche; da giudici olistici (AUROC 50–57) a quasi pari a GPT-5.5 con la scomposizione | dominio specifico (revisioni), niente calibrazione, niente LLM-AggreFact, niente fine-tuning |
| **Arize, decision model benchmark** (ottobre, blog) | 8 TDM su RAGTruth (2.675 righe): Jev 85,5, Clef 85,2, d1 84,8, OpenAI 81,5, Kev-9B 76,8…; **sensibilità alla polarità** della domanda | blog, non paper; soglia fittata su metà dei dati; un solo benchmark |
| JEV-as-a-Judge (2609.26550, v5) | Jev come giudice con escalation; 240 casi di HaluEval | |
| Radiologia (2609.27607), citazioni finanziarie (2610.08675) | Jev come verificatore di supporto in un dominio, con coppie minime controllate | domini singoli, solo Jev |
| **Leaderboard di LLM-AggreFact** | nimble-v4-max 79,5, Clef 79,0, Decider v1.2 78,7, Jev 1.13 78,7, d1-ultra 78,5, nimble-v4 77,8, Clef Flash 76,6, Drex v1.5 76,5 | protocollo non documentato (domanda, soglia, chunking); nessuna calibrazione |

Da notare: la **Decision Index** contiene RAGTruth (2.700 richieste) e HoVer fra i benchmark pubblici, e ANLI, ContractNLI, NLI4CT fra quelli di NLI. I produttori di TDM ottimizzano esplicitamente per la Decision Index, quindi **la fonte RAGTruth di LLM-AggreFact va considerata a rischio di contaminazione** per tutti i TDM recenti (§5).

### 1.3 Fact checker specializzati su documento

- **MiniCheck** (2404.10774, EMNLP 2024): introduce LLM-AggreFact e i dati sintetici C2D/D2C; Bespoke-MiniCheck-7B (77,4) **non è più** il miglior modello aperto della leaderboard: lo superano Nimble-v4-max, Clef, Decider e Nimble-v4, tutti TDM.
- **FactCG** (2501.17144, NAACL 2025): DeBERTa da 0,4B a 75,6.
- AlignScore, SummaC, HHEM, Granite Guardian 3.3 (76,5), Lynx/HaluBench, HalluGuard.
- Lavori recenti: aggregazione di giudici economici (RAIM, 2609.39229, entro 1,9 punti dal primo della leaderboard), self-play per rilevatori (2607.07993), le metriche di attribuzione non trasferiscono fra dataset (2606.23915), le etichette dei benchmark di allucinazione dipendono dalla formulazione del criterio (2610.08026).

### 1.4 LLM generici letti come TDM, senza training

- **AnyJev** (2610.00831, Nokia): livello "L0" senza training: rotazione ciclica delle opzioni contro il bias di posizione e divisione per il prior delle etichette stimato senza etichette. Su Gemma-4-31B, 60,22 sulla Decision Index 0.3 (5° su 149) senza alcun training.

- **LLM-as-Jev** (2610.02076): gli LLM moderni sono già TDM; il fine-tuning serve soprattutto ai modelli piccoli.
- **Releasing the Inner Jev** (2610.17205): Gemma-4-31B zero-shot passa da 72,9 a 79,6 di Capability con la sola temperatura per tipo di domanda.

Conseguenza per noi: la baseline B1 non può essere solo la base "letta in modo ingenuo" (softmax sulle lettere). Serve anche **la base letta in modo calibrato senza training** (rotazione delle opzioni + temperatura), altrimenti un revisore dirà che il vantaggio del TDM è solo calibrazione che si ottiene gratis.

## 2. Il buco, rivisto

| Domanda | Coperta da qualcuno? |
|---|---|
| Quanto vale Jev su LLM-AggreFact intero? | **sì** (78,6 a soglia 0,5: 2609.37647). Per noi diventa un numero da riprodurre, non un contributo |
| Quanto valgono **i TDM aperti** con **un unico protocollo controllato** su AggreFact e fuori dominio? | **no**: solo voci di leaderboard inviate dai produttori, protocollo ignoto |
| Cosa aggiunge l'addestramento da decision model **rispetto alla base**, sul grounding? Varia molto fra ricette sulla stessa base? | **no** sul grounding (solo Qwen/Gemma accanto a Jev, che non ha una base nota); l'audit lo indica come domanda aperta in generale |
| Quanto della classifica dipende dal protocollo (soglia, formulazione, polarità, una o tre domande, composizione della richiesta, troncamento)? | **no** (studi di sensibilità esistono su altri compiti, non sul grounding e non su molti TDM) |
| I TDM distinguono "contraddetto" da "non stabilito"? Gli errori sono simmetrici? | in parte: asimmetria degli errori per Jev su 495 claim; ipotesi del "terzo valore soppresso" su dati sintetici |
| Le probabilità sono calibrate sul grounding? La soglia trasferisce fra domini? | in parte: solo l'ECE di Jev su AggreFact (0,128); niente trasferimento fra domini, niente TDM aperti |
| Gli errori dei TDM sono correlati fra loro e con i checker specializzati? (cascate, ensemble) | in parte: errori condivisi fra Jev e LLM su rubriche (2609.29769); non sul grounding, non fra TDM sulla stessa base |
| Partire da un TDM è meglio che partire dalla base, per addestrare un checker di grounding? | **no** (le ricette pubblicate addestrano TDM generali, non checker; il controllo con la base non c'è) |

## 3. Cosa rende il contributo difendibile oggi

1. **Ampiezza controllata**: ~15–20 TDM aperti e chiusi, cinque architetture di lettura (lettere su LLM causale, attenzione bidirezionale sul prompt, testa congiunta, encoder, contrastivo), da 3B a 27B, **stesse domande, stessi dati, stesse regole**, con cache di probabilità e logit rilasciate. Nessuna voce della leaderboard è confrontabile così.
2. **L'esperimento naturale "stessa base, ricette diverse"**: sei TDM su Qwen3.5-9B, due su Qwen3.8-27B, più Winnow/Gemma-4-12B e KnowLine/Qwen3.5-4B, contro la base letta in modo ingenuo e calibrato. Separa tre effetti: base, lettura, addestramento da decision model.
3. **Sensibilità al protocollo**, misurata senza nuova inferenza grazie alla grid search già pronta: se le scelte di protocollo valgono più della distanza fra i modelli, la leaderboard va letta diversamente. È un risultato utile a tutto il campo.
4. **Errori, calibrazione, trasferimento**: asimmetria degli errori (claim non supportati ammessi), contraddetto contro non stabilito, ECE per dominio, trasferimento della soglia, accordo fra modelli.
5. **Un esperimento di fine-tuning mirato** (B-ctrl): stesso training di grounding su un TDM e sulla sua base.
6. **Rispetto della checklist dell'audit** (§4), dichiarato punto per punto.

## 4. La checklist dell'audit (da rispettare)

| ID | Requisito | Come lo copriamo |
|---|---|---|
| B1 | baseline con log-probabilità delle etichette | basi dei TDM (Qwen3.5-9B, Qwen3.8-27B, Gemma-4-12B, Qwen3.5-4B) con lo stesso prompt; lettura ingenua **e** calibrata senza training (AnyJev L0 o temperatura) |
| B2 | cascate generative economiche | LLM piccolo che genera "Yes/No" (con e senza ragionamento breve); cascata TDM → LLM con il controllo a escalation casuale di 2610.20634 |
| B3 | modelli specifici del compito | Bespoke-MiniCheck-7B, MiniCheck-Flan-T5-L, FactCG, AlignScore, Granite Guardian 3.3 |
| T1 | dispersione fra modelli | molti TDM e più baseline; intervalli di confidenza |
| T2 | invarianza delle decisioni | polarità e parafrasi della domanda, distrattori, posizione dell'evidenza, composizione della richiesta |
| T3 | scambio dei nomi delle opzioni | inversione e rinomina delle opzioni e dei campi |
| T4 | provenienza dei dati | tabelle di provenienza; contaminazione (RAGTruth nella Decision Index; colonna `contamination_identifier` di AggreFact) |
| R1 | versioni e date esatte | revisioni dei pesi (già in `run.json`), versione di Jev (1.13 e 1.14), date delle chiamate |
| R2 | intervalli di confidenza | bootstrap per documento |
| R3 | scelte fatte dopo la valutazione | registro degli esperimenti; dichiarazione del controllo intermedio di Jev; la grid search sul test è solo esplorativa |
| C1 | calibrazione su dati tenuti da parte | ECE e Brier su test fuori dominio |
| C2 | accuratezza ad alta confidenza | copertura selettiva |
| C3 | soglie congelate prima del test | protocollo dello Step 0 |
| C4 | latenza con e senza cache | già misurata dal benchmark (sonda a cache fredda, throughput per batch) |

## 5. Rischi per la novità

- **Scoop**: altissimo. In sei settimane sono usciti tre lavori su TDM e AggreFact o claim verification, e i produttori inviano TDM alla leaderboard ogni settimana. Contromisura: preprint della parte di analisi entro fine novembre; ricontrollare arXiv ogni settimana con le chiavi del §6.
- **"È solo benchmarking"**: il rischio resta. La risposta è un'idea scientifica netta (RQ2: base contro ricetta; RQ3: protocollo contro modello), non la quantità di modelli.
- **Contaminazione**: RAGTruth è nella Decision Index, i dati di training dei TDM non sono pubblici. Riportare sempre la media di AggreFact anche **senza RAGTruth**, e verificare la colonna `contamination_identifier`.
- **Bersaglio mobile**: Jev 1.14, nuove versioni ogni settimana. Congelare la lista dei modelli a una data (es. 30 novembre) e dichiararla.
- **Modelli chiusi**: conclusioni principali sui modelli aperti; per i chiusi, versione e date.

### 6. Chiavi per la ricerca settimanale

arXiv (API: `abs:Jev`, `abs:"decision model" AND abs:typed`, `abs:AggreFact`, `abs:MiniCheck`), la leaderboard di LLM-AggreFact, la Decision Index, Semantic Scholar con "typed decision model fact", "System One grounding", "decision model hallucination". Lo script usato il 26 ottobre è descritto in 09.

## Le opzioni di paper, a confronto

La domanda è: *creare un dataset nuovo e testarci i modelli? proporre un dataset? oppure altro?* Rispetto all'8 ottobre le opzioni sono le stesse, ma il loro valore è cambiato: la valutazione di Jev su AggreFact è già pubblicata (2609.37647), e le ricette di fine-tuning dei TDM pure (2610.02076, 2610.17205, 2609.35865). Dettagli in 01 e 09.

### Opzione 1 — Benchmarking ampio ("tutti i TDM su AggreFact")

**Cosa**: valutare molti TDM aperti e chiusi sul fact checking documento–claim (LLM-AggreFact + fuori dominio), contro checker specializzati e LLM generici.

| Pro | Contro |
|---|---|
| quasi tutta l'inferenza è già fatta o pronta | **più debole di prima**: Jev su AggreFact è pubblicato, la leaderboard ha già i TDM |
| tempi brevi | senza una domanda scientifica è "una tabella più lunga della leaderboard" |

**Adatta a**: workshop o preprint, non a una conferenza principale.

### Opzione 2 — Paper di analisi con domande scientifiche nette (consigliata ora)

**Cosa**: la stessa inferenza dell'Opzione 1, organizzata attorno a tre domande che nessuno ha affrontato sul grounding: 1. **Base contro ricetta** (RQ2): sei TDM su Qwen3.5-9B, due su Qwen3.8-27B, Winnow su Gemma-4-12B, KnowLine su Qwen3.5-4B, contro la loro base letta in modo ingenuo e calibrato senza training. *Quanto aggiunge l'addestramento da decision model, e quanto varia fra ricette sulla stessa base?* 2. **Protocollo contro modello** (RQ3): quanto spostano il risultato soglia, polarità e parafrasi della domanda, una contro tre domande, composizione della richiesta, troncamento, contaminazione. *Le differenze della leaderboard sono più grandi del rumore di protocollo?* 3. **Che errori fanno** (RQ4–RQ6): ammissione di claim non supportati, contraddetto contro non stabilito, calibrazione e trasferimento della soglia, sovrapposizione degli errori.

Più **un solo esperimento di fine-tuning** (B-ctrl, 04): stesso training di grounding su un TDM e sulla sua base.

| Pro | Contro |
|---|---|
| ogni risultato ha valore, in qualunque direzione esca ("la ricetta conta poco" è un risultato forte quanto "conta molto") | servono le basi generiche e i test di robustezza: ~3 settimane di lavoro |
| usa il vantaggio unico della repo: stesse domande, cache di logit, grid search senza inferenza, misure di costo ed energia | il fine-tuning ridotto a un controllo: chi cerca un metodo resta deluso |
| risponde alla domanda aperta dell'audit (vantaggio della lettura tipizzata) sul compito dove conta | il campo corre: i risultati sui modelli vanno congelati a una data |
| sta nei tempi di ARR del 4 gennaio | |

**Adatta a**: ACL 2027 (main o Findings).

## Opzione 3 — Valutazione + metodo di specializzazione (era la consigliata)

**Cosa**: l'Opzione 2 più il fine-tuning completo (loss sulle lettere, replay o ancoraggio, varianti di domanda, negativi difficili, ablazioni, tre seed) su Winnow e JPT.

| Pro | Contro |
|---|---|
| contributo "dove sono i TDM" + "come migliorarli" | **la novità del metodo è calata**: loss sulle lettere + KL (LLM-as-Jev), calo di calibrazione con il fine-tuning (Inner Jev), coppie contrastive e rimozione dell'evidenza (PACT) sono già pubblicati in forma generale<br>2–2,5 mesi di lavoro: non entra nel 4 gennaio insieme alla Parte A fatta bene<br>rischio che il fine-tuning non superi Nimble-v4-max (79,5) o Clef (79,0) zero-shot |

**Adatta a**: secondo paper (EMNLP 2027 o ciclo ARR successivo), meglio se combinato con l'Opzione 4 completa e con dati multilingue.

## Opzione 4 — Set diagnostico ricavato da test esistenti

**Cosa**: test controllati costruiti trasformando esempi di test esistenti (coppie minime, rimozione dell'evidenza, distrattori, posizione, polarità della domanda, composizione della richiesta), validati a mano su un campione. Dettagli: 05_set_diagnostico.md.

| Pro | Contro |
|---|---|
| misura proprio le proprietà che i lavori di ottobre mettono in dubbio (polarità, contesto che ribalta, richieste composte)<br>economico | coppie minime controllate esistono già per domini singoli (radiologia, finanza): il valore sta nel farle su molti TDM e su fonti diverse<br>non si può derivare da LLM-AggreFact (licenza CC BY-ND, solo valutazione) |

Nel primo paper: **versione ridotta** (le famiglie automatiche che non richiedono validazione umana, più rimozione dell'evidenza dove è annotata). La versione completa va nel secondo.

## Opzione 5 — Proporre un dataset nuovo

| Pro | Contro |
|---|---|
| contributo chiaro e durevole<br><br>con **etichette distribuzionali** (più annotatori per esempio) sarebbe l'unico modo per valutare davvero la calibrazione, promessa centrale dei TDM; Sys1Cal (2609.35342) e ProbabilityBench (2610.17016) lo fanno su dati sintetici, non sul grounding | costoso (settimane di annotazione), revisori severi, allontana dalla domanda principale |

**Quando**: secondo o terzo paper (NeurIPS 2027 Datasets & Benchmarks, LREC). Candidati distintivi: etichette distribuzionali per il grounding, con la classe "non stabilito" separata da "contraddetto"; documenti in italiano.

## Tabella riassuntiva

| Opzione | Novità oggi | Costo | Tempo | Rischio di rifiuto (main) | Venue tipica |
|---|---|---|---|---|---|
| 1. Benchmarking ampio | bassa | basso | 3–4 sett. | alto | workshop, preprint |
| **2. Analisi con domande nette + B-ctrl** | **media-alta** | basso-medio | 7–8 sett. | medio | **ACL 2027 main/Findings** |
| 3. Analisi + metodo completo | media (metodo in parte pubblicato) | medio | 3–4 mesi | medio | EMNLP 2027 |
| 4. Set diagnostico | media (come aggiunta) | basso-medio | 2–3 sett. | — | dentro la 2 (ridotto) o la 3 (completo) |
| 5. Dataset nuovo | alta se il buco è reale | alto | 4–6 mesi | medio-alto | D&B, LREC |

### Raccomandazione

**Opzione 2, con il set diagnostico ridotto e B-ctrl, sottomessa ad ARR il 4 gennaio 2027 per ACL 2027, con un preprint entro fine novembre.** Poi l'Opzione 3 (+ Opzione 4 completa) come secondo paper.

Motivi: - la valutazione "piatta" e il metodo generale sono stati occupati da altri in ottobre; le domande RQ2 e RQ3 no, e la repo ha già quasi tutti i dati per rispondere; - ogni esito è pubblicabile: è la proprietà che serve con dieci settimane a disposizione; - B-ctrl è l'unico esperimento di fine-tuning con una domanda nuova (inizializzazione da TDM contro base, per il grounding) e costa poche corse; - il preprint anticipato è indispensabile: tre lavori vicini in sei settimane.

### Cosa decidere subito

1. **Data di congelamento della lista dei modelli** (proposta: 30 novembre). Dopo quella data, nuovi modelli solo in appendice.
2. **I modelli chiusi**: Jev 1.13 (per continuità con 2609.37647 e con il nostro run) e 1.14 (versione corrente); gli altri chiusi solo se l'accesso è immediato.
3. **B-ctrl su quale coppia**: proposta JPT-9B (o elephant-1) contro Qwen3.5-9B, perché la base è la stessa di molti TDM ed entra in una L40S; d1-3B per il pilota.

## Parte A — Il paper di analisi: cosa aggiungono i decision model al fact checking su documento

Rivista il 26 ottobre 2026. Rispetto alla prima versione: Jev su AggreFact è già pubblicato (2609.37647), quindi il paper non si regge più su "quanto vale un TDM", ma su **perché** e **quanto è solido il numero**.

### 1. Domande di ricerca

| RQ | Domanda | Esperimento principale |
|---|---|---|
| **RQ1** | Dove stanno i TDM aperti e chiusi, **con un unico protocollo**, rispetto a checker specializzati e LLM generici? Su AggreFact e fuori dominio? | tabella principale (A1) |

| RQ | Domanda | Esperimento principale |
|---|---|---|
| **RQ2** | **Base contro ricetta**: quanto aggiunge l'addestramento da decision model rispetto alla stessa base letta in modo ingenuo e in modo calibrato senza training? Quanto variano le ricette sulla stessa base? | gruppi per base (A2) |
| **RQ3** | **Protocollo contro modello**: quanto spostano il risultato soglia, polarità e parafrasi della domanda, una o tre domande, composizione della richiesta, troncamento, esclusione delle fonti a rischio di contaminazione? | grid search e varianti (A3) |
| **RQ4** | **Che errori**: i TDM ammettono claim non supportati più dei checker? Distinguono "contraddetto" da "non stabilito"? Dove cadono (lunghezza, multi-hop, numeri, entità)? | A4, A8 |
| **RQ5** | **Calibrazione**: le probabilità sono calibrate sul grounding? La soglia scelta in un dominio trasferisce agli altri? | A5 |
| **RQ6** | **Robustezza**: distrattori, posizione dell'evidenza, opzioni invertite o rinominate, richiesta con più domande | set diagnostico ridotto (A6) |
| **RQ7** | **Costo e composizione**: qualità contro costo, latenza, energia; gli errori si sovrappongono? Le cascate battono il controllo a escalation casuale? | A7, A9 |

RQ2 e RQ3 sono il cuore del paper: sono le domande nuove, e qualunque risultato esca è informativo.

## 2. Indizi già visibili nei nostri dati

Dalla grid search sul test (`results/.../grid_551bb722.md`). Sono **esplorativi** (scelte fatte sul test): servono a capire dove guardare, non vanno nel paper come risultati.

| Osservazione | Numeri | Perché conta |
|---|---|---|
| Il protocollo sposta più della distanza fra modelli | migliore combinazione contro default: d1-3B **+3,6** (71,84 → 75,47, una domanda sola), Rune +1,7, JPT +1,2, Winnow +0,8; fra i primi cinque della leaderboard ci sono 1,0 punti | RQ3: la leaderboard può essere più "protocollo" che "modello" |
| BAcc e AUC ordinano i modelli in modo diverso | elephant-1 ha la Macro AUC più alta (87,15) ma è secondo per BAcc (76,70 contro 76,95 di Winnow, Macro AUC 84,99) | RQ3/RQ5: la soglia fissa penalizza i modelli meno calibrati sul compito |

| Osservazione | Numeri | Perché conta |
|---|---|---|
| La terza domanda (contraddizione) porta poco segnale | AUC invertita di `contradicted_detail` fra 0,62 e 0,83, contro 0,89–0,91 per le altre due | RQ4: i TDM riconoscono il "non supportato" ma non distinguono bene il "contraddetto" (cfr. il "terzo valore soppresso" di Sys1Cal) |
| Tre domande aiutano poco o niente | per Rune e d1-3B la migliore regola è una domanda sola; Jev con una domanda a 0,5 fa 78,6 (2609.37647), il nostro run a tre domande dev-tuned 79,09 | RQ4: la scomposizione "in domande" non è la scomposizione "in premesse" di PremiseCheck |
| Profili diversi a parità di media | Winnow forte su CNN (72,2), KnowLine debole (56,1) ma migliore su LFQA (85,2); elephant-1 primo su XSum e FactCheck | RQ4/RQ7: errori non sovrapposti, spazio per ensemble |
| Documenti lunghi | BAcc fra 67 e 71 oltre 16.000 caratteri per tutti i TDM, contro 82–87 fra 1.000 e 4.000 | RQ4: il limite è comune, non di un modello |

## 3. Modelli

### 3.1 I gruppi per base (il disegno di RQ2)

| Base | TDM (stato nella repo) | Base generica da leggere |
|---|---|---|
| **Qwen3.5-9B** | JPT-9B (fatto), elephant-1 (fatto), Nimble-9B-v3 (adapter pronto), d3-flash (adapter pronto), StartLux-9B-Instant (adapter pronto; base da verificare), Kev-9B (da aggiungere) | Qwen3.5-9B (nella cache HF) |
| **Qwen3.8-27B** | Clef (nella cache, adapter da scrivere), Nimble-v4-max (da aggiungere) | Qwen3.8-27B (da scaricare; ~55 GB in BF16: serve una GPU da 80 GB o FP8) |
| Gemma-4-12B | Winnow-12B (fatto: BF16 e NVFP4) | Gemma-4-12B |
| Gemma-4-26B-A4B | Rune-26B (fatto) | Gemma-4-26B-A4B |
| Qwen3.5-4B | KnowLine-4B (fatto) | Qwen3.5-4B |
| LFM2.5-VL-3B | d1-3B (fatto) | LFM2.5-VL-3B |
| Qwen3-8B | CLM-8B (fatto, encoder congelato + teste) | Qwen3-8B (nella cache) |

Il gruppo Qwen3.5-9B è il più prezioso: **sei ricette diverse** (LoRA semplice, attenzione bidirezionale a blocchi, testa con 255 codici, attenzione bidirezionale sul prompt, testa a puntatore) **sulla stessa base**. Misura direttamente quanto conta la ricetta.

Per ogni base, tre letture: 1. **ingenua**: il prompt del TDM corrispondente (o un prompt neutro comune), softmax sulle lettere delle opzioni, attenzione causale; 2. **calibrata senza training**: rotazione delle opzioni e divisione per il prior delle etichette (AnyJev L0, 2610.00831), più temperatura fittata sul nostro dev; 3. il **TDM** con il suo runtime nativo (già così nella repo).

La differenza $3-2$ è "cosa aggiunge l'addestramento da decision model oltre a ciò che si ottiene gratis"; la differenza $2-1$ è "quanto vale la sola calibrazione della lettura". È esattamente la domanda dell'audit (2609.32160).

### 3.2 Gli altri gruppi

| Gruppo | Modelli | Stato |
|---|---|---|
| TDM chiusi | Jev 1.13 (fatto, da rifare con protocollo zero-shot), **Jev 1.14**; facoltativi: OpenAI Decisions (beta pubblica), d1-ultra, pplx-decider v1.2 via API | da fare (pochi dollari) |
| Altri TDM aperti | Rune-26B (fatto), d3-turbo (GPU 56 GiB+), StartLux-27B-AutoThink (pensa quando è incerto: interessante per RQ4), Drex v1.5, pplx-decider v1.2 (se i pesi sono scaricabili), Laya (encoder 0,4B) | in parte |
| Checker specializzati (B3) | FactCG-DeBERTa-L (fatto, 75,64), Bespoke-MiniCheck-7B (adapter fatto), MiniCheck-Flan-T5-L, AlignScore, Granite Guardian 3.3 | in parte |
| LLM generativi (B2) | un LLM piccolo che genera "Yes/No", con e senza ragionamento breve; un LLM chiuso economico su un sottoinsieme | da fare |

Per 08 la lista completa e la selezione minima.

## 4. Dati

| Blocco | Dataset | Uso |
|---|---|---|
| Sviluppo | `dev_select` / `dev_confirm` dalle nostre fonti (../fine_tuning_factcheck/00b_split_e_protocollo.md) | soglia, temperatura, scelta delle domande |
| Test principale | **LLM-AggreFact test** (11 fonti, 29.320 righe), zero-shot; media riportata **anche senza RAGTruth** | confronto con la leaderboard e con 2609.37647 |
| Fuori dominio | HaluBench (senza la parte RAGTruth), HalluMix, SciFact, Climate-FEVER, HealthVer, COVID-Fact, LLM-Oasis; FaithBench se ottenibile | generalizzazione e trasferimento della soglia; quasi tutti già nella cache HF |
| Diagnostico | 05_set_diagnostico.md, versione ridotta | RQ6 |

**Contaminazione** (T4): la Decision Index usa RAGTruth e HoVer, e i produttori ottimizzano per la Decision Index. Quindi RAGTruth va trattato come "probabilmente visto" per tutti i TDM recenti; HoVer non va usato come test fuori dominio per i TDM. Controllare anche la colonna `contamination_identifier` di AggreFact.

## 5. Protocollo

1. **Prompt**: per ogni TDM il suo formato e runtime nativi (già così nella repo: llm2jev, qev, Nimble engine, startlux-decide, ...). Per le basi, il formato del TDM corrispondente e un prompt neutro comune.
2. **Domande**: il pacchetto `config/questions/claim_support.json` (tre domande, scelte in origine per Jev sul dev di AggreFact: dichiararlo). Più la domanda singola `support_simple` come configurazione "neutra", e le sue varianti di polarità e parafrasi per RQ3.

3. **Soglia e temperatura**: fittate su `dev_select`, confermate su `dev_confirm`, applicate a tutti i test. Riportare **anche** soglia 0,5 (come 2609.37647) e soglia fittata sul dev di AggreFact (come probabilmente fanno le voci della leaderboard).
4. **Test**: una sola esecuzione per configurazione congelata. La grid search sul test resta esplorativa e va dichiarata come tale.
5. **Jev**: versione esatta (1.13.0 e 1.14.0) e date delle chiamate; il controllo intermedio del run originale (../../legacy/results/INTERIM_AMENDMENT.md) dichiarato.
6. **Documenti lunghi**: stessa regola per tutti (80.000 caratteri, 75% inizio e 25% fine); i runtime che rifiutano invece di troncare (elephant-1, Nimble, d3) registrano i fallimenti: riportarli per modello e per fonte.
7. **Data di congelamento** della lista dei modelli (proposta: 30 novembre 2026).

## 6. Metriche

- BAcc per fonte e media (formato della leaderboard); AUC per fonte e Macro AUC.
- **Tasso di ammissione dei non supportati** (1 − recall dei non supportati) e recall dei supportati, al punto operativo: la metrica di deployment che la BAcc nasconde (2610.20634). Già nel `report.json` (`unsupported_recall`).
- Brier, ECE (10 intervalli), diagrammi di affidabilità; ECE dopo temperature scaling.
- Copertura selettiva: accuratezza contro percentuale coperta.
- Sensibilità al protocollo: intervallo dei risultati sulle varianti di protocollo, per modello; correlazione di rango fra le classifiche ottenute con protocolli diversi (tau di Kendall).
- Costo: token, latenza p50/p95 a cache fredda, throughput, energia per 1.000 righe (già misurati dal benchmark).
- Intervalli al 95% con bootstrap per documento; test appaiati (bootstrap appaiato o McNemar).

## 7. Esperimenti e analisi

| ID | Esperimento | Cosa mostra |
|---|---|---|
| A1 | Tabella principale: tutti i modelli, AggreFact (11 fonti, con e senza RAGTruth) + media fuori dominio | RQ1 |
| A2 | TDM contro la loro base, lettura ingenua e calibrata, per gruppo di base; dispersione fra ricette sulla stessa base | **RQ2** |
| A3 | Sensibilità al protocollo: soglia (0,5 / nostro dev / dev di AggreFact), polarità e parafrasi della domanda, una contro tre domande, domanda da sola contro dentro una richiesta con tre domande, troncamento; classifica sotto ogni protocollo | **RQ3** |
| A4 | Errori asimmetrici; una domanda a tre opzioni (supportato / contraddetto / non stabilito) contro le domande binarie, sulle fonti dove le due classi negative sono distinguibili | RQ4 |
| A5 | ECE per dominio; soglia dal nostro dev contro soglia in dominio, per fonte | RQ5 |
| A6 | Set diagnostico ridotto | RQ6 |
| A7 | Qualità contro costo (BAcc contro costo e contro energia per 1.000 claim) | RQ7 |

| ID | Esperimento | Cosa mostra |
|---|---|---|
| A8 | Analisi degli errori: 100 errori per modello rappresentativo, categorizzati (entità, numeri, attribuzione, multi-hop, documento lungo, etichetta dubbia) | RQ4 |
| A9 | Accordo fra modelli: sovrapposizione degli errori fra TDM sulla stessa base, fra TDM e checker; ensemble semplice; cascata TDM → LLM contro escalation casuale a pari budget | RQ7 |
| A10 | Quantizzazione: Winnow BF16 / NVFP4 (fatto: 76,95 contro 77,49) | robustezza del deployment, in appendice |

## 8. Tabelle e figure previste

| N. | Contenuto |
|---|---|
| Tab. 1 | Modelli: base, ricetta di lettura, parametri, licenza, runtime, costo |
| Tab. 2 | LLM-AggreFact per fonte, tutti i modelli, protocollo unico |
| Tab. 3 | Fuori dominio + medie |
| Tab. 4 | TDM contro base (ingenua, calibrata), per gruppo (RQ2) |
| Tab. 5 | Sensibilità al protocollo, per modello (RQ3) |
| Tab. 6 | Set diagnostico ridotto (RQ6) |
| Fig. 1 | RQ2: per ogni base, la base ingenua, la base calibrata e i TDM come punti sullo stesso asse |
| Fig. 2 | RQ3: classifica sotto protocolli diversi (grafico a "bump"), con la banda della leaderboard |
| Fig. 3 | Diagrammi di affidabilità in dominio e fuori dominio |
| Fig. 4 | Qualità contro costo |
| Fig. 5 | Ammissione dei non supportati contro BAcc |

## 9. Lavoro e costi stimati

| Voce | Stima |
|---|---|
| Split, dev e test fuori dominio | 1 settimana (codice) |
| Run completi dei TDM con adapter pronto (d3-flash, StartLux, Nimble-v3, MiniCheck-7B) | 2–3 giorni GPU |
| Adapter nuovi (Clef, Nimble-v4, Kev-9B, basi generiche con le due letture) | 1,5 settimane |
| Inferenza su dev, fuori dominio e diagnostico | 3–5 giorni GPU |
| Jev 1.13 e 1.14 con il protocollo zero-shot | pochi dollari |
| Varianti di protocollo (RQ3) | quasi tutte senza inferenza (grid search); polarità e composizione della richiesta richiedono un'inferenza su un sottoinsieme |
| Analisi degli errori | 3 giorni |
| Scrittura | 2 settimane |
| **Totale** | **~7 settimane**, in parallelo con B-ctrl |

# Parte B — Fine-tuning: un esperimento nel primo paper, il metodo nel secondo

Il piano tecnico completo è in ../fine_tuning_factcheck/. Qui c'è solo ciò che serve **per i paper**. Rivisto il 26 ottobre 2026.

## 1. Cosa è cambiato

La prima versione proponeva quattro contributi tecnici. Oggi tre sono pubblicati in forma generale (per TDM generali, non per il grounding):

| Contributo previsto | Già pubblicato | Cosa resta nostro |
|---|---|---|
| Loss solo sulle lettere delle opzioni | LLM-as-Jev (2610.02076), Releasing the Inner Jev (2610.17205), Our Own Jev (2610.29052) | niente come metodo; resta la scelta motivata |
| Replay / ancoraggio contro l'oblio | ancoraggio KL in LLM-as-Jev; Inner Jev: nessun calo su BoolQ, MMLU, ARC… dopo il training; calibrazione in calo su 3 modelli su 4 | la misura sul grounding, non il metodo |
| Negativi per cancellazione dell'evidenza e coppie minime | PACT (2609.35865): coppie contrastive con certificato di rimozione della frase decisiva, termine di "necessità dell'evidenza", consistenza alle permutazioni | l'applicazione ai dati di grounding (MiniCheck, FactCG) |
| Robustezza alle varianti di domanda | in parte in PACT (permutazioni) e negli studi di fragilità | il test su polarità e composizione della richiesta |

Inoltre la guida di fine-tuning è passata a **una sola domanda `noul`** con loss binaria sul margine fra le due lettere, d1-3B per iterare e replay **non** obbligatorio (../fine_tuning_factcheck/summary/02c_replay_e_forgetting.md). Il paper va allineato a quella guida.

## 2. Nel primo paper: B-ctrl

### L'ipotesi

> A parità di dati di grounding, di loss e di budget, un checker ottenuto da un **TDM** è migliore (BAcc fuori dominio, calibrazione) di uno ottenuto dalla **sua base generica**.

Nessuno l'ha testata. Le ricette pubblicate addestrano TDM generali; i checker specializzati (MiniCheck, FactCG) partono da basi generiche. La risposta dice se l'addestramento da decision model è un buon punto di partenza per un checker, che è la domanda pratica di chi deve costruirne uno.

### Il disegno minimo

| Elemento | Scelta |
|---|---|
| Coppia principale | JPT-9B (o elephant-1) contro Qwen3.5-9B; pilota su d1-3B contro LFM2.5-VL-3B |
| Dati | mix di stadio 1 della guida (fonti pubbliche + MiniCheck C2D/D2C + ANLI difficile), stesso per entrambe (../fine_tuning_factcheck/02e_mix_finale.md) |
| Domanda | una `noul` (quella scelta sul nostro dev secondo ../fine_tuning_factcheck/02d_varianti_domanda.md) |

| Elemento | Scelta |
|---|---|
| Loss | CE binaria sul margine fra le due lettere (../fine_tuning_factcheck/04_loss.md) |
| Training | LoRA, stesso rank, passi e learning rate; 3 seed se il budget lo consente, altrimenti 1 seed + bootstrap |
| Valutazione | AggreFact zero-shot (con e senza RAGTruth), fuori dominio, ECE; facoltativo: un sottoinsieme della Decision Index pubblica per sapere quanto il TDM resta generale |
| Curva | BAcc contro numero di esempi (es. 0, 2k, 8k, 32k): il vantaggio del TDM, se c'è, dovrebbe essere massimo con pochi dati |

**Possibili esiti**

| Esito | Lettura |
|---|---|
| TDM-FT $\gg$ base-FT, soprattutto con pochi dati | l'inizializzazione da decision model aiuta: consiglio pratico ai costruttori di checker |
| TDM-FT $\approx$ base-FT | il valore è nei dati: coerente con l'audit; RQ2 e B-ctrl si confermano a vicenda |
| TDM-FT $<$ base-FT | il post-training da decision model irrigidisce il modello: risultato sorprendente, da controllare con un secondo seed e un secondo TDM |

Tutti e tre sono pubblicabili dentro il paper di analisi.

**Costo**

| Voce | Stima |
|---|---|
| Codice di training (già progettato nella guida) | 1,5–2 settimane |
| Pilota d1-3B (2 corse) | 1–2 giorni su una GPU da 24 GB |
| Coppia 9B, 2 corse × (1–3 seed), più la curva sui dati | ~1 settimana su L40S |
| Valutazione | 2–3 giorni |

## 3. Nel secondo paper: il metodo completo

Se B-ctrl dà un vantaggio al TDM, il secondo paper diventa "come specializzare un TDM per il grounding", con la novità spostata dove la letteratura non arriva:

1. **Dati di grounding con certificato** (stile PACT, ma sulle ricette C2D/D2C/CG2C): coppie minime e rimozione dell'evidenza, con il termine di necessità dell'evidenza.
2. **Tre classi invece di due**: supportato / contraddetto / non stabilito, per affrontare il "terzo valore soppresso" (Sys1Cal) e la debolezza della domanda sulla contraddizione che vediamo nei nostri dati (03 §2).
3. **Robustezza a polarità e composizione** come obiettivo di training, misurata sul set diagnostico completo.
4. **Confronto con lo stato dell'arte del momento**: Nimble-v4-max (79,5), Clef (79,0) e i checker; obiettivo realistico: un 9B vicino ai 27B.
5. **Oblio e calibrazione**: oblio sulla Decision Index pubblica (attenzione: contiene RAGTruth e HoVer, da escludere dal conto); calibrazione fuori dominio.

| Esperimento | Perché |
|---|---|
| B-main | TDM-FT contro i migliori zero-shot e i checker |

| Esperimento | Perché |
|---|---|
| B-loss | CE contro Brier contro CE + termini PACT |
| B-anchor | con e senza ancoraggio KL ai target del modello di partenza (P-KL della guida) |
| B-data | leave-one-source-out o almeno tre mix |
| B-3way | due classi contro tre |
| B-seed | 3 seed per la configurazione finale |

Tempi: 2–3 mesi. Venue: EMNLP 2027 o il ciclo ARR utile successivo (06).

### 4. Cosa rilasciare

- Adapter LoRA di B-ctrl (licenze: JPT e Nimble non commerciali; elephant-1 MIT; Qwen3.5 Apache 2.0) e codice di training.
- Ricette dei dati (script, non i testi di terze parti se le licenze non lo consentono).
- Cache delle previsioni su tutti i test, come già fatto per gli altri modelli.

## Il set diagnostico

Rivisto il 26 ottobre 2026: due versioni (ridotta per il primo paper, completa per il secondo) e tre famiglie nuove, suggerite dai lavori di ottobre sulla fragilità dei TDM.

### 1. Perché un set diagnostico e non un dataset nuovo

Un benchmark come LLM-AggreFact dice **quanto** un modello sbaglia, non **perché**. I TDM promettono di leggere il documento, di rispondere in modo stabile alla stessa domanda posta in modi diversi e di dare probabilità calibrate. In ottobre tre lavori hanno mostrato che queste promesse non sono scontate: - la **polarità** della domanda ("ogni claim è supportato?" contro "contiene un claim non supportato?") inverte o annulla l'AUC di cinque TDM su otto su RAGTruth (Arize); - **aggiungere altre domande** alla stessa richiesta cambia le risposte dei TDM aperti (2610.14631); - un **contesto naturale** aggiunto ribalta decisioni corrette e sicure (JevOut, 2609.30243, con contesti ottimizzati in modo avversario).

Un set diagnostico misura queste proprietà sul grounding, su molti TDM, con esempi costruiti in modo controllato. Le coppie minime esistono già per domini singoli e solo per Jev (radiologia 2609.27607, citazioni finanziarie 2610.08675): il nostro valore aggiunto è la copertura (molti modelli, più fonti) e il collegamento con RQ2 (le ricette sulla stessa base sono ugualmente fragili?).

### 2. Da dove si parte

Solo da **test** di dataset con licenza compatibile e mai usati in training: - test in distribuzione delle nostre fonti (FEVER `paper_test`, VitaminC test, MiniCheck e SummEdits nella parte di test); - fonti fuori dominio (SciFact, Climate-FEVER, HealthVer, COVID-Fact).

**Non** da LLM-AggreFact: la licenza è **CC BY-ND 4.0** e l'accesso è concesso "come benchmark di valutazione", quindi non si possono ridistribuire derivati. Su AggreFact si possono applicare le trasformazioni automatiche in locale e pubblicare solo gli script e i risultati aggregati.

**HoVer**: è fra i benchmark pubblici della Decision Index, quindi probabilmente visto dai TDM recenti; usarlo solo per le famiglie in cui conta la variazione fra originale e perturbato, e segnalarlo.

### 3. Le famiglie di test

| Famiglia | Trasformazione | Etichetta attesa | Costruzione | Validazione umana | Versione |
|---|---|---|---|---|---|
| **Polarità della domanda** (nuova) | stessa decisione chiesta in forma positiva e negata | complementare | automatica | no | **ridotta** |
| **Composizione della richiesta** (nuova) | la domanda da sola, poi dentro una richiesta con 2–3 altre domande (le nostre o domande non pertinenti) | invariata | automatica | no | **ridotta** |
| **Opzioni invertite o rinominate** | ordine A/B scambiato; `yes/no` → `true/false`, `supported/not supported` | invariata | automatica | no | **ridotta** |
| **Campi rinominati** | `document/claim` → `passage/assertion`, `context/answer` | invariata | automatica | no | **ridotta** |
| **Distrattori** | paragrafi irrilevanti dello stesso dominio prima e dopo | invariata | automatica | no | **ridotta** |
| **Posizione dell'evidenza** | la frase di supporto all'inizio, a metà o alla fine di un documento lungo | invariata | automatica | no | **ridotta** |
| **Solo claim** | documento vuoto o non pertinente | 0 | automatica | no | **ridotta** |
| **Rimozione dell'evidenza** | si cancellano le frasi gold che supportano il claim | da 1 a 0 (non stabilito) | automatica dove l'evidenza è annotata (FEVER); con LLM altrove | sì | ridotta (solo FEVER), completa |
| **Contesto naturale compatibile** (nuova) | una frase di contesto plausibile che non cambia la risposta (non ottimizzata in modo avversario, a differenza di JevOut) | invariata | LLM + filtro | a campione | completa |
| **Coppia minima sul claim** | si cambia un numero, una data, un'entità o un'attribuzione | da 1 a 0 (contraddetto) | LLM + verifica automatica | sì | completa |

| Famiglia | Trasformazione | Etichetta attesa | Costruzione | Validazione umana | Versione |
|---|---|---|---|---|---|
| **Coppia minima sul documento** | si cambia nel documento il valore citato dal claim | da 1 a 0 | VitaminC (già contrastivo) + LLM | a campione | completa |
| **Formulazione della domanda** | 10 parafrasi mai viste | invariata | LLM + filtro | a campione | completa |
| **Parafrasi del claim** | stesso contenuto, parole diverse | invariata | LLM + verifica | sì | completa |

Le famiglie della versione ridotta sono tutte automatiche e con etichetta garantita per costruzione: si fanno in pochi giorni, senza annotatori. Le famiglie "rimozione dell'evidenza" e "coppia minima" sono anche quelle che distinguono **non stabilito** da **contraddetto**, utile per RQ4.

Esempio di coppia minima sul claim:

> Documento: "Okeh Records is a subsidiary of Sony Music Entertainment and was founded by Otto Heinemann." Claim originale (1): "Okeh Records was founded by Otto Heinemann." Claim modificato (0): "Okeh Records was founded by **Thomas Edison**."

## 4. Validazione umana (versione completa)

- **Campione**: ~500 esempi delle famiglie in cui l'etichetta cambia (rimozione, coppie minime, parafrasi del claim, contesto naturale).
- **Annotatori**: 2, indipendenti, con una guida di una pagina ("il documento supporta ogni parte del claim? sì / no, contraddetto / no, non stabilito / incerto").
- **Accordo**: kappa di Cohen e accuratezza delle etichette automatiche contro il giudizio umano. Obiettivo: $\geq$ 95% di etichette automatiche confermate; le famiglie sotto il 90% vanno riviste o tolte.
- **Tempo**: ~500 esempi × ~40 secondi × 2 persone $\approx$ 11 ore in totale.

## 5. Metriche del set

| Proprietà | Metrica |
|---|---|
| Sensibilità all'evidenza | % di esempi in cui la decisione si inverte correttamente (rimozione, coppie minime) |
| Invarianza | % di decisioni invariate (distrattori, posizione, formulazione, campi, opzioni, composizione, parafrasi del claim) |
| Coerenza di polarità | AUC della forma negata contro quella positiva; % di coppie con P(sì positivo) + P(sì negato) $\approx$ 1 |
| Dipendenza dal solo claim | P(supportato) media con documento vuoto |
| Calibrazione sotto perturbazione | variazione dell'ECE fra originale e perturbato |

Un modello ideale ha sensibilità 100% e invarianza 100%. I due numeri insieme sono più informativi della sola accuratezza: un modello che dice sempre "no" ha invarianza alta ma sensibilità nulla.

## 6. Dimensione e formato

- Versione ridotta: ~300–500 esempi per famiglia, ~3.000 in tutto.
- Versione completa: ~300–1.000 esempi per famiglia, ~6.000–10.000 in tutto.
- Formato: JSONL con `id`, `family`, `parent_id`, `document`, `claim`, `question_variant`, `label`, `expected_change` ("flip" / "invariant" / "complement"), `source`, `license`, `validated`.

- Rilascio: dati derivati da fonti con licenza compatibile (CC BY / CC BY-SA / MIT; per le NC, solo uso non commerciale e dichiarato) + script per rigenerare il resto, incluse le trasformazioni su AggreFact.

### 7. Documentazione richiesta dai revisori

Una scheda tipo *datasheet*: motivazione, composizione, processo di raccolta, trasformazioni, validazione, accordo, usi previsti e non previsti, licenze, contatti. Va in appendice e nel repository del set.

## Venue, calendario, rigore e rischi

Date verificate il 26 ottobre 2026 sui siti ufficiali dove indicato; le altre vanno ricontrollate.

### 1. Dove sottomettere

| Venue | Come | Scadenze | Adatta a | Note |
|---|---|---|---|---|
| **ACL 2027** (Kyoto, 17–22 agosto 2027) | ACL Rolling Review, poi *commitment* | **ARR: 4 gennaio 2027**, 23:59 AoE (ufficiale, call); commitment e notifiche ancora da annunciare | **primo paper** (analisi + B-ctrl) | **obiettivo consigliato**. Long paper 8 pagine (9 nella versione finale); Limitations e Responsible NLP checklist obbligatorie; nessuna doppia sottomissione |
| Findings of ACL 2027 | stessa sottomissione | decisione dei chair | se main non passa | |
| EMNLP 2027 | ARR | conferenza a inizio novembre 2027 (Messico o America Centrale, provvisorio); ciclo ARR non ancora annunciato | **secondo paper** (metodo completo + set diagnostico completo) | |
| NAACL 2027, COLING 2027, EACL 2027 | ARR | scadenze ARR del 12 ottobre 2026 passate | — | non raggiungibili |
| ICLR 2027 | diretta | passata | — | |
| Workshop FEVER | diretta | FEVER 2026 si è tenuto il 28 marzo 2026 a Rabat; l'edizione 2027 non è ancora annunciata | versione breve, o il set diagnostico | attenzione alla doppia sottomissione se ci sono atti |
| NeurIPS 2027 Datasets & Benchmarks | diretta | attesa verso maggio 2027 | solo per un dataset vero (etichette distribuzionali) | |
| **arXiv** | preprint | **entro fine novembre 2026** | fissare la priorità | ARR permette i preprint (da verificare la regola corrente sull'anonimato nella call); la sottomissione resta anonima |

Il tema speciale di ACL 2027 è "Homogenization and knowledge collapse in LLMs". C'è un aggancio possibile ma da non forzare: se i TDM costruiti sulla stessa base sbagliano negli stessi punti (A9), è un caso misurabile di omogeneizzazione. Va citato solo se i dati lo mostrano.

## 2. Calendario a ritroso (obiettivo: ARR 4 gennaio 2027)

Dieci settimane. La parte di analisi viene prima, perché serve per il preprint e perché è il paper anche se B-ctrl non arriva.

| Periodo | Lavoro | Uscita |
|---|---|---|
| 26 ott – 8 nov | Step 0: split, dev, test fuori dominio. Run completi dei TDM con adapter pronto (d3-flash, StartLux-9B, Nimble-9B-v3, MiniCheck-7B). Adapter delle basi (lettura ingenua e calibrata). Jev 1.13 e 1.14 con il protocollo zero-shot | tabella A1 parziale |
| 9 – 22 nov | Adapter nuovi (Clef, Nimble-v4, Kev-9B). Inferenza fuori dominio. Varianti di protocollo (RQ3) e set diagnostico ridotto. Codice di B-ctrl e pilota su d1-3B | A1–A3 complete |
| **30 nov** | **congelamento della lista dei modelli**; **preprint arXiv** con A1–A3 (RQ1–RQ3) | preprint |
| 1 – 14 dic | B-ctrl sulla coppia 9B; calibrazione e trasferimento (A5); errori e accordo (A4, A8, A9) | risultati completi |
| **12 dic** | **punto di decisione**: se B-ctrl non è solido, resta il pilota in una sottosezione o in appendice | |
| 15 – 31 dic | scrittura, figure, appendici, revisione interna, checklist ARR | paper completo |
| 1 – 4 gen | ultimi controlli, sottomissione | |
| primavera 2027 | revisioni ARR, risposta, commitment ad ACL 2027 | |

Margine: stretto. La parte più a rischio sono gli adapter nuovi (Clef, Nimble-v4) e la base Qwen3.8-27B, che richiede una GPU da 80 GB: se non c'è, il gruppo 27B si limita ai TDM senza la base, e RQ2 si appoggia ai gruppi 9B, 12B e 4B.

## 3. Checklist di rigore (da completare prima della sottomissione)

**Dai 14 punti dell'audit dei TDM** (01_stato_arte_e_novita.md, §4): - [ ] B1 basi con lettura ingenua **e** calibrata senza training; B2 cascata generativa con controllo a escalation casuale; B3 checker specializzati - [ ] T1 dispersione fra modelli; T2 invarianza (polarità, composizione, distrattori, posizione); T3 opzioni rinominate o invertite; T4 provenienza e contaminazione - [ ] R1 versioni e date esatte (revisioni dei pesi in `run.json`, Jev 1.13.0 e 1.14.0); R2 intervalli di confidenza; R3 scelte post-valutazione dichiarate - [ ] C1 calibrazione su dati tenuti da parte; C2 accuratezza ad alta confidenza; C3 soglie congelate prima del test; C4 latenza con e senza cache

**Dalla checklist ARR**: - [ ] sezione Limitations - [ ] dichiarazione su rischi ed etica - [ ] licenze di dati e modelli e rispetto dei termini (LLM-AggreFact: CC BY-ND, solo valutazione; JPT, Nimble, StartLux, Bespoke-MiniCheck: non commerciali) - [ ] dettagli di calcolo: GPU, ore, numero di corse, energia (già misurata dal benchmark) - [ ] iperparametri e procedura di scelta - [ ] codice e dati rilasciati (o motivazione) - [ ] uso di assistenti AI dichiarato secondo la policy "Writing Assistance"

**Specifiche di questo lavoro**: - [ ] dichiarare che il pacchetto di domande e la soglia del run originale di Jev sono stati scelti sul dev di AggreFact, e il controllo intermedio sul test (../../legacy/results/INTERIM_AMENDMENT.md); nel paper usare il protocollo zero-shot - [ ] riprodurre il numero di Jev di 2609.37647 (78,6 a soglia 0,5) come controllo del nostro protocollo - [ ] la grid search sul test è esplorativa: nessuna scelta del paper viene da lì - [ ] media di AggreFact riportata anche senza RAGTruth (Decision Index); HoVer mai usato come test fuori dominio per i TDM - [ ] decontaminazione dei dati di B-ctrl documentata (RAGTruth 98%, WiCE 30%) - [ ] data di congelamento della lista dei modelli dichiarata

## 4. Rischi e contromisure

| Rischio | Probabilità | Impatto | Contromisura |
|---|---|---|---|
| Scoop: un lavoro con molti TDM aperti su AggreFact (tre lavori vicini in sei settimane; i produttori inviano alla leaderboard ogni settimana) | **alta** | alto | preprint entro il 30 novembre; ricerca settimanale su arXiv (01 §6); puntare su RQ2 e RQ3, che sono più difficili da replicare senza la nostra infrastruttura |
| Revisori: "è solo benchmarking" | media | alto | RQ2 e RQ3 come contributi principali; ogni tabella risponde a una domanda; B-ctrl è un risultato: conferma l'audit sul grounding e sposta il valore dei TDM su costo e interfaccia |
| RQ2 dà differenze piccole fra base calibrata e TDM | media | basso | data di congelamento; i nuovi modelli in appendice; il messaggio di RQ3 non dipende dai modelli |
| Bersaglio mobile (nuovi TDM, Jev 1.14, leaderboard che cambia) | certa | medio | analisi con e senza RAGTruth; test fuori dominio scelti fuori dalla Decision Index; dichiarato nelle limitazioni |
| Contaminazione dei TDM (dati di training non pubblici; RAGTruth nella Decision Index) | alta | medio | priorità ai modelli già pronti; Clef ha un `systemone` in Python nel repository dei pesi |
| Adapter nuovi lenti da scrivere (runtime proprietari, versioni di vLLM incompatibili) | media | medio | FP8 su L40S dove il runtime lo consente; altrimenti RQ2 sui gruppi 9B, 12B, 4B |
| GPU insufficiente per i 27B (Qwen3.8-27B, Nimble-v4-max, d3-turbo richiedono 56–80 GB) | media | medio | categoria "etichetta dubbia" nell'analisi degli errori; non inseguire le fonti rumorose |
| Etichette rumorose (ExpertQA ~59–61 per tutti; HaluEval segnalato) | certa | medio | dichiarare; non ridistribuire derivati di AggreFact |
| Licenze (molti TDM non commerciali; AggreFact CC BY-ND) | certa | basso per un paper | preferire arXiv |
| Doppia sottomissione (workshop con atti + conferenza) | bassa | alto | |

### 5. Etica e limitazioni (bozza)

- Un fact checker documento–claim verifica il **supporto nel documento**, non la verità nel mondo: un documento sbagliato produce verdetti sbagliati. Va scritto chiaramente, per evitare usi come "rilevatore di fake news".
- La BAcc nasconde l'asimmetria degli errori: un guardiano che ammette più claim non supportati è più pericoloso a parità di BAcc. Lo misuriamo e lo diciamo.
- Tutti i dati sono in inglese.
- Le probabilità calibrate in un dominio possono non esserlo in un altro (RQ5).
- Uso di modelli chiusi e di TDM aperti con dati di training non pubblici: contaminazione non esclusa.
- I dati generati con LLM (set diagnostico, B-ctrl) possono contenere errori sistematici del generatore; sono verificati automaticamente e, nella versione completa, su un campione umano.

## Scheletro del paper

Formato ACL: 8 pagine (long paper) + riferimenti + Limitations + appendici. Rivisto il 26 ottobre 2026 per il paper di analisi (02, Opzione 2).

### 1. Titoli possibili

Se il risultato di RQ2 è "la ricetta conta poco, la base e la lettura contano molto": - *Same Backbone, Same Verdicts? What Decision Training Adds to Grounded Fact Checking* - *Decision Models Are Their Backbones: A Controlled Study of Typed Decision Models as Fact Checkers*

Se il risultato di RQ2 è "la ricetta conta": - *Same Backbone, Different Verdicts: What Decision Training Adds to Grounded Fact Checking*

Se il messaggio principale è RQ3: - *Is It the Model or the Protocol? Typed Decision Models on Grounded Fact Checking*

### 2. Abstract di prova (numeri da riempire)

> Typed decision models (TDMs) answer typed questions about a state in one forward pass and return a probability for every option. They now top the LLM-AggreFact leaderboard, but their entries come from vendors with undocumented protocols, and recent work finds that the typed readout has no independent accuracy advantage over reading label probabilities from an ordinary LLM. We evaluate [K] open and closed TDMs, five readout architectures from 3B to 27B parameters, under a single frozen protocol on LLM-AggreFact and [M] out-of-domain grounding benchmarks, against specialized checkers and against their own base models read both naively and with training-free calibration. Exploiting [six] TDMs built on the same 9B backbone, we find that decision training adds [X] points of balanced accuracy over the calibrated base, while recipes on the same backbone differ by [Y]. Protocol choices that leaderboards leave unstated (threshold, question polarity, one versus three questions, request composition) move a single model by up to [Z] points, more than the [1.0]-point spread among the five best leaderboard entries, and change the ranking (Kendall $\tau$ = [t]). TDMs admit [W]% of unsupported claims at matched balanced accuracy, rarely separate contradicted from unstated content, and their thresholds transfer [poorly] across domains. Finally, training a grounding checker from a TDM rather than from its base [helps / does not help] ([V] points). We release predictions with full option distributions for every model, the evaluation harness, and a diagnostic suite.

### 3. Sezioni (~8 pagine)

| Sezione | Contenuto | Pagine |
|---|---|---|
| 1. Introduction | i TDM in cima alla leaderboard del grounding; due domande aperte (cosa aggiunge l'addestramento rispetto alla base; quanto è solido il numero); contributi | 1 |
| 2. Background & Related Work | TDM e ricette aperte; valutazioni di Jev (incluso AggreFact); TDM per claim verification (PremiseCheck, cascate RAG); checker specializzati; letture senza training e calibrazione; fragilità | 0,75 |
| 3. Setup | compito; modelli raggruppati per base; tre letture della base; protocollo congelato; dati e contaminazione; metriche (inclusa l'ammissione dei non supportati) | 1 |
| 4. RQ1–RQ2: What does decision training add? | tabella principale; base ingenua contro calibrata contro TDM, per gruppo; dispersione delle ricette | 1,5 |
| 5. RQ3: Model or protocol? | sensibilità a soglia, polarità, numero di domande, composizione, troncamento, contaminazione; classifiche sotto protocolli diversi | 1 |
| 6. RQ4–RQ6: What do TDMs get wrong? | errori asimmetrici, contraddetto contro non stabilito, calibrazione e trasferimento, set diagnostico ridotto, analisi degli errori | 1,25 |
| 7. RQ7 and B-ctrl: Using and training TDMs as checkers | costo, accordo fra modelli, cascate contro escalation casuale; TDM contro base come punto di partenza per il fine-tuning | 1 |
| 8. Discussion & Conclusion | quando usare un TDM, un checker, una base calibrata; raccomandazioni per chi pubblica risultati di TDM sul grounding (protocollo minimo da dichiarare) | 0,5 |
| Limitations | lingua, supporto contro verità, contaminazione, modelli chiusi, bersaglio mobile, dati sintetici | (fuori conteggio) |
| Appendici | prompt e runtime di ogni modello; tabelle per fonte; varianti di protocollo complete; iperparametri di B-ctrl; costi ed energia; schede del set diagnostico; checklist dell'audit punto per punto | |

## 4. Contributi (da scrivere nell'introduzione)

1. **Il primo confronto controllato di molti TDM aperti sul fact checking su documento**: [K] modelli, stesse domande, stessi dati, stesse regole, con le distribuzioni complete delle opzioni rilasciate.
2. **Una risposta, sul grounding, alla domanda aperta dell'audit**: grazie a più TDM sulla stessa base, separiamo il contributo della base, della lettura e dell'addestramento da decision model.
3. **Una misura della sensibilità al protocollo** che mostra quanto delle differenze riportate dipende da scelte non dichiarate, e un **protocollo minimo** da dichiarare.
4. **Un'analisi degli errori e della calibrazione** orientata al deployment (ammissione dei non supportati, contraddetto contro non stabilito, trasferimento delle soglie) e un set diagnostico ridotto.
5. **Un esperimento controllato di fine-tuning**: TDM contro base come punto di partenza per un checker.

## 5. Figure chiave

| Figura | Messaggio in una frase |
|---|---|
| Fig. 1 (pagina 1) | per ogni base, la base ingenua, la base calibrata e i TDM come punti sullo stesso asse di BAcc: quanto della distanza è lettura e quanto è addestramento |
| Fig. 2 | la classifica cambia con il protocollo (grafico a "bump"), con la banda dei primi cinque della leaderboard |
| Fig. 3 | ammissione dei non supportati contro BAcc: modelli con la stessa BAcc e guardiani molto diversi |
| Fig. 4 | diagrammi di affidabilità in dominio e fuori dominio |
| Fig. 5 | qualità contro costo (ed energia) per 1.000 claim |

## 6. Le obiezioni prevedibili dei revisori, e la risposta pronta

| Obiezione | Risposta |
|---|---|
| "Jev su AggreFact è già stato valutato (2609.37647)" | lo riproduciamo come controllo; il contributo sono i TDM aperti, il confronto con le basi e il protocollo |
| "La leaderboard ha già questi numeri" | protocollo non dichiarato; mostriamo che il protocollo vale quanto le differenze; i nostri numeri sono confrontabili fra loro |
| "Gli LLM sono già TDM (AnyJev, LLM-as-Jev)" | è la nostra ipotesi nulla, testata sul grounding con la lettura calibrata senza training |
| "Avete scelto soglia e prompt sul benchmark" | tutto scelto sul nostro dev; la grid search sul test è esplorativa e dichiarata |
| "Contaminazione" | media senza RAGTruth; fuori dominio scelto fuori dalla Decision Index; colonna `contamination_identifier` |
| "I modelli cambiano ogni settimana" | data di congelamento; il risultato di RQ3 non dipende dai modelli; harness e previsioni rilasciati |
| "Differenze piccole, entro il rumore" | intervalli per documento, test appaiati; per B-ctrl seed multipli o bootstrap |
| "Il fine-tuning è un controllo, non un metodo" | sì, per scelta: risponde a una domanda precisa; il metodo è un lavoro separato |
| "Solo inglese" | dichiarato nelle limitazioni |

## 7. Prossimi passi concreti

1. Confermare l'Opzione 2 e la data di congelamento (30 novembre).
2. Step 0 (split, dev, fuori dominio): è la base di tutte le tabelle.
3. Finire i run dei TDM con adapter pronto; scrivere gli adapter delle basi con le due letture.

4. Jev 1.13 e 1.14 con il protocollo zero-shot; riprodurre il 78,6 di 2609.37647.
5. Preparare il preprint con A1–A3 per il 30 novembre.

## Benchmark e modelli: cosa usano i lavori del settore e cosa usare noi

Integra 03_parte_A_valutazione.md. Rivisto il 26 ottobre 2026 con i rilasci di ottobre. Valutare solo su LLM-AggreFact resta un punto debole: i paper di riferimento usano più benchmark.

### 1. Su cosa si valutano i lavori di fact checking su documento

| Paper / modello | Benchmark usati | Metrica | Fonte |
|---|---|---|---|
| **TRUE** (NAACL 2022) | 11 dataset (FRANK, SummEval, MNBM, QAGS-CNNDM, QAGS-XSum, BEGIN, $Q^2$, DialFact, PAWS, FEVER, VitaminC) | ROC-AUC | 2204.04991 |
| **AlignScore** (ACL 2023) | TRUE + SummaC + altri 6: 22 in tutto, 19 mai visti | AUC, BAcc, correlazioni | 2305.16739 |
| **MiniCheck** (EMNLP 2024) | LLM-AggreFact (introdotto lì) | BAcc media per fonte | 2404.10774 |
| **FactCG** (NAACL 2025) | LLM-AggreFact | BAcc | 2501.17144 |
| **Granite Guardian** (IBM) | TRUE + benchmark di rischio | AUC | 2412.07724 |
| **Lynx** (Patronus) | HaluBench (introdotto lì) | accuratezza | 2407.08488 |
| **LettuceDetect** | RAGTruth | F1 | 2502.17125 |
| **HalluGuard** (Findings ACL 2026) | LLM-AggreFact (75,7) + RAGTruth (84,0) | BAcc | 2510.00880 |
| **FaithBench** (NAACL 2025) | allucinazioni di 10 LLM nei riassunti; i rilevatori migliori vicini al 50% | BAcc, F1 | 2410.13210 |
| **Evaluating Jev** (TDM, 29/9/2026) | 37 dataset, fra cui **LLM-AggreFact intero** (78,6), ANLI, PAWS | BAcc, ECE | 2609.37647 |
| **Jev-as-a-Judge for RAG** (TDM, 30/9/2026) | 495 claim di LLM-AggreFact | BAcc, ammissione dei non supportati, costo | 2610.20634 |
| **PremiseCheck** (TDM, 15/10/2026) | ReviewFact (9.267 commenti di revisione) | AUROC, costo | 2610.21046 |
| **Arize** (8 TDM, ottobre 2026) | RAGTruth (2.675) + valutatori Phoenix + routing | BAcc, errore di calibrazione, polarità | blog |
| **Decision Index** (classifica dei TDM) | fra i pubblici: **RAGTruth**, **HoVer**, ANLI, ContractNLI, NLI4CT; dalla 0.4 il punteggio conta solo le parti private | punteggi corretti per il caso | repo |

**La prassi**: almeno un benchmark aggregato (LLM-AggreFact oppure TRUE/SummaC), un benchmark RAG (RAGTruth o HaluBench), e nei lavori recenti un benchmark difficile e moderno (FaithBench). I lavori sui TDM usano quasi sempre un solo benchmark di grounding: è lo spazio in cui la nostra suite fa la differenza.

### 2. La suite proposta

"In cache" = già nella cache HF di questa macchina.

**Livello 1 — indispensabile**

| Benchmark | Cosa copre | Dimensione | Metrica | In cache | Note |
|---|---|---|---|---|---|
| **LLM-AggreFact** (11 fonti) | riassunti, dialoghi, RAG, claim di LLM | 29.320 | BAcc media per fonte + AUC; media anche **senza RAGTruth** | sì | CC BY-ND, solo valutazione |
| **HaluBench** (6 fonti) | QA con contesto: finanza, medicina, DROP | ~15.000 | BAcc per fonte | sì | parte RAGTruth riportata a parte |
| **HalluMix** | multi-documento, documenti lunghi, più domini | da verificare | BAcc | sì | sostituisce TRUE se il tempo manca |
| **Verifica di claim con evidenza data**: SciFact, Climate-FEVER, HealthVer, COVID-Fact | scienza, clima, salute | migliaia | BAcc, AUC | sì | fuori dalla Decision Index: test fuori dominio puliti per i TDM |
| **TRUE** (11 dataset) | riassunti, dialogo, parafrasi, verifica | ~100.000 (campionare a 5.000 per dataset) | ROC-AUC per dataset | no | confronto con AlignScore e Granite Guardian; facoltativo se il tempo manca |
| **FaithBench** | allucinazioni difficili nei riassunti | ~800 | BAcc | no | il più duro |

**Livello 2 — consigliato**

| Benchmark | Perché | In cache |
|---|---|---|
| **RAGTruth** (test, livello di risposta) | confronto con Arize, LettuceDetect, HalluGuard | sì (`wandb/RAGTruth-processed`) |
| **LLM-Oasis** (claim verification) | testi di Wikipedia | sì |
| SummaC benchmark | standard storico | no |
| WiCE, SummEdits, VitaminC (test) | in distribuzione per B-ctrl; VitaminC anche per le coppie minime | sì |

**Livello 3 — facoltativo**

| Benchmark | Perché |
|---|---|
| ContextualJudgeBench | se si parla di LLM-as-judge |
| SEAHORSE o altri multilingue | solo per una sezione multilingue |
| FACTS Grounding | **non adatto così com'è**: non fornisce coppie (documento, claim) etichettate da persone |

**Sempre presenti**

- **Set diagnostico ridotto** (05_set_diagnostico.md).
- **Generalità del TDM dopo il fine-tuning** (solo B-ctrl, facoltativo): un sottoinsieme della Decision Index pubblica, **escludendo RAGTruth e HoVer**.

## 3. Attenzione alle sovrapposizioni (fra benchmark, con il training, con la Decision Index)

| Sovrapposizione | Problema | Come gestirla |
|---|---|---|
| TRUE, SummaC e LLM-AggreFact condividono dataset di riassunti | coppie contate due volte | deduplicare per documento + claim; riportare ogni aggregato da solo |
| RAGTruth è in LLM-AggreFact, in HaluBench **e nella Decision Index** | per i TDM recenti RAGTruth è probabilmente visto | AggreFact con e senza RAGTruth; blocco RAGTruth riportato una volta, segnalato |
| **HoVer è nella Decision Index** (e nel nostro training di B-ctrl) | non è fuori dominio per nessuno | mai come test fuori dominio |
| ANLI, ContractNLI, NLI4CT nella Decision Index | i TDM sono ottimizzati sull'NLI | non usarli come test; ANLI difficile resta solo nel training di B-ctrl |
| TRUE contiene FEVER e VitaminC, nel training di B-ctrl | in distribuzione per i modelli fine-tunati | riportare TRUE anche senza FEVER e VitaminC (TRUE-9) |

Regola generale: nella tabella principale dichiarare per ogni benchmark se è **mai visto** in training (per B-ctrl) e se è **nella Decision Index** (per i TDM).

## 4. I modelli

### 4.1 Typed decision model

Raggruppati per base, perché è il disegno di RQ2. Stato: **fatto** = run completo sul test di AggreFact; **pronto** = adapter nella repo; **nuovo** = da aggiungere.

| Base | Modello | Lettura | Licenza | Stato |
|---|---|---|---|---|
| — (chiuso) | **Jev 1.13** / **1.14** (TypeSafe) | API | — | 1.13 fatto (dev-tuned, da rifare zero-shot); 1.14 nuovo |
| — (chiuso) | OpenAI Decisions (beta pubblica), Microsoft Decision-1, d1-ultra (Liquid), pplx-decider via API | API | — | facoltativi |
| **Qwen3.5-9B** | JPT-9B | LoRA, lettere | CC BY-NC | fatto (76,04) |
| | elephant-1 (Baseten) | attenzione bidirezionale a blocchi, lettere | MIT | fatto (76,70) |
| | Bespoke-Nimble-9B-v3 | LoRA, 255 codici | CC BY-NC | pronto |
| | d3-flash (vLLM-SR) | attenzione non causale, 255 codici | Apache 2.0 | pronto |

| Base | Modello | Lettura | Licenza | Stato |
|---|---|---|---|---|
| | StartLux-Decision-v1.1-9B-Instant | attenzione bidirezionale sul prompt (base da verificare) | CC BY-NC | pronto |
| | Kev-9B | LoRA + testa a puntatore | aperto | nuovo |
| | Nimble-v4 9B (base da verificare) | — | CC BY-NC | nuovo (77,8 in leaderboard) |
| **Qwen3.8-27B** | **Clef** (Cloudflare) | testa congiunta sugli stati nascosti | Apache 2.0 | nuovo (pesi in cache; 79,0 in leaderboard) |
| | **Nimble-v4-max** | — | CC BY-NC | nuovo (79,5 in leaderboard; ~55 GB BF16) |
| Gemma-4-12B | Winnow-12B | lettere | Apache 2.0 | fatto (BF16 76,95; NVFP4 77,49) |
| Gemma-4-26B-A4B | Rune-26B-A4B-v3 | lettere | aperto | fatto (76,24) |
| Qwen3.5 26B | d3-turbo | prefisso bidirezionale, 255 codici | Apache 2.0 | pronto (GPU 56 GiB+) |
| Qwen3.5 27B | StartLux-27B-AutoThink | pensa quando è incerto | CC BY-NC | pronto |
| Qwen3.5-4B | KnowLine-4B-Gen5.5 | lettura doppia dei prompt brevi | Apache 2.0 | fatto (75,65) |
| LFM2.5-VL-3B | d1-3B (Liquid) | parole yes/no | LFM Open | fatto (71,84) |
| Qwen3-8B (congelato) | CLM-v0.1-8B | contrastivo | Apache 2.0 | fatto (49,98: la regola a tre domande non è adatta) |
| MiMo-V2.6-Distill-Qwen-9B | Drex v1.5 | — | RAIL | facoltativo (76,5 in leaderboard) |
| ModernBERT | Laya (~0,4B) | encoder + testa | aperto | facoltativo (il più piccolo) |
| — | pplx-decider v1.2 27B / flash 4B | — | pesi aperti (licenza da verificare) | facoltativo (78,7 in leaderboard) |

### 4.2 Checker specializzati

| Modello | Taglia | Perché |
|---|---|---|
| **Bespoke-MiniCheck-7B** | 7B | riferimento storico (77,4); adapter pronto |
| MiniCheck-Flan-T5-L | 0,8B | riferimento di LLM-AggreFact |
| **FactCG-DeBERTa-L** | 0,4B | fatto (75,64) |
| AlignScore-large | 0,4B | riferimento per TRUE |
| **Granite Guardian 3.3** | 8B | forte su AggreFact (76,5) |
| HHEM-2.1-open, Lynx-8B, HalluGuard-4B | 0,1–8B | facoltativi |

### 4.3 Basi generiche lette come un TDM (B1, il cuore di RQ2)

| Base | TDM del gruppo | Letture |
|---|---|---|
| **Qwen3.5-9B** (in cache) | JPT, elephant-1, Nimble-v3, d3-flash, StartLux-9B, Kev-9B | ingenua (prompt di ogni TDM + prompt neutro) e calibrata (AnyJev L0 + temperatura) |
| **Qwen3.8-27B** | Clef, Nimble-v4-max | idem; serve GPU da 80 GB o FP8 |
| Gemma-4-12B | Winnow | idem |
| Qwen3.5-4B | KnowLine | idem |
| LFM2.5-VL-3B | d1-3B | idem |
| Gemma-4-26B-A4B, Qwen3-8B | Rune, CLM | facoltative |

#### 4.4 LLM generici che generano (B2, giudici)

| Gruppo | Modelli | Come |
|---|---|---|
| Aperti | un modello piccolo (es. Qwen3.5-9B stesso in modalità generativa) e uno medio (es. gpt-oss-20b o Qwen3.6-35B-A3B) | "Yes/No" generato; con e senza ragionamento |
| Chiusi | un modello economico e uno di punta di un fornitore | **su un sottoinsieme** (es. 200 righe per fonte); API batch; per la cascata con controllo a escalation casuale |

Per i modelli vecchi (GPT-4o, Claude 3.5 Sonnet, Llama-3.1-70B, ...) si citano i numeri della leaderboard.

## 5. Selezione consigliata

#### Versione minima (il paper del 4 gennaio)

| Gruppo | Modelli |
|---|---|
| TDM (~13) | Jev 1.13 e 1.14; gruppo Qwen3.5-9B (JPT, elephant-1, Nimble-v3, d3-flash, StartLux-9B, Kev-9B); Winnow-12B; KnowLine-4B; d1-3B; Rune-26B; Clef |
| Basi (4) | Qwen3.5-9B, Gemma-4-12B, Qwen3.5-4B, LFM2.5-VL-3B, con due letture |
| Specializzati (4) | Bespoke-MiniCheck-7B, MiniCheck-Flan-T5-L, FactCG, Granite Guardian 3.3 |
| Generativi (2–3) | un aperto piccolo, un chiuso economico, un chiuso di punta su sottoinsieme |

Benchmark: livello 1 senza TRUE e FaithBench se il tempo manca (tutti gli altri sono già in cache), più il set diagnostico ridotto.

#### Versione estesa (se c'è tempo, o nel secondo paper)

Nimble-v4 / v4-max e la base Qwen3.8-27B, d3-turbo, StartLux-27B-AutoThink, pplx-decider, Drex, Laya, CLM con domande adatte; TRUE, FaithBench, SummaC; i chiusi facoltativi.

## 6. Costi stimati

| Voce | Stima |
|---|---|
| Coppie della suite minima (AggreFact + HaluBench + HalluMix + 4 di verifica + diagnostico) | ~60.000–70.000 |
| TDM da ~9B, tre domande per coppia, su L40S | ~2–6 ore per modello sulla suite (riferimento: Winnow BF16 9,8 righe/s, elephant-1 5,9, KnowLine 2,9 sul test di AggreFact) |
| ~15 modelli aperti + 4 basi × 2 letture | ~80–120 ore GPU |
| Jev su tutta la suite | pochi dollari (il test di AggreFact è costato ~1,5 $) |
| LLM chiusi su un sottoinsieme (~5.000 coppie) | da qualche decina a qualche centinaio di dollari; API batch |

### Fonti

- TRUE https://arxiv.org/abs/2204.04991 · AlignScore https://arxiv.org/abs/2305.16739 · MiniCheck https://arxiv.org/abs/2404.10774 · FactCG https://arxiv.org/abs/2501.17144
- Granite Guardian https://arxiv.org/abs/2412.07724 · Lynx / HaluBench https://arxiv.org/abs/2407.08488 · LettuceDetect https://arxiv.org/abs/2502.17125 · HalluGuard https://arxiv.org/abs/2510.00880 · FaithBench https://arxiv.org/abs/2410.13210
- Leaderboard di LLM-AggreFact https://llm-aggrefact.github.io/ · Decision Index https://github.com/apolinario/decision-index
- TDM: Clef https://huggingface.co/Cloudflare/clef · Nimble-v4-max https://huggingface.co/bespokelabs/Nimble-v4-max · Drex https://huggingface.co/nace-ai/drex-v1.5 · Laya https://huggingface.co/convaiinnovations/laya · Kev https://github.com/jaredpalmer/kev · CLM https://huggingface.co/Contrastive-LM/CLM-v0.1-8B · AnyJev https://github.com/nokia-applied-research/AnyJev
- Lavori sui TDM e il grounding: vedi 09_aggiornamento_ottobre_2026.md

## Aggiornamento del 26 ottobre 2026: cosa è uscito e cosa cambia

Ricerca fatta il 26 ottobre 2026, diciotto giorni dopo la prima versione di queste note. Metodo: ricerca web; interrogazione dell'API di arXiv (`abs:Jev`, `abs:"decision model" AND abs:typed`, `abs:"decision models" AND abs:"System One"`, `abs:"typed decision"`, `abs:AggreFact`, `abs:MiniCheck`, `abs:FaithBench`), che dà ~200 paper sui TDM dal 1° settembre, filtrati per titolo e abstract su grounding, fact checking, allucinazioni, NLI, calibrazione e fine-tuning; lettura dei lavori più vicini; metadati e model card su Hugging Face; leaderboard di LLM-AggreFact e Decision Index; siti ufficiali delle conferenze.

### 1. I cambiamenti che toccano direttamente il paper

| # | Cosa è uscito | Cosa cambia per noi |
|---|---|---|
| 1 | **Jev su tutto il test di LLM-AggreFact**: 78,6 [77,6–79,6], una domanda *noul*, soglia 0,5, ECE 0,128; Qwen3.8-27B 76,9 e Gemma-4-E4B 75,6 con la stessa lettura (2609.37647, 29/9) | "Primo studio dei TDM su AggreFact" non è più vero per Jev. Il numero diventa un controllo da riprodurre |
| 2 | **Jev contro un LLM di frontiera su 495 claim di AggreFact**: pari in BAcc, costo 187 volte minore, ma 23,2% di claim non supportati ammessi contro 14,1%; cascata non migliore di un'escalation casuale a pari budget (2610.20634, 30/9) | Adottare la metrica "ammissione dei non supportati" e il controllo a escalation casuale per le cascate |

| # | Cosa è uscito | Cosa cambia per noi |
|---|---|---|
| 3 | **PremiseCheck**: Jev, Kev-27B, Microsoft Decision-1, Perplexity Decider come verificatori di premesse estratte da commenti di revisione; da 50–57 a quasi pari a GPT-5.5 grazie alla scomposizione (2610.21046, 15/10) | La scomposizione in premesse funziona; la nostra scomposizione "in domande" sembra aiutare poco: è un contrasto da discutere (RQ4) |
| 4 | **La leaderboard di LLM-AggreFact ha i TDM in testa**: nimble-v4-max 79,5, Clef 79,0, Decider v1.2 78,7, Jev 1.13 78,7, d1-ultra 78,5, nimble-v4 77,8, Clef Flash 76,6, Drex v1.5 76,5; Bespoke-MiniCheck-7B (77,4) non è più il miglior aperto | Nasce la domanda RQ3: le voci non dichiarano domanda, soglia, chunking; i primi cinque stanno in 1 punto |
| 5 | **La Decision Index** (classifica dei TDM, 0.4 dal 20/10, >200 sistemi) include RAGTruth e HoVer fra i benchmark pubblici, e ANLI, ContractNLI, NLI4CT | Rischio di contaminazione su RAGTruth per i TDM recenti; HoVer non utilizzabile come fuori dominio |
| 6 | **Audit dei primi 28 paper**: la lettura tipizzata non ha mostrato un vantaggio di accuratezza indipendente rispetto alla lettura delle probabilità delle etichette (2609.32160) | Diventa la nostra domanda RQ2, sul grounding |
| 7 | **Letture senza training**: AnyJev (rotazione delle opzioni + divisione per il prior, 2610.00831); LLM-as-Jev ("gli LLM sono già TDM", 2610.02076); Gemma-4-31B da 72,9 a 79,6 con la sola temperatura (2610.17205) | La baseline B1 deve includere la base **calibrata** senza training, non solo quella ingenua |
| 8 | **Ricette di fine-tuning per TDM**: LoRA sulle lettere + ancoraggio KL (LLM-as-Jev); LoRA + testa di decisione, calibrazione in calo su 3 modelli su 4, nessun calo su BoolQ/MMLU/ARC (Inner Jev); coppie contrastive con certificato di rimozione dell'evidenza (PACT, 2609.35865); autodistillazione del ragionamento (SII-Decision, 2610.03935; Tacit in AnyJev) | Il metodo della Parte B perde gran parte della novità. Nel primo paper resta B-ctrl (TDM contro base come punto di partenza), che nessuno ha fatto |
| 9 | **Fragilità**: la polarità della domanda inverte o annulla l'AUC di cinque TDM su otto su RAGTruth (Arize); altre domande nella stessa richiesta cambiano le risposte (2610.14631); un contesto naturale ribalta il 61–73% delle decisioni corrette (2609.30243); limiti della singola passata sui fatti aggiornati più volte (2610.24929) | Tre famiglie nuove nel set diagnostico (polarità, composizione della richiesta, contesto naturale); la nostra regola a tre domande dentro una richiesta va testata anche domanda per domanda |

| # | Cosa è uscito | Cosa cambia per noi |
|---|---|---|
| 10 | **"Terzo valore soppresso"**: nelle risposte binarie Jev sembra nascondere un "non so" (Sys1Cal, 2609.35342) | Collega la debolezza della domanda sulla contraddizione nei nostri dati alla distinzione "contraddetto / non stabilito" (RQ4) |
| 11 | **Jev 1.14** (14/10): immagini, tipo `box`, contesto lungo come funzione "danger zone"; `jev-latest` passa a 1.14; 1.13 resta con 60 giorni di preavviso prima del ritiro (blog) | Valutare entrambe le versioni; registrare la versione esatta |
| 12 | **ACL 2027**: ARR il **4 gennaio 2027** (ufficiale); tema speciale "Homogenization and knowledge collapse in LLMs" (call) | Il calendario si stringe a dieci settimane |
| 13 | **LLM-AggreFact** è CC BY-ND 4.0, con accesso "come benchmark di valutazione" (metadati del dataset su Hugging Face) | Nessun derivato ridistribuibile: il set diagnostico non può partire da AggreFact |

## 2. Nuovi TDM rilevanti per noi

| Modello | Data | Note |
|---|---|---|
| Clef / Clef-flash (Cloudflare) | 1/10 | Qwen3.8-27B, Apache 2.0, testa congiunta; pesi già nella cache HF di questa macchina |
| Nimble-v4 / v4-max (Bespoke Labs) | v4-max su HF dal 18/10 | Qwen3.8-27B (v4-max), CC BY-NC; il runtime è nel dataset `bespokelabs/nimble-v4-max-decision-index` |
| pplx-decider v1.2 27B / flash 4B (Perplexity) | metà ottobre | pesi aperti secondo la stampa; licenza e base da verificare |
| Drex v1.5 (nace-ai) | 28/9 | base MiMo-V2.6-Distill-Qwen-9B, licenza RAIL |
| mammoth-1 (Baseten) | ottobre | primo su Decision Index 0.4 secondo Baseten (71,24), terzo secondo BenchLM (68,4): fonti in disaccordo |
| Kev-27B | ottobre | usato in PremiseCheck |
| OpenAI Decisions, Microsoft Decision-1, d1-ultra | — | chiusi |

Con quelli già nella repo, il gruppo "Qwen3.5-9B" arriva a sei TDM e il gruppo "Qwen3.8-27B" a due: è ciò che rende possibile RQ2.

## 3. Altri lavori da citare

- Giudici a rubrica: i TDM e gli LLM sbagliano negli stessi punti (2609.29769).
- JEV-as-a-Judge (2609.26550, ora v5): 240 casi di HaluEval, escalation per confidenza.
- JEVal (2610.03935): i TDM sovrastimano la probabilità dell'opzione scelta.
- Radiologia (2609.27607) e citazioni finanziarie (2610.08675): Jev come verificatore di supporto in un dominio, con coppie minime.
- Opzioni di fallback poco affidabili (2610.19856); trasferimento delle politiche di rifiuto (2610.03387).

- Valutazione per agenti con autoverifica della pipeline (2610.02267): un buon modello di come dichiarare i propri errori di analisi.
- Grounding senza TDM: aggregazione di giudici economici (RAIM, 2609.39229); le metriche di attribuzione non trasferiscono fra dataset (2606.23915); le etichette dei benchmark di allucinazione dipendono dal criterio (2610.08026); self-play per rilevatori (2607.07993).
- Guardrail: i TDM non battono in modo affidabile classificatori e LLM-as-judge su prompt injection e sicurezza (Red Hat).

## 4. Cosa non ho trovato (e va ricontrollato ogni settimana)

- Nessun lavoro con **molti TDM aperti** sotto un unico protocollo su un benchmark di grounding.
- Nessun confronto **TDM contro la propria base** sul grounding.
- Nessuno studio della **sensibilità al protocollo** delle voci della leaderboard di AggreFact.
- Nessun **fine-tuning di un TDM come checker di grounding** con il controllo sulla base.
- Nessun dettaglio pubblico sul protocollo delle voci TDM della leaderboard (le model card di Nimble-v4-max e Clef non ne parlano; il documento dei benchmark pubblici di Nimble elenca AggreFact fra i dataset scartati per licenza e accesso).

## 5. Incertezze di questa ricerca

- Alcune pagine non erano leggibili (alcuni siti bloccati, PDF compressi): per Nimble-v4 9B, pplx-decider e mammoth-1 i dettagli (base, licenza) vanno verificati sulle model card.
- I punteggi della Decision Index cambiano fra fonti e date (es. mammoth-1: 71,24 secondo Baseten, 68,4 secondo BenchLM al 25/10).
- Le date ARR per EMNLP 2027 non sono ancora annunciate.