Idea di paper

Decision model tipizzati per il fact checking documento–claim

26 ottobre 2026

Indice

Idea di paper: decision model tipizzati per il fact checking documento–claim **3**
La risposta breve . . . 3
I file . . . 3
Cosa abbiamo già (e cosa manca) . . . 4

Stato dell'arte e novità **5**
1. Tre filoni che si incontrano . . . 5
1.1 Typed decision model (TDM) . . . 5
1.2 Fact checker specializzati su documento . . . 5
1.3 LLM come giudici e calibrazione . . . 5
2. Il buco . . . 6
3. Cosa rende il contributo difendibile . . . 6
4. La checklist dell'audit (da rispettare) . . . 6
5. Rischi per la novità . . . 7

Le opzioni di paper, a confronto **8**
Opzione 1 — Solo valutazione ("benchmarking paper") . . . 8
Opzione 2 — Valutazione + metodo di specializzazione (consigliata) . . . 8
Opzione 3 — Proporre un dataset nuovo . . . 8
Opzione 4 — Set diagnostico ricavato da test esistenti (contributo secondario consigliato) . . . 9
Opzione 5 — Due paper separati . . . 9
Tabella riassuntiva . . . 10
Raccomandazione . . . 10
Una domanda da chiarire prima di partire . . . 10

Parte A — Valutazione dei typed decision model come fact checker **11**
1. Domande di ricerca . . . 11
2. Modelli . . . 11
3. Dati . . . 12
4. Protocollo . . . 12
5. Metriche . . . 12
6. Esperimenti e analisi . . . 13
7. Tabelle e figure previste . . . 13
8. Lavoro e costi stimati . . . 14

Parte B — Specializzare i decision model senza romperli **15**
1. L'ipotesi . . . 15
2. Contributi tecnici (cosa c'è di nuovo) . . . 15
3. Esperimenti indispensabili per il paper . . . 15
4. Possibili esiti e come raccontarli . . . 16
5. Calcolo e tempi (stime) . . . 16
6. Cosa rilasciare . . . 16

Il set diagnostico (contributo secondario) **18**

1. Perché un set diagnostico e non un dataset nuovo . . . 18
2. Da dove si parte . . . 18
3. Le famiglie di test . . . 18
4. Validazione umana . . . 19
5. Metriche del set . . . 19
6. Dimensione e formato . . . 19
7. Documentazione richiesta dai revisori . . . 20

Venue, calendario, rigore e rischi **21**
1. Dove sottomettere . . . 21
2. Calendario a ritroso (obiettivo: ARR gennaio 2027 per ACL 2027) . . . 21
3. Checklist di rigore (da completare prima della sottomissione) . . . 22
4. Rischi e contromisure . . . 22
5. Etica e limitazioni (bozza) . . . 23

Scheletro del paper **24**
1. Titoli possibili . . . 24
2. Abstract di prova (versione "metodo", numeri da riempire) . . . 24
3. Sezioni (versione completa, ~8 pagine) . . . 24
4. Contributi (da scrivere nell'introduzione) . . . 25
5. Figure chiave . . . 25
6. Le obiezioni prevedibili dei revisori, e la risposta pronta . . . 26
7. Prossimi passi concreti . . . 26

Benchmark e modelli: cosa usano i paper del settore e cosa usare noi **27**
1. Su cosa si valutano i paper di fact checking su documento . . . 27
2. La suite proposta . . . 28
   Livello 1 — indispensabile . . . 28
   Livello 2 — consigliato . . . 28
   Livello 3 — facoltativo . . . 29
   Sempre presenti . . . 29
3. Attenzione alle sovrapposizioni fra benchmark (e con il training) . . . 29
4. I modelli . . . 29
   4.1 Typed decision model / System One . . . 29
   4.2 Checker specializzati . . . 30
   4.3 LLM generici letti come un TDM (baseline B1 della checklist) . . . 30
   4.4 LLM generici che generano (baseline B2, giudici) . . . 31
5. Selezione consigliata . . . 31
   Versione minima (paper solido, ~20 modelli) . . . 31
   Versione estesa (se c'è tempo) . . . 31
6. Costi stimati (da verificare) . . . 31
7. Cosa cambia nel paper . . . 32
Fonti . . . 32

Idea di paper: decision model tipizzati per il fact checking documento–claim

Cartella di lavoro per decidere **che paper scrivere**, **con quali esperimenti** e **dove sottometterlo**. Scritta l'8 ottobre 2026.

La risposta breve

1. **La novità c'è, ma il campo corre.** Dal rilascio di Jev (15 settembre 2026) sono usciti decine di paper sui *typed decision model* (TDM). L'audit dei primi 28 (arXiv 2609.32160) dice che **nessuno** si concentra su fact checking, allucinazioni, NLI o verifica di claim, e nessuno fa fine-tuning dei modelli aperti. Il lavoro più vicino (JEV-as-a-Judge, 2609.26550) usa 240 esempi di HaluEval, solo con Jev. Lo spazio "TDM come fact checker su documento" è libero **oggi**: conviene muoversi in fretta e rendere pubblico un preprint presto.
2. **Non partirei da un dataset nuovo.** Proporre un dataset è un contributo a sé: richiede annotazione umana, documentazione, licenze e baseline, cioè mesi di lavoro e costi. Per questa domanda di ricerca esistono già benchmark solidi (LLM-AggreFact e altri). Il contributo più forte e più rapido è **un'analisi rigorosa dei TDM come fact checker**, più **un metodo per specializzarli senza rompere ciò che li rende utili**.
3. **Il piano consigliato: un paper principale, con un preprint anticipato.**
   - **Parte A, valutazione** (in gran parte già fatta in questa repo): TDM aperti e chiusi contro checker specializzati (MiniCheck, FactCG, Bespoke) e contro LLM generici letti allo stesso modo, su LLM-AggreFact **zero-shot**, su domini fuori distribuzione, con calibrazione e test di robustezza.
   - **Parte B, metodo**: fine-tuning di Winnow-12B e JPT-9B con loss sulle lettere di risposta e replay per non dimenticare, misurando quanto si guadagna sul fact checking e quanto si perde sulle decisioni generali.
   - **Contributo secondario facoltativo**: un piccolo **set diagnostico** (coppie minime, rimozione dell'evidenza, distrattori) ricavato da test esistenti e validato a mano su un campione. È molto più economico di un dataset nuovo ed è utile a tutta la comunità.
4. **Dove sottometterlo**: ACL 2027 (Kyoto, agosto 2027) tramite ACL Rolling Review; secondo il sito di ACL 2027, l'ultimo ciclo ARR utile è **gennaio 2027**. In alternativa EMNLP 2027 (scadenza attesa verso maggio–giugno 2027), oppure il workshop FEVER se si vuole uscire prima con la sola Parte A. Le date esatte vanno verificate sui siti ufficiali.

I file

File	Contenuto
01_stato_arte_e_novita.md	Cosa esiste già (TDM, fact checker specializzati, LLM-as-judge), dove sta il buco, cosa si rischia
02_opzioni_di_paper.md	Le alternative (solo valutazione, metodo, dataset nuovo, set diagnostico) con pro, contro, costi e raccomandazione

File	Contenuto
03_parte_A_valutazione.md	Domande di ricerca, modelli, baseline, dati, metriche, esperimenti, tabelle e figure della parte di valutazione
04_parte_B_finetuning.md	Il metodo di specializzazione e gli esperimenti che servono per un paper
05_set_diagnostico.md	Come costruire e validare il set diagnostico (contributo secondario)
06_venue_calendario_rischi.md	Conferenze, calendario a ritroso, checklist di rigore, rischi e come gestirli
07_scheletro_paper.md	Titoli possibili, abstract di prova, sezioni, tabelle e figure

Cosa abbiamo già (e cosa manca)

Elemento	Stato
Jev-1.13 su tutto il test di LLM-AggreFact (79,09, dev-tuned)	fatto, ma con due limiti da dichiarare: domande e soglia scelte sul dev di AggreFact, e un controllo intermedio sul test (vedi `results/INTERIM_AMENDMENT.md`)
Winnow-12B (NVFP4 e BF16), JPT-9B, Rune-26B, FactCG su tutto il test, con cache di logit e probabilità	fatto
Soglie fittate sul dev di AggreFact per i modelli aperti	fatto
Split nostri train/dev/test e test fuori dominio	da fare (../fine_tuning/00b_split_e_protocollo.md)
Baseline con LLM generici letti allo stesso modo (stesso prompt, logit delle lettere)	da fare: è la prima obiezione che farà un revisore
Calibrazione, robustezza, costi e latenza misurati in modo sistematico	in parte (latenze nei log), da completare
Fine-tuning	da fare (../fine_tuning/)

Stato dell'arte e novità

1. Tre filoni che si incontrano

1.1 Typed decision model (TDM)

Modelli che non generano testo: leggono uno stato e domande tipizzate (*choice*, *noul* sì/no, *score*) e restituiscono una probabilità per opzione in una sola passata.

Modello	Tipo	Note
Jev 1.13 (TypeSafe)	chiuso, API	rilasciato il 15/09/2026; riferimento del filone
Winnow-12B	aperto (Gemma-4-12B), Apache 2.0	GGUF + server llama.cpp
JPT-9B	aperto (Qwen3.5-9B + LoRA), CC BY-NC 4.0	implementazione `llm2jev`
Rune-26B-A4B	aperto (Gemma-4 MoE)	
Laya (421M), Kev-9B/4B, djev-0.1	aperti	citati in JevBench e nei benchmark di Winnow

Letteratura (settembre–ottobre 2026), tutta molto recente:

- **Audit dei primi 28 paper** (2609.32160): rassegna e **checklist di 14 punti** per valutare i TDM (baseline, disegno dei test, riproducibilità, calibrazione e deployment). Nessun paper si concentra su fact checking, allucinazioni, NLI o verifica di claim; il fine-tuning dei modelli aperti non è trattato.
- **JEV-as-a-Judge** (2609.26550): Jev come giudice economico con escalation; fra i compiti, **240 casi di HaluEval** con evidenza; trova rumore nelle etichette di HaluEval. Solo Jev, nessun modello aperto, nessun benchmark di grounding completo.
- **JevBench** (preprint): framework di valutazione generale dei TDM (Jev, djev-0.1, Laya).
- Altri: copertura delle opzioni candidate (2610.03387), agent harness (2610.02267), penetration testing (2609.28940), decisioni scientifiche (2609.24965).

1.2 Fact checker specializzati su documento

- **MiniCheck** (2404.10774, EMNLP 2024): introduce LLM-AggreFact e i dati sintetici C2D/D2C; Bespoke-MiniCheck-7B (77,4) è il miglior modello aperto della leaderboard.
- **FactCG** (2501.17144, NAACL 2025): dati multi-hop da grafi di contesto (CG2C); DeBERTa da 0,4B a 75,6.
- AlignScore, SummaC, HHEM, Granite Guardian, Lynx/HaluBench (2407.08488).

Questi modelli sono **addestrati per un solo compito**. I TDM sono generali e vanno adattati al compito solo con la domanda.

1.3 LLM come giudici e calibrazione

- LLM generici letti tramite le probabilità di "sì/no" in una passata (classificazione con label log-probability): idea vecchia, che i TDM rendono un prodotto.

- Lavori recenti sostengono che sui modelli proprietari post-2025 la confidenza verbalizzata sia più affidabile delle log-probabilità (2609.10996) e che la calibrazione vada trattata come criterio primario di valutazione (2609.26489). Sono temi che il nostro paper tocca direttamente: i TDM promettono probabilità calibrate per costruzione.

2. Il buco

Domanda	Coperta da qualcuno?
Quanto valgono i TDM (aperti e chiusi) come fact checker su documento, su un benchmark completo come LLM-AggreFact?	**No** (solo 240 casi HaluEval con Jev)
Battono i checker specializzati di pari taglia? E un LLM generico letto allo stesso modo?	**No**
Le loro probabilità sono calibrate su questo compito?	**No** (calibrazione dei TDM studiata in generale, non sul grounding)
La soglia trasferisce fra domini?	**No**
Scomporre la decisione in più domande tipizzate (supporto, dettaglio non stabilito, contraddizione) aiuta?	In parte per altri compiti (invarianza delle decisioni), non per il fact checking
Sono robusti a formulazione della domanda, nomi dei campi, distrattori, rimozione dell'evidenza?	**No**
Si possono specializzare con fine-tuning senza perdere le capacità generali?	

3. Cosa rende il contributo difendibile

1. **Primo studio sistematico** dei TDM sul fact checking documento–claim, con modelli aperti e chiusi.
2. **Protocollo zero-shot pulito** su LLM-AggreFact (decisioni prese su dati nostri), quindi confrontabile con la leaderboard.
3. **Le baseline che un revisore chiederà**: checker specializzati e LLM generici con lo stesso prompt e la stessa lettura dei logit. Separano l'effetto dell'addestramento "da decision model" dall'effetto del semplice leggere le probabilità.
4. **Calibrazione e robustezza** misurate, non solo l'accuratezza.
5. **Metodo di specializzazione** con misura esplicita dell'oblio.
6. Rispetto della **checklist dell'audit** (§4): è un argomento forte in revisione, perché mostra che il lavoro segue gli standard del filone.

4. La checklist dell'audit (da rispettare)

ID	Requisito	Come lo copriamo
B1	baseline con log-probabilità delle etichette	LLM generici (Qwen3.5-9B, Gemma-4-12B, base dei TDM aperti) con lo stesso prompt
B2	cascate generative economiche	LLM piccolo che genera "Yes/No" (più eventuale ragionamento breve)
B3	modelli specifici del compito	MiniCheck, Bespoke-MiniCheck-7B, FactCG, AlignScore
T1	dispersione fra modelli	più TDM e più baseline; intervalli di confidenza
T2	invarianza delle decisioni	test comportamentali (formulazione, distrattori, posizione)

ID	Requisito	Come lo copriamo
T3	scambio dei nomi delle opzioni	inversione e rinomina delle opzioni e dei campi
T4	provenienza dei dati	tabelle di provenienza e decontaminazione
R1	versioni e date esatte	revisioni dei pesi, versione di Jev, date delle chiamate
R2	intervalli di confidenza	bootstrap per documento
R3	scelte fatte dopo la valutazione	registro degli esperimenti; dichiarazione del controllo intermedio di Jev
C1	calibrazione su dati tenuti da parte	ECE e Brier su test fuori dominio
C2	accuratezza ad alta confidenza	copertura selettiva
C3	soglie congelate prima del test	protocollo dello Step 0
C4	latenza con e senza cache	misure su vLLM e sul server Winnow

5. Rischi per la novità

- **Scoop**: decine di paper sui TDM in un mese. Un lavoro sul fact checking può uscire in qualsiasi momento. Contromisura: preprint su arXiv della Parte A appena pronta, poi la versione completa.
- **"È solo una valutazione"**: per una conferenza principale serve qualcosa in più del benchmarking. La Parte B (metodo) e le analisi (calibrazione, scomposizione in domande, robustezza) rispondono a questa critica.
- **Modello chiuso (Jev)**: versioni che cambiano, prompt interno non noto. Va riportata la versione esatta, e le conclusioni principali vanno appoggiate ai modelli aperti.

Prima della sottomissione: rifare la ricerca bibliografica (arXiv, ACL Anthology, Semantic Scholar) con le chiavi "typed decision model", "System One", "Jev", "decision model fact", "LLM-AggreFact 2026".

Le opzioni di paper, a confronto

La domanda è: *creare un dataset nuovo e testarci i modelli? proporre un dataset? oppure altro?* Le opzioni realistiche sono cinque.

Opzione 1 — Solo valutazione ("benchmarking paper")

Cosa: valutare TDM aperti e chiusi sul fact checking documento–claim con benchmark esistenti (LLM-AggreFact + test fuori dominio), con calibrazione, robustezza e costi, contro checker specializzati e LLM generici.

Pro	Contro
Gran parte dei risultati c'è già (5 modelli su tutto il test di AggreFact)	i revisori delle conferenze principali tendono a considerarla un contributo debole se manca un'idea o un'analisi forte
Tempi brevi (4–6 settimane)	facile da superare: chiunque abbia accesso a Jev può fare qualcosa di simile
Costo basso (inferenza; Jev è costato ~2 $ per tutto)	

Adatta a: preprint rapido, workshop (FEVER, TrustNLP), Findings se l'analisi è profonda.

Opzione 2 — Valutazione + metodo di specializzazione (consigliata)

Cosa: l'Opzione 1, più il fine-tuning di Winnow-12B e JPT-9B con loss sulle lettere e replay, con la misura di quanto si perde sulle decisioni generali (oblio).

Pro	Contro
Contributo completo: "dove sono i TDM oggi" + "come migliorarli senza romperli"	più lavoro: codice di training, GPU (L40S), molte corse
Risponde a un buco esplicito dell'audit (fine-tuning dei modelli aperti, attribuzione dei guadagni)	rischio che il fine-tuning non batta i checker specializzati: il paper resta valido se l'analisi è onesta, ma è meno forte
Il controllo con i modelli base (stesso training su Gemma-4-12B e Qwen3.5-9B) dà un risultato scientifico netto, in un senso o nell'altro	

Adatta a: ACL / EMNLP (main o Findings).

Opzione 3 — Proporre un dataset nuovo

Cosa: costruire un benchmark nuovo di fact checking (documenti, claim, etichette umane) e valutarci i modelli.

Pro	Contro
Un buon dataset può avere molto impatto e molte citazioni	**costoso**: per ~2.000–5.000 esempi con doppia annotazione servono settimane di annotatori (o un budget di crowdsourcing qualificato) e un protocollo di accordo
Contributo chiaro e durevole	**i revisori sono severi**: chiedono motivazione del buco, guida di annotazione, accordo fra annotatori, analisi degli errori, datasheet, licenze, baseline forti il buco va dimostrato: LLM-AggreFact, HaluBench, HalluMix, RAGTruth, FaithBench coprono già molto allontana dalla domanda principale (i TDM)

Quando avrebbe senso: solo se c'è un buco che i dataset esistenti non coprono e che i TDM rendono importante. Due candidati:

- **etichette graduate o distribuzionali** (più annotatori per esempio, con probabilità di supporto): l'unico modo per valutare davvero la calibrazione, che è la promessa dei TDM;
- **domini o lingue non coperti** (es. documenti in italiano, documenti amministrativi o legali lunghi).

Adatta a: NeurIPS Datasets & Benchmarks, LREC-COLING, oppure come secondo paper dopo il primo.

Opzione 4 — Set diagnostico ricavato da test esistenti (contributo secondario consigliato)

Cosa: un insieme di test **controllati**, costruito trasformando esempi di test esistenti: coppie minime (si cambia un numero o un'entità nel claim), rimozione della frase di evidenza, distrattori aggiunti, evidenza spostata in un documento lungo, domande parafrasate, campi rinominati. Le trasformazioni sono automatiche (anche con LLM); un **campione viene validato a mano**.

Pro	Contro
Costa poco: niente annotazione da zero, solo validazione di un campione (es. 500 esempi, 2 annotatori, 2–3 giorni)	non è un "dataset nuovo" pieno: va presentato come risorsa diagnostica
Misura proprio le proprietà promesse dai TDM (sensibilità all'evidenza, invarianza, calibrazione)	va costruito solo da test (mai da dati di training) e con licenze compatibili
Riutilizzabile da tutta la comunità, anche per altri checker	

Dettagli: 05_set_diagnostico.md.

Opzione 5 — Due paper separati

1. **Subito**: Opzione 1 come preprint e poi workshop o Findings (fissa la priorità, dato che il campo corre).
2. **Dopo**: Opzione 2 (fine-tuning) + Opzione 4 (set diagnostico) per ACL o EMNLP 2027.

Pro	Contro
protegge dallo scoop	i due paper si sovrappongono: il secondo deve aggiungere molto per essere accettato

Pro	Contro
il primo esce in poche settimane	un preprint arXiv **non** impedisce la sottomissione a ACL/EMNLP; un paper già *accettato* a un workshop con atti sì, se il secondo è troppo simile: verificare le regole sulla doppia sottomissione

Tabella riassuntiva

Opzione	Novità	Costo	Tempo	Rischio di rifiuto (conferenza principale)	Venue tipica
1. Solo valutazione	media	basso	4–6 sett.	alto	workshop, Findings
2. Valutazione + metodo	alta	medio	3–4 mesi	medio	ACL/EMNLP main o Findings
3. Dataset nuovo	alta se il buco è reale	alto	4–6 mesi	medio-alto	D&B track, LREC
4. Set diagnostico	media (come aggiunta)	basso-medio	2–3 sett.	— (secondario)	dentro l'Opzione 2
5. Due paper	—	medio	preprint subito + 3–4 mesi	—	workshop + main

Raccomandazione

Opzione 2 con il set diagnostico dell'Opzione 4, più un preprint anticipato della sola parte di valutazione.

Motivi:

- usa il lavoro già fatto (cinque modelli valutati, infrastruttura, protocollo, dati di training pronti);
- risponde a tre buchi indicati dall'audit: fine-tuning dei modelli aperti, attribuzione dei guadagni (architettura/inizializzazione contro dati), stabilità della calibrazione fra domini;
- evita il costo e il rischio di un dataset nuovo, ma lascia una risorsa riutilizzabile (il set diagnostico);
- il preprint anticipato protegge dallo scoop.

Il dataset nuovo (Opzione 3) lo terrei come **secondo paper**, nella forma più distintiva: **etichette distribuzionali per la calibrazione** dei fact checker, eventualmente multilingue (inglese + italiano).

Una domanda da chiarire prima di partire

Contributo principale: "valutazione" o "metodo"? Il titolo, l'abstract e l'ordine delle sezioni cambiano molto:

- se il fine-tuning dà un guadagno netto (es. Winnow sopra 79 su AggreFact zero-shot, senza oblio), il paper è **di metodo**, con la valutazione come motivazione;
- se il guadagno è modesto, il paper è **di analisi** ("cosa sanno e non sanno fare i TDM come fact checker"), con il fine-tuning come uno degli esperimenti.

Conviene decidere dopo le prime corse del pilota (Fase 1 di ../fine_tuning/07_esperimenti.md), scrivendo intanto le sezioni comuni.

Parte A — Valutazione dei typed decision model come fact checker

1. Domande di ricerca

RQ	Domanda	Esperimento principale
RQ1	Quanto valgono i TDM (aperti e chiusi) come fact checker documento–claim, zero-shot, rispetto a checker specializzati e a LLM generici?	tabella principale su LLM-AggreFact + test fuori dominio
RQ2	Il vantaggio viene dall'addestramento "da decision model" o dal semplice leggere i logit di un LLM?	stesso prompt e stessa lettura su Gemma-4-12B e Qwen3.5-9B base (le basi di Winnow e JPT)
RQ3	Le probabilità sono calibrate? Una soglia scelta in un dominio trasferisce agli altri?	ECE/Brier; soglia dal nostro dev contro soglia dal dev di AggreFact
RQ4	Scomporre la decisione in più domande tipizzate aiuta?	una domanda contro la regola a tre domande `min(p1, 1−p2, 1−p3)`; contributo di ciascuna domanda
RQ5	I TDM guardano davvero il documento? Sono robusti a formulazione, nomi, distrattori?	set diagnostico (05)
RQ6	Qual è il compromesso qualità / costo / latenza?	token/s, costo per 1.000 claim, latenza con e senza cache del prefisso

2. Modelli

Gruppo	Modelli	Stato nella repo
TDM chiuso	Jev 1.13 (API)	valutato su tutto il test di AggreFact
TDM aperti	Winnow-12B (BF16, NVFP4; Q8_0 da aggiungere), JPT-9B, Rune-26B-A4B	valutati su tutto il test
TDM aperti da aggiungere	Laya (421M), Kev-9B / Kev-4B, djev-0.1	da fare (danno la dimensione: da 0,4B a 26B)
LLM generici, stessa lettura (B1)	Gemma-4-12B, Qwen3.5-9B (basi di Winnow e JPT); eventualmente Qwen3-8B, Gemma-4-31B	da fare

Gruppo	Modelli	Stato nella repo
LLM generici, generazione (B2)	un LLM piccolo che risponde "Yes/No" generando; un LLM con breve ragionamento	da fare
Checker specializzati (B3)	FactCG-DeBERTa-L (fatto: 75,64), MiniCheck-Flan-T5-L, Bespoke-MiniCheck-7B (pesi già nella cache HF), AlignScore	in parte

Il confronto più informativo per RQ2 è **Winnow contro Gemma-4-12B** e **JPT contro Qwen3.5-9B**: stessa architettura, stesso prompt, stessa lettura dei logit. La differenza misura cosa ha aggiunto l'addestramento a decision model.

3. Dati

Blocco	Dataset	Uso
Sviluppo	`dev_select` / `dev_confirm` costruiti dalle nostre fonti (../fine_tuning/00b_split_e_protocollo.md)	soglia, temperatura, scelta delle domande
Test principale	**LLM-AggreFact test** (11 fonti, 29.320 righe), zero-shot	confronto con la leaderboard
Test fuori dominio	HaluBench (senza la parte RAGTruth, riportata a parte), HalluMix, SciFact, Climate-FEVER, HealthVer / COVID-Fact	generalizzazione
Test in distribuzione	test di FEVER, ANLI, VitaminC, HoVer, MiniCheck, SummEdits, AVeriTeC	riferimento per la Parte B
Diagnostico	05_set_diagnostico.md	RQ5

Per la Parte A da sola, il test in distribuzione è utile ma non indispensabile; i blocchi chiave sono AggreFact e fuori dominio.

4. Protocollo

1. **Prompt**: per ogni TDM il suo formato nativo (già riprodotto per Winnow, JPT, Rune nei benchmark della repo); per gli LLM generici lo stesso formato usato dal TDM corrispondente.
2. **Domande**: il pacchetto `packs/claim_support.json` (tre domande). Va dichiarato che è stato scelto, per Jev, sul dev di AggreFact. Per un'analisi pulita aggiungere anche una domanda "neutra" scritta prima di qualsiasi esperimento (es. la sola `support_simple`).
3. **Soglia e temperatura**: fittate su `dev_select`, confermate su `dev_confirm`, applicate a tutti i test. Come confronto secondario, la soglia fittata sul dev di AggreFact.
4. **Test**: una sola esecuzione per configurazione congelata.
5. **Jev**: riportare versione e date delle chiamate; dichiarare il controllo intermedio sul test fatto nel run originale (`results/INTERIM_AMENDMENT.md`). Rieseguire Jev con il protocollo zero-shot costa pochi dollari.
6. **Documenti lunghi**: stessa regola di troncamento per tutti i modelli (80.000 caratteri, 75% inizio e 25% fine); riportare quanti documenti sono stati troncati per modello e per fonte.

5. Metriche

- BAcc per fonte e media (LLM-AggreFact: media sulle 11 fonti, come la leaderboard); AUC.
- Brier, ECE (10 intervalli), diagrammi di affidabilità.

- Copertura selettiva: accuratezza contro percentuale di esempi coperti, al variare della confidenza.
- Stabilità: deviazione standard fra domande parafrasate.
- Costi: token di input, latenza per claim, throughput (con e senza cache del prefisso: le tre domande condividono il documento).
- Intervalli al 95% con bootstrap per documento; test appaiati fra modelli (bootstrap appaiato o test di permutazione).

6. Esperimenti e analisi

ID	Esperimento	Cosa mostra
A1	Tabella principale: tutti i modelli, AggreFact (11 fonti) + media fuori dominio	RQ1
A2	TDM contro la loro base generica, stessa lettura	RQ2: vale l'addestramento da decision model?
A3	Soglia dal nostro dev contro soglia dal dev di AggreFact; ECE per dominio	RQ3: trasferimento della calibrazione
A4	Una domanda contro tre; ablazione di ciascuna domanda nella regola min; regola min contro media	RQ4
A5	Set diagnostico	RQ5
A6	Curva qualità–costo (BAcc contro costo per 1.000 claim)	RQ6
A7	Quantizzazione: Winnow BF16 / Q8_0 / NVFP4	effetto della compressione su accuratezza e calibrazione
A8	Analisi degli errori: 100 errori per modello, categorizzati (entità, numeri, attribuzione, multi-hop, etichetta dubbia)	dove sbagliano i TDM
A9	Accordo fra modelli: quanto gli errori dei TDM si sovrappongono a quelli dei checker specializzati	utile per ensemble e cascate

Spunto già visibile dai dati della repo per A2 e A8: Winnow è forte sui riassunti di notizie (CNN 72,1 alla soglia 0,30) e più debole su WiCE (77,4), JPT il contrario (CNN 62,3, WiCE 83,8). Profili di errore diversi a parità di media: argomento interessante per l'analisi.

7. Tabelle e figure previste

N.	Contenuto
Tab. 1	Modelli: tipo, parametri, licenza, formato, costo
Tab. 2	LLM-AggreFact zero-shot per fonte, tutti i modelli (formato leaderboard)
Tab. 3	Fuori dominio + media dei blocchi
Tab. 4	TDM contro la base generica (RQ2)
Tab. 5	Ablazione delle domande (RQ4)
Tab. 6	Set diagnostico (RQ5)
Fig. 1	Diagrammi di affidabilità (RQ3)
Fig. 2	Qualità contro costo (RQ6)
Fig. 3	Copertura selettiva

N.	Contenuto
Fig. 4	Delta soglia trasferita contro soglia in dominio, per fonte

8. Lavoro e costi stimati

Voce	Stima
Split, dev e test fuori dominio	1 settimana (codice)
Inferenza dei modelli aperti su dev + test fuori dominio + diagnostico	~1–2 giorni su L40S
Nuovi modelli (Laya, Kev, basi generiche, Bespoke, MiniCheck) su AggreFact	~2–3 giorni su L40S
Jev con il protocollo zero-shot	pochi dollari
Analisi degli errori	2–3 giorni
Scrittura	2 settimane
Totale Parte A	**~4–6 settimane**

Parte B — Specializzare i decision model senza romperli

Il piano tecnico completo è in ../fine_tuning/. Qui c'è solo ciò che serve **per il paper**: l'ipotesi, gli esperimenti indispensabili e come presentarli.

1. L'ipotesi

> Un typed decision model si può specializzare sul fact checking documento–claim con un fine-tuning leggero (LoRA) che ottimizza **solo la decisione che si legge in inferenza** (il softmax sui logit delle lettere delle opzioni), più un **replay con target del modello di partenza**. Si ottiene un guadagno netto sul fact checking, zero-shot fuori dominio, mantenendo calibrazione e capacità di decisione generali.

2. Contributi tecnici (cosa c'è di nuovo)

1. **Loss sulle lettere** al posto dell'SFT classico: si ottimizza solo il softmax ristretto alle opzioni nella posizione della risposta. Mostrare con dati che l'SFT classico peggiora la calibrazione (ECE) a parità di accuratezza.
2. **Replay per self-distillation** per un modello i cui dati originali non sono pubblici: domande tipizzate generiche, con target uguali alle probabilità del modello congelato (KL). Misurare l'oblio su JevBench, Kev e typed-decisions.
3. **Dati solo testo contro testo, con negativi difficili**: fonti pubbliche + negativi generati per cancellazione dell'evidenza e modifica minima del claim, con etichette derivate dall'operazione e verificate da un secondo modello.
4. **Robustezza del formato**: varianti automatiche di domanda e nomi dei campi, per non trasformare il TDM in un classificatore a una sola stringa.

Nessuno di questi elementi da solo è radicalmente nuovo. La novità è **combinarli per una classe di modelli nuova (i TDM)** e **misurare il compromesso specializzazione / oblio / calibrazione**, che l'audit del filone indica come problema aperto.

3. Esperimenti indispensabili per il paper

ID	Esperimento	Perché un revisore lo chiederà
B-main	Winnow-FT e JPT-FT contro la baseline, su AggreFact zero-shot + fuori dominio + in distribuzione	il risultato principale
B-ctrl	**Stesso training su Gemma-4-12B e Qwen3.5-9B base**	separa il contributo dell'inizializzazione da decision model da quello dei dati
B-loss	Loss sulle lettere contro SFT classico; CE contro Brier	giustifica la scelta della loss

ID	Esperimento	Perché un revisore lo chiederà
B-replay	Con e senza replay; quota di replay (0 / 10 / 20%)	misura l'oblio evitato
B-data	Leave-one-source-out (o almeno: solo MiniCheck+ANLI, + negativi generati, mix completo)	quali dati contano
B-var	Con e senza varianti di domanda	robustezza al wording
B-seed	3 seed per la configurazione finale	varianza
B-ext	Bespoke-MiniCheck-7B e FactCG con la stessa suite	confronto con lo stato dell'arte aperto

Facoltativi (se c'è tempo): loss contrastiva su coppie minime; S3 (tre domande) contro S1; rank LoRA; 8k contro 4k token.

4. Possibili esiti e come raccontarli

Esito	Lettura	Come impostare il paper
FT del TDM $\gg$ baseline e $\gg$ FT della base generica, oblio contenuto	l'inizializzazione da decision model aiuta	paper di **metodo**: "Specializing typed decision models for grounded fact checking"
FT del TDM $\approx$ FT della base generica	il valore è nei dati; il TDM non dà vantaggio di partenza	paper di **analisi**: risultato onesto e utile ("decision training does not transfer to grounding")
FT migliora AggreFact ma peggiora fuori dominio	sovra-specializzazione	analisi delle fonti di dati (B-data); paper di analisi
Oblio forte anche con replay	compromesso reale	curva specializzazione contro oblio come risultato centrale

Tutti gli esiti sono pubblicabili **se** il protocollo è pulito e i controlli ci sono. Il rischio vero è un paper senza B-ctrl o senza oblio misurato.

5. Calcolo e tempi (stime)

Voce	Stima
Codice (render, train, merge, valutatori)	2–3 settimane
Generazione di replay, varianti, negativi difficili (modello locale o API)	1 settimana
Corse su JPT (pilota + ablazioni, ~10 corse)	2–3 settimane su portatile o L40S
Corse su Winnow (~5 corse) + controlli sulle basi (2 corse)	2 settimane su L40S
Valutazione completa ed export	1 settimana
Totale Parte B	**~2–2,5 mesi** in parallelo con la scrittura

6. Cosa rilasciare

- Adapter LoRA (o pesi fusi) di Winnow-FT (licenza da verificare in base ai dati, vedi ../fine_tuning/08_merge_export.md) e JPT-FT (non commerciale).
- Codice di training e valutazione.
- Ricette dei dati (script, non i dati di terze parti, se le licenze non lo consentono) e set diagnostico.

- Cache delle previsioni sui test, come già fatto per Jev in questa repo: permettono di ricalcolare le metriche senza nuova inferenza.

Il set diagnostico (contributo secondario)

1. Perché un set diagnostico e non un dataset nuovo

Un benchmark come LLM-AggreFact dice **quanto** un modello sbaglia, non **perché**. I typed decision model promettono proprietà precise: leggono il documento, rispondono in modo stabile alla stessa domanda posta in modi diversi, danno probabilità calibrate. Un set diagnostico misura esattamente queste proprietà, con esempi costruiti in modo controllato. Costa una frazione di un dataset nuovo, perché parte da esempi già etichettati.

2. Da dove si parte

Solo da **test** di dataset con licenza compatibile e mai usati in training:

- test in distribuzione delle nostre fonti (FEVER `paper_test`, HoVer, VitaminC test, MiniCheck e SummEdits nella parte di test);
- fonti fuori dominio (SciFact, Climate-FEVER, HealthVer).

Non da LLM-AggreFact: la sua licenza permette la valutazione, ma derivare e ridistribuire un nuovo dataset dalle sue parti va verificato fonte per fonte. Se si vuole includerlo, distribuire solo gli script di trasformazione, non i testi.

3. Le famiglie di test

Famiglia	Trasformazione	Etichetta attesa	Costruzione	Validazione umana
Rimozione dell'evidenza	si cancellano dal documento le frasi gold che supportano il claim	da 1 a 0 (non stabilito)	automatica dove l'evidenza è annotata (FEVER, HoVer); con LLM altrove	sì: il documento non deve più supportare il claim, né contraddirlo
Coppia minima sul claim	si cambia un numero, una data, un'entità o un'attribuzione	da 1 a 0 (contraddetto)	LLM (`contradict_claim`) + verifica automatica	sì
Coppia minima sul documento	si cambia nel documento il valore che il claim cita	da 1 a 0	VitaminC (già contrastivo) + LLM	a campione
Distrattori	paragrafi irrilevanti (da altri documenti dello stesso dominio) prima e dopo	invariata	automatica	no (l'etichetta non cambia per costruzione)

Famiglia	Trasformazione	Etichetta attesa	Costruzione	Validazione umana
Posizione dell'evidenza	la frase di supporto messa all'inizio, a metà o alla fine di un documento lungo	invariata	automatica	no
Solo claim	documento vuoto o non pertinente	0	automatica	no
Formulazione della domanda	10 parafrasi mai viste in training	invariata	LLM + filtro	a campione
Campi rinominati	`document/claim` → `passage/assertion`, `context/answer`, ...	invariata	automatica	no
Paraphrase del claim	stesso contenuto, parole diverse	invariata	LLM + verifica	sì

Esempio di coppia minima sul claim:

> Documento: "Okeh Records is a subsidiary of Sony Music Entertainment and was founded by Otto Heinemann." Claim originale (1): "Okeh Records was founded by Otto Heinemann." Claim modificato (0): "Okeh Records was founded by **Thomas Edison**."

4. Validazione umana

- **Campione**: ~500 esempi delle famiglie in cui l'etichetta cambia (rimozione, coppie minime, parafrasi del claim).
- **Annotatori**: 2, indipendenti, con una guida di una pagina ("il documento supporta ogni parte del claim? sì / no / incerto").
- **Accordo**: kappa di Cohen fra annotatori e accuratezza delle etichette automatiche contro il giudizio umano. Obiettivo: $\geq 95\%$ di etichette automatiche confermate; le famiglie sotto il 90% vanno riviste o tolte.
- **Tempo**: ~500 esempi × ~40 secondi × 2 persone $\approx$ 11 ore di annotazione in totale.

5. Metriche del set

Proprietà	Metrica
Sensibilità all'evidenza	% di esempi in cui la decisione si inverte correttamente (rimozione, coppie minime)
Invarianza	% di decisioni invariate (distrattori, posizione, formulazione, campi, parafrasi del claim)
Dipendenza dal solo claim	P(supportato) media con documento vuoto
Calibrazione sotto perturbazione	variazione dell'ECE fra originale e perturbato

Un modello ideale ha sensibilità 100% e invarianza 100%. I due numeri insieme sono più informativi della sola accuratezza: un modello che dice sempre "no" ha invarianza alta ma sensibilità nulla.

6. Dimensione e formato

- ~300–1.000 esempi per famiglia, ~5.000–8.000 in tutto.
- Formato: JSONL con `id`, `family`, `parent_id`, `document`, `claim`, `label`, `expected_change` ("flip" / "invariant"), `source`, `license`, `validated` (true/false).
- Rilascio: dati derivati da fonti con licenza compatibile (CC BY / CC BY-SA / MIT; per le NC, solo uso non commerciale e dichiarato) + script per rigenerare il resto.

7. Documentazione richiesta dai revisori

Una scheda tipo *datasheet*: motivazione, composizione, processo di raccolta, trasformazioni, validazione, accordo, usi previsti e non previsti, licenze, contatti. Va in appendice del paper e nel repository del set.

Venue, calendario, rigore e rischi

Le date sono quelle trovate l'8 ottobre 2026; vanno sempre ricontrollate sui siti ufficiali (ACL Rolling Review, siti delle conferenze).

1. Dove sottomettere

Venue	Come	Scadenze note / attese	Adatta a	Note
ACL 2027 (Kyoto, 17–22 agosto 2027)	ACL Rolling Review (ARR), poi *commitment*	l'ultimo ciclo ARR utile per ACL 2027 è a **gennaio 2027** (date esatte ancora "TBA" sul sito)	paper completo (Parte A + B)	**obiettivo consigliato**
EMNLP 2027	ARR	ciclo atteso verso maggio–giugno 2027	piano di riserva, o versione più ricca	
Findings (ACL / EMNLP)	stessa sottomissione ARR	decisione dei chair	se main non passa	
NAACL 2027, EACL 2027, COLING 2027	ARR	i commitment (ottobre e dicembre 2026) richiedono revisioni ARR già ottenute	—	non raggiungibili per questo lavoro
ICLR 2027	diretta	scadenza passata (25/09/2026)	—	
Workshop FEVER (Fact Extraction and VERification)	diretta	di solito a primavera, co-locato con ACL o EMNLP	sola Parte A, o versione breve	attenzione alle regole sulla doppia sottomissione se si pubblicano atti
TrustNLP (co-locato con ACL/NAACL)	diretta	primavera 2027, da verificare	Parte A	
NeurIPS 2027 Datasets & Benchmarks	diretta	attesa verso maggio 2027	solo se si fa un dataset vero (Opzione 3)	
arXiv	preprint	subito	fissare la priorità	non impedisce la sottomissione ARR (seguire le regole ARR sull'anonimato)

2. Calendario a ritroso (obiettivo: ARR gennaio 2027 per ACL 2027)

Periodo	Lavoro	Uscita
ottobre 2026 (sett. 2–4)	Step 0: split, test fuori dominio; baseline di tutti i modelli con protocollo zero-shot; LLM generici con la stessa lettura (B1); checker specializzati (B3)	tabella della Parte A
inizio novembre 2026	set diagnostico (costruzione + validazione di 500 esempi); analisi degli errori	Parte A completa
metà novembre 2026	**preprint arXiv della Parte A** (facoltativo ma consigliato, per la priorità)	preprint
novembre 2026	codice di training; replay, varianti, negativi difficili; pilota su JPT	primo risultato di fine-tuning
dicembre 2026	ablazioni su JPT; Winnow; controlli sulle basi; seed	risultati della Parte B
fine dicembre 2026 – gennaio 2027	scrittura, figure, appendici, revisione interna, checklist ARR (riproducibilità, limitazioni, etica)	paper completo
gennaio 2027	**sottomissione ARR**	
primavera 2027	revisioni ARR, risposta ai revisori, commitment ad ACL 2027	

Margine: è stretto ma fattibile, perché la Parte A è già in gran parte pronta. Se a metà dicembre la Parte B non è solida, si sottomette la Parte A più un pilota di fine-tuning a gennaio, e si sposta il paper completo su EMNLP 2027.

3. Checklist di rigore (da completare prima della sottomissione)

Dai 14 punti dell'audit dei TDM (01_stato_arte_e_novita.md, §4):

- ☐ B1 baseline con log-probabilità di LLM generici; B2 cascata generativa; B3 checker specializzati
- ☐ T1 dispersione fra modelli; T2 invarianza; T3 opzioni rinominate o invertite; T4 provenienza dei dati
- ☐ R1 versioni e date esatte (pesi, Jev); R2 intervalli di confidenza; R3 scelte post-valutazione dichiarate
- ☐ C1 calibrazione su dati tenuti da parte; C2 accuratezza ad alta confidenza; C3 soglie congelate prima del test; C4 latenza con e senza cache

Dalla checklist ARR:

- ☐ sezione Limitations (obbligatoria)
- ☐ dichiarazione su rischi ed etica
- ☐ licenze di dati e modelli, rispetto dei termini (LLM-AggreFact: solo valutazione)
- ☐ dettagli di calcolo: GPU, ore, numero di corse
- ☐ iperparametri e procedura di scelta
- ☐ codice e dati rilasciati (o motivazione)
- ☐ uso di assistenti AI dichiarato secondo le regole della venue

Specifiche di questo lavoro:

- ☐ dichiarare che il pacchetto di domande e la soglia di Jev nel run originale sono stati scelti sul dev di AggreFact, e il controllo intermedio sul test (`results/INTERIM_AMENDMENT.md`); nel paper usare il protocollo zero-shot
- ☐ decontaminazione documentata (RAGTruth 98%, WiCE 30%)
- ☐ nessun test usato per scegliere nulla

4. Rischi e contromisure

Rischio	Probabilità	Impatto	Contromisura
Scoop da un altro gruppo (il filone produce paper ogni settimana)	media	alto	preprint della Parte A entro metà novembre; ricontrollare arXiv ogni settimana
Revisori: "è solo benchmarking"	alta per la sola Parte A	alto	Parte B + RQ2 (contro le basi generiche) + analisi di calibrazione e robustezza
Il fine-tuning non batte i checker specializzati	media	medio	il paper regge come analisi se B-ctrl e oblio sono misurati; raccontare il compromesso
Jev cambia versione o prezzo	media	basso	conclusioni principali sui modelli aperti; versione e date registrate; cache delle risposte rilasciate
Etichette rumorose (ExpertQA ~59 per tutti; HaluEval già segnalato)	certa	medio	analisi degli errori con categoria "etichetta dubbia"; non inseguire le fonti rumorose
Licenze (JPT non commerciale; dati NC)	certa	basso per un paper	dichiarare; rilasciare adapter con le licenze corrette
Calcolo insufficiente	media	medio	JPT con QLoRA sul portatile; Winnow solo per la configurazione finale; L40S per le corse critiche
Doppia sottomissione (workshop con atti + conferenza)	bassa	alto	preferire arXiv; se workshop, scegliere uno senza atti o un contenuto chiaramente diverso

5. Etica e limitazioni (bozza)

- Un fact checker documento–claim verifica il **supporto nel documento**, non la verità nel mondo: un documento sbagliato produce verdetti sbagliati. Va scritto chiaramente, per evitare usi impropri come "rilevatore di fake news".
- Tutti i dati sono in inglese; nessuna garanzia su altre lingue.
- Le probabilità calibrate su un dominio possono non esserlo su un altro (lo misuriamo: RQ3).
- Uso di modelli chiusi (Jev) e riproducibilità limitata dalle loro versioni.
- I dati generati con LLM possono contenere errori sistematici del generatore; sono verificati da un secondo modello e su un campione umano.

Scheletro del paper

Formato ACL: 8 pagine (long paper) + riferimenti + Limitations + appendici illimitate.

1. Titoli possibili

Se il contributo principale è il **metodo** (fine-tuning con guadagno netto):

- *Specializing Typed Decision Models for Grounded Fact Checking without Forgetting*
- *One Forward Pass to Check a Claim: Adapting Typed Decision Models to Document-Grounded Verification*

Se il contributo principale è l'**analisi**:

- *Are Typed Decision Models Good Fact Checkers? An Evaluation on Document-Grounded Claim Verification*
- *Calibrated, Cheap, and Grounded? Typed Decision Models as Fact Checkers*

2. Abstract di prova (versione "metodo", numeri da riempire)

> Typed decision models (TDMs) answer typed questions about a structured state with one forward pass and return a probability for every option, promising cheap and calibrated decisions. We present the first systematic study of TDMs as document-grounded fact checkers. On LLM-AggreFact, evaluated zero-shot with all choices made on held-out data from other sources, open TDMs reach [X] balanced accuracy, [above / below] specialized checkers of similar size, and [Y] points above their own base LLMs read in the same way, showing that decision training [does / does not] transfer to grounding. Their probabilities are [well / poorly] calibrated in domain but thresholds transfer [poorly] across domains. Decomposing the decision into typed sub-questions [helps / does not help]. We then specialize two open TDMs with LoRA, optimizing only the option-letter distribution read at inference and replaying self-distilled generic decisions. The adapted models gain [Z] points zero-shot on LLM-AggreFact and [W] on out-of-domain benchmarks while losing at most [V] points on general decision benchmarks. We release code, adapters, predictions, and a diagnostic set of [N] controlled perturbations.

3. Sezioni (versione completa, ~8 pagine)

Sezione	Contenuto	Pagine
1. Introduction	i TDM: perché sono interessanti (una passata, probabilità, costo); il buco (nessuna valutazione sul fact checking documento–claim, nessun fine-tuning dei modelli aperti); domande di ricerca; contributi in 4 punti	1

Sezione	Contenuto	Pagine
2. Background & Related Work	TDM (Jev, Winnow, JPT, Laya, ...); fact checker specializzati (MiniCheck, FactCG, AlignScore, ...); LLM-as-judge e calibrazione; adattamento senza oblio	0,75
3. Task and Evaluation Protocol	definizione del compito; prompt e domande tipizzate; protocollo zero-shot (dev nostro, test una volta); suite (AggreFact, fuori dominio, diagnostico, oblio); metriche	1
4. How Good Are TDMs as Fact Checkers?	RQ1–RQ3 e RQ6: tabella principale, TDM contro basi generiche, calibrazione e trasferimento della soglia, costo	1,5
5. What Do TDMs Get Wrong?	RQ4–RQ5: scomposizione in domande, set diagnostico, analisi degli errori	1
6. Specializing TDMs	metodo (loss sulle lettere, replay, dati, varianti); risultati; controlli (basi generiche, loss, replay, dati)	1,75
7. Discussion	quando usare un TDM e quando un checker specializzato; cascate; implicazioni per i costruttori di TDM	0,5
8. Conclusion		0,25
Limitations	lingua, supporto contro verità, modelli chiusi, calibrazione fra domini, dati sintetici	(fuori conteggio)
Appendici	prompt completi; tabelle per fonte; iperparametri; costi e calcolo; datasheet del set diagnostico; analisi degli errori estesa; checklist dell'audit	

4. Contributi (da scrivere nell'introduzione)

1. **Il primo studio sistematico dei typed decision model come fact checker documento–claim**: [K] TDM aperti e chiusi contro checker specializzati e contro le loro basi generiche, con un protocollo zero-shot su LLM-AggreFact e test fuori dominio.
2. **Un'analisi della calibrazione e della robustezza**: trasferimento delle soglie fra domini, scomposizione in domande tipizzate, set diagnostico di perturbazioni controllate.
3. **Un metodo di specializzazione** che ottimizza la sola distribuzione sulle opzioni e usa replay auto-distillato, con misura esplicita dell'oblio.
4. **Rilascio** di codice, adapter, previsioni e set diagnostico.

5. Figure chiave

Figura	Messaggio in una frase
Fig. 1 (pagina 1)	schema: stato (documento, claim) + domande tipizzate → una passata → probabilità per opzione; confronto con checker specializzato e LLM generativo
Fig. 2	qualità contro costo per 1.000 claim: i TDM sul fronte di Pareto?
Fig. 3	diagrammi di affidabilità: in dominio contro fuori dominio
Fig. 4	sensibilità e invarianza sul set diagnostico, per modello
Fig. 5	specializzazione contro oblio: guadagno su AggreFact (asse x) contro calo su JevBench/Kev (asse y), per configurazione

6. Le obiezioni prevedibili dei revisori, e la risposta pronta

Obiezione	Risposta (con riferimento all'esperimento)
"Un LLM qualsiasi letto con le log-probabilità fa lo stesso"	RQ2 / B-ctrl: confronto diretto con le basi generiche, stesso prompt e stessa lettura
"Avete scelto soglia e prompt sul benchmark"	protocollo zero-shot: tutto scelto su dati nostri; la soglia dal dev di AggreFact è solo un confronto secondario dichiarato
"Il fine-tuning rovina il modello"	oblio misurato su tre benchmark esterni; curva specializzazione–oblio
"Contaminazione dei dati di training"	decontaminazione documentata, con numeri per fonte
"Jev è chiuso, non è riproducibile"	conclusioni principali sui modelli aperti; versione, date e risposte di Jev rilasciate
"Differenze piccole, entro il rumore"	intervalli di confidenza per documento, test appaiati, 3 seed
"Solo inglese"	dichiarato nelle limitazioni; eventuale estensione futura

7. Prossimi passi concreti

1. Decidere fra paper unico (consigliato) e due paper (02_opzioni_di_paper.md, Opzione 5).
2. Completare lo Step 0 e la baseline con il protocollo zero-shot: è la base di tutte le tabelle.
3. Aggiungere le baseline B1 (basi generiche) e B3 (Bespoke-MiniCheck-7B, MiniCheck-Flan-T5-L): danno subito la tabella principale.
4. Valutare se uscire con un preprint della Parte A a metà novembre.

Benchmark e modelli: cosa usano i paper del settore e cosa usare noi

Integra 03_parte_A_valutazione.md. Valutare solo su LLM-AggreFact sarebbe un punto debole: i paper di riferimento usano **più benchmark**, e i revisori se lo aspettano. Anche i modelli vanno ampliati: oggi la repo ne ha cinque.

1. Su cosa si valutano i paper di fact checking su documento

Paper / modello	Benchmark usati	Metrica	Fonte
TRUE (Honovich et al., NAACL 2022)	introduce TRUE: 11 dataset (FRANK, SummEval, MNBM, QAGS-CNNDM, QAGS-XSum, BEGIN, Q^2, DialFact, PAWS, FEVER, VitaminC) su riassunti, dialogo, parafrasi, verifica di claim	ROC-AUC	2204.04991
AlignScore (ACL 2023)	TRUE (11) + SummaC benchmark (6) + altri 6 dataset: 22 in tutto, 19 mai visti in training	AUC, BAcc, correlazioni	2305.16739
MiniCheck (EMNLP 2024)	LLM-AggreFact (introdotto lì)	BAcc media per fonte	2404.10774
FactCG (NAACL 2025)	LLM-AggreFact (+ analisi sul ragionamento multi-hop)	BAcc	2501.17144
Granite Guardian (IBM)	TRUE (AUC media 0,854 per la versione 3.0-8B) + benchmark di rischio	AUC	2412.07724
Lynx (Patronus)	HaluBench (introdotto lì): DROP, CovidQA, PubMedQA, FinanceBench, HaluEval, RAGTruth	accuratezza	2407.08488
LettuceDetect	RAGTruth (livello di risposta e di span)	F1	2502.17125
HalluGuard (Findings ACL 2026)	LLM-AggreFact intero (75,7) + focus su RAGTruth (84,0)	BAcc	2510.00880

Paper / modello	Benchmark usati	Metrica	Fonte
FaithBench (NAACL 2025)	introduce FaithBench: allucinazioni di 10 LLM moderni nei riassunti, annotate da esperti; i rilevatori migliori sono vicini al 50%	BAcc, F1	2410.13210
JEV-as-a-Judge (TDM, 2026)	240 casi di HaluEval con evidenza (fra altri compiti non di fact checking)	accuratezza	2609.26550

La prassi: almeno **un benchmark aggregato** (LLM-AggreFact oppure TRUE/SummaC), più **un benchmark RAG** (RAGTruth o HaluBench), e nei lavori recenti **un benchmark difficile e moderno** (FaithBench). I lavori più solidi (AlignScore) dichiarano quanti dataset non sono mai stati visti in training.

2. La suite proposta

Livello 1 — indispensabile

Benchmark	Cosa copre	Dimensione	Metrica principale	Note
LLM-AggreFact (11 fonti)	riassunti, dialoghi, RAG, claim di LLM	29.320	BAcc media per fonte (come la leaderboard) + AUC	già valutato per 5 modelli
TRUE (11 dataset)	riassunti, dialogo, parafrasi, verifica di claim	~100.000 coppie (dominate da VitaminC e FEVER)	**ROC-AUC** per dataset (come nel paper originale e in AlignScore/Granite Guardian) + BAcc	campionare i dataset più grandi (es. massimo 5.000 per dataset) per contenere i costi
HaluBench (6 fonti)	QA con contesto: finanza, medicina, DROP	~15.000	accuratezza e BAcc per fonte	la parte RAGTruth si riporta a parte (è anche in LLM-AggreFact)
RAGTruth (test, livello di risposta)	risposte di LLM in RAG: QA, data-to-text, riassunti	~2.700 risposte (da verificare)	BAcc, F1	confronto diretto con LettuceDetect e HalluGuard
FaithBench	allucinazioni difficili di LLM moderni nei riassunti	~800 (da verificare)	BAcc	il più duro: i rilevatori attuali sono vicini al 50%

Livello 2 — consigliato

Benchmark	Perché
SummaC benchmark (6 dataset di riassunti)	standard storico; utile per il confronto con AlignScore e SummaC
HalluMix	multi-documento, documenti lunghi, più domini
Verifica di claim fuori dominio: SciFact, Climate-FEVER, HealthVer / COVID-Fact	domini scientifico, clima, salute; claim reali; evidenza data
LLM-Oasis (test annotato a mano)	testi di Wikipedia, se disponibile la variante con evidenza

Livello 3 — facoltativo

Benchmark	Perché
ContextualJudgeBench	giudizi contestuali, se si vuole parlare di LLM-as-judge
Benchmark multilingue (es. SEAHORSE per i riassunti)	solo se si vuole una sezione multilingue (Laya è multilingue)
FACTS Grounding	**non adatto così com'è**: valuta la generazione di risposte giudicata da LLM, non fornisce coppie (documento, claim) etichettate da persone

Sempre presenti

- **Set diagnostico** (05_set_diagnostico.md).
- **Oblio** (solo per la Parte B): JevBench pubblico, Kev-v9 clean, typed-decisions test.

3. Attenzione alle sovrapposizioni fra benchmark (e con il training)

Sovrapposizione	Problema	Come gestirla
TRUE, SummaC e LLM-AggreFact condividono dataset di riassunti (FRANK, SummEval, QAGS, XSumFaith compaiono in più aggregati)	la stessa coppia contata due volte, risultati correlati	deduplicare per documento + claim; riportare ogni aggregato da solo, non sommarli
RAGTruth è in LLM-AggreFact e in HaluBench	idem	blocco RAGTruth riportato una sola volta
TRUE contiene **FEVER e VitaminC**, che sono nel nostro training (Parte B)	per i modelli fine-tunati, quei due dataset diventano "in distribuzione"	per la Parte B riportare TRUE anche **senza FEVER e VitaminC** (TRUE-9); dichiararlo
HaluBench contiene HaluEval, già usato in JEV-as-a-Judge	—	non è un problema, ma va citato

Regola generale: nella tabella principale dichiarare per ogni benchmark se è **mai visto** in training, come fa AlignScore.

4. I modelli

4.1 Typed decision model / System One

Modello	Architettura	Accesso	Note
Jev 1.13 (TypeSafe)	chiuso	API (~0,042 $ per milione di token di input)	riferimento; già valutato
OpenAI Decisions API (`gpt-6-luna`)	chiuso	**preview limitata**; 0,10 $ per milione di token di input, output gratis	se si ottiene l'accesso, è il secondo TDM chiuso: confronto molto interessante
Winnow-12B	autoregressivo (Gemma-4-12B fine-tunato), GGUF	aperto, Apache 2.0	già valutato (BF16, NVFP4); aggiungere Q8_0
JPT-9B	autoregressivo (Qwen3.5-9B + LoRA)	aperto, CC BY-NC	già valutato

Modello	Architettura	Accesso	Note
Rune-26B-A4B	autoregressivo MoE (Gemma-4)	aperto	già valutato
Kev-9B / Kev-4B (e taglie minori)	LoRA + "pointer head" su Qwen3.5	aperto, server compatibile System One	da fare; varie taglie → curva di scala
Laya (395M)	**encoder** (ModernBERT-large) + testa di decisione, non autoregressivo, multilingue	aperto	da fare; il più piccolo e veloce
djev-0.1	**diffusione** (DiffusionGemma 26B-A4B)	aperto	da fare
CLM-v0.1-8B (Stanford / NVIDIA)	**contrastivo**: encoder Qwen3-8B congelato + teste di stato e azione (InfoNCE)	aperto; server con schema System One	runner già pronto nella repo (`evaluate.py`), mai eseguito

Sono **nove TDM con quattro architetture diverse** (autoregressivo, encoder, diffusione, contrastivo) e taglie da 0,4B a 26B. È un asse di analisi a sé: *quale tipo di decision model funziona come fact checker?*

4.2 Checker specializzati

Modello	Taglia	Perché
MiniCheck-RoBERTa-L, MiniCheck-DeBERTa-L, MiniCheck-Flan-T5-L	0,4–0,8B	riferimento di LLM-AggreFact
Bespoke-MiniCheck-7B	7B	miglior aperto della leaderboard (77,4); pesi già nella cache HF di questa macchina
FactCG-DeBERTa-L	0,4B	già valutato (75,64)
AlignScore-large	0,4B	riferimento per TRUE e SummaC
HHEM-2.1-open (Vectara)	0,1B	molto usato in produzione
Granite Guardian 3.3	8B	forte su TRUE e AggreFact (76,5)
Lynx-8B (70B facoltativo)	8B / 70B	riferimento di HaluBench
HalluGuard-4B	4B	recente (2026), 75,7 su LLM-AggreFact
SummaC-ZS	0,1B	baseline storica (facoltativa)

4.3 LLM generici letti come un TDM (baseline B1 della checklist)

Stesso prompt del TDM corrispondente, si leggono i logit delle lettere, una passata:

Modello	Perché
Gemma-4-12B	base di Winnow → confronto diretto
Qwen3.5-9B	base di JPT e di Kev-9B → confronto diretto
Qwen3-8B	base di CLM
Gemma-4-26B-A4B	base di Rune (e affine a djev)
Una scala della stessa famiglia (es. Qwen3.5 piccoli → 9B, o Gemma-4 → 31B)	effetto della taglia a parità di metodo

4.4 LLM generici che generano (baseline B2, giudici)

Gruppo	Modelli	Come
Aperti	gpt-oss-20b, gpt-oss-120b, Qwen3-30B-A3B, Gemma-4-31B, Mistral-Small-3.2-24B, DeepSeek-V4.1-Flash	risposta "Yes/No" generata; con e senza ragionamento
Chiusi	un modello di punta e uno economico per fornitore: famiglia GPT-5.x/6 (OpenAI), Claude Sonnet 5.5 e Haiku 4.5 (Anthropic), Gemini 3.x Pro e Flash (Google)	**su un sottoinsieme** (es. 200 righe per fonte) per contenere i costi

Per i modelli più vecchi (GPT-4o, Claude 3.5 Sonnet, Llama-3.1-70B, ...) si citano i numeri della leaderboard di LLM-AggreFact invece di rifarli.

5. Selezione consigliata

Versione minima (paper solido, ~20 modelli)

Gruppo	Modelli
TDM (8)	Jev, Winnow-12B, JPT-9B, Rune-26B, Kev-9B, Laya, djev-0.1, CLM-8B (+ OpenAI Decisions se accessibile)
Specializzati (6)	Bespoke-MiniCheck-7B, MiniCheck-Flan-T5-L, FactCG-DeBERTa-L, AlignScore-L, Granite Guardian 3.3, Lynx-8B
LLM letti come TDM (2)	Gemma-4-12B, Qwen3.5-9B
LLM generativi (4)	gpt-oss-20b, Qwen3-30B-A3B, un chiuso di punta, un chiuso economico

Benchmark: livello 1 completo, più i tre di verifica di claim fuori dominio.

Versione estesa (se c'è tempo)

Aggiungere: Kev-4B e taglie minori (curva di scala), HHEM, HalluGuard-4B, Lynx-70B, Qwen3-8B e Gemma-4-26B letti come TDM, gpt-oss-120b, Gemma-4-31B, DeepSeek-V4.1-Flash; livello 2 completo.

6. Costi stimati (da verificare)

Voce	Stima
Coppie della suite di livello 1 (TRUE campionato a 5.000 per dataset)	~90.000 coppie
Modello aperto da ~9–12B, tre domande per coppia, su L40S	~4–6 ore per modello (riferimento: Winnow NVFP4 ~4,3 coppie/s sul portatile)
15 modelli aperti	~60–90 ore GPU
Modelli piccoli (Laya, DeBERTa, RoBERTa, T5)	minuti o poche ore
Jev su tutta la suite	pochi dollari (l'intero test di LLM-AggreFact è costato ~1,5 $)
LLM chiusi su un sottoinsieme (~5.000 coppie)	da qualche decina a qualche centinaio di dollari secondo il modello; usare l'API batch

7. Cosa cambia nel paper

- La **tabella principale** diventa: modelli × {LLM-AggreFact, TRUE, HaluBench, RAGTruth, FaithBench, verifica di claim fuori dominio}, più la media.
- Nuova analisi: **architettura del TDM** (autoregressivo, encoder, diffusione, contrastivo) contro qualità e costo.
- Nuova analisi: **taglia** (Kev da piccolo a 9B, Laya 0,4B, Rune 26B).
- RQ2 (TDM contro la base generica) si fa su quattro coppie: Winnow/Gemma-4-12B, JPT e Kev/Qwen3.5-9B, CLM/Qwen3-8B, Rune/Gemma-4-26B.

Fonti

- TRUE: https://arxiv.org/abs/2204.04991 · AlignScore: https://arxiv.org/abs/2305.16739 · MiniCheck: https://arxiv.org/abs/2404.10774 · FactCG: https://arxiv.org/abs/2501.17144
- Granite Guardian: https://arxiv.org/abs/2412.07724 · Lynx / HaluBench: https://arxiv.org/abs/2407.08488 · LettuceDetect: https://arxiv.org/abs/2502.17125 · HalluGuard: https://arxiv.org/abs/2510.00880 · FaithBench: https://arxiv.org/abs/2410.13210
- TDM: Laya https://huggingface.co/convaiinnovations/laya · Kev https://github.com/jaredpalmer/kev · djev https://github.com/Davipar/djev-dev · CLM https://huggingface.co/Contrastive-LM/CLM-v0.1-8B · OpenAI Decisions API https://www.firecrawl.dev/blog/openai-decisions-api-vs-jev