Idea di paper: decision model tipizzati per il fact checking documento–claim

Cartella di lavoro per decidere **che paper scrivere**, **con quali esperimenti** e **dove sottometterlo**. Scritta l'8 ottobre 2026.

La risposta breve

1. **La novità c'è, ma il campo corre.** Dal rilascio di Jev (15 settembre 2026) sono usciti decine di paper sui *typed decision model* (TDM). L'audit dei primi 28 (arXiv 2609.32160) dice che **nessuno** si concentra su fact checking, allucinazioni, NLI o verifica di claim, e nessuno fa fine-tuning dei modelli aperti. Il lavoro più vicino (JEV-as-a-Judge, 2609.26550) usa 240 esempi di HaluEval, solo con Jev. Lo spazio "TDM come fact checker su documento" è libero **oggi**: conviene muoversi in fretta e rendere pubblico un preprint presto.
2. **Non partirei da un dataset nuovo.** Proporre un dataset è un contributo a sé: richiede annotazione umana, documentazione, licenze e baseline, cioè mesi di lavoro e costi. Per questa domanda di ricerca esistono già benchmark solidi (LLM-AggreFact e altri). Il contributo più forte e più rapido è **un'analisi rigorosa dei TDM come fact checker**, più **un metodo per specializzarli senza rompere ciò che li rende utili**.
3. **Il piano consigliato: un paper principale, con un preprint anticipato.**
   - **Parte A, valutazione** (in gran parte già fatta in questa repo): TDM aperti e chiusi contro checker specializzati (MiniCheck, FactCG, Bespoke) e contro LLM generici letti allo stesso modo, su LLM-AggreFact **zero-shot**, su domini fuori distribuzione, con calibrazione e test di robustezza.
   - **Parte B, metodo**: fine-tuning di Winnow-12B e JPT-9B con loss sulle lettere di risposta e replay per non dimenticare, misurando quanto si guadagna sul fact checking e quanto si perde sulle decisioni generali.
   - **Contributo secondario facoltativo**: un piccolo **set diagnostico** (coppie minime, rimozione dell'evidenza, distrattori) ricavato da test esistenti e validato a mano su un campione. È molto più economico di un dataset nuovo ed è utile a tutta la comunità.
4. **Dove sottometterlo**: ACL 2027 (Kyoto, agosto 2027) tramite ACL Rolling Review; secondo il sito di ACL 2027, l'ultimo ciclo ARR utile è **gennaio 2027**. In alternativa EMNLP 2027 (scadenza attesa verso maggio–giugno 2027), oppure il workshop FEVER se si vuole uscire prima con la sola Parte A. Le date esatte vanno verificate sui siti ufficiali.

I file

File	Contenuto
01_stato_arte_e_novita.md	Cosa esiste già (TDM, fact checker specializzati, LLM-as-judge), dove sta il buco, cosa si rischia
02_opzioni_di_paper.md	Le alternative (solo valutazione, metodo, dataset nuovo, set diagnostico) con pro, contro, costi e raccomandazione
03_parte_A_valutazione.md	Domande di ricerca, modelli, baseline, dati, metriche, esperimenti, tabelle e figure della parte di valutazione
04_parte_B_finetuning.md	Il metodo di specializzazione e gli esperimenti che servono per un paper
05_set_diagnostico.md	Come costruire e validare il set diagnostico (contributo secondario)
06_venue_calendario_rischi.md	Conferenze, calendario a ritroso, checklist di rigore, rischi e come gestirli
07_scheletro_paper.md	Titoli possibili, abstract di prova, sezioni, tabelle e figure

Cosa abbiamo già (e cosa manca)

Elemento	Stato
Jev-1.13 su tutto il test di LLM-AggreFact (79,09, dev-tuned)	fatto, ma con due limiti da dichiarare: domande e soglia scelte sul dev di AggreFact, e un controllo intermedio sul test (vedi `results/INTERIM_AMENDMENT.md`)
Winnow-12B (NVFP4 e BF16), JPT-9B, Rune-26B, FactCG su tutto il test, con cache di logit e probabilità	fatto
Soglie fittate sul dev di AggreFact per i modelli aperti	fatto
Split nostri train/dev/test e test fuori dominio	da fare (../fine_tuning/00b_split_e_protocollo.md)
Baseline con LLM generici letti allo stesso modo (stesso prompt, logit delle lettere)	da fare: è la prima obiezione che farà un revisore
Calibrazione, robustezza, costi e latenza misurati in modo sistematico	in parte (latenze nei log), da completare
Fine-tuning	da fare (../fine_tuning/)