Step 2a — Dataset: le fonti esistenti, rilette per il compito binario

Obiettivo

Riusare le coppie (documento, claim, etichetta) già prodotte da `data_prep/build_pairs.py` (../fine_tuning/02a_dataset_fonti_esistenti.md) e decidere **quanto pesa ciascuna fonte** quando l'unico obiettivo è il verdetto binario. In più: costruire un **sottoinsieme difficile di ANLI** come fa MiniCheck, e aggiungere le fonti multi-hop da cui FactCG genera CG2C-MHQA.

1. Cosa cambia con il compito binario

Aspetto	Piano generale	Qui
`orig_label` a 3 classi	serviva per i target delle domande 2 e 3	serve solo per analisi (errori su "contraddetto" vs "non stabilito") e per bilanciare i due tipi di negativo
Formato	stato JSON di un decision model	invariato: il prompt resta quello nativo, con una sola domanda
Etichetta	1 = supportato in ogni parte; 0 = contraddetto **o** non stabilito	identica (convenzione LLM-AggreFact)

Regola di qualità per i negativi: per un fact checker binario i negativi **"non stabilito"** (manca un pezzo di evidenza) sono i più utili e i più rari nei dataset pubblici. Il mix deve averne almeno ~40% sul totale dei negativi; il resto contraddetti.

2. Le fonti e il loro ruolo

Fonte	Coppie train disponibili	Ruolo nel compito binario	Stadio (02e)
MiniCheck C2D	~7k	claim multi-fatto, negativi per evidenza tolta: è il dato costruito per questo compito	1
MiniCheck D2C	~7k	stessa logica su notizie reali	2
ANLI R1–R3	162.865	inferenza difficile; **solo il sottoinsieme difficile** (§3)	1
SummEdits	6.348	riassunti con errori sottili, 10 domini: vicino alle fonti deboli di AggreFact (CNN, XSum, MediaSum)	2
HoVer	17.000	multi-hop su 2–4 pagine	1
FEVER	144.411	single-hop, molti NEI; scorciatoie note	1 (quota bassa)
VitaminC	370.653	contrasti su numeri e date (coppie minime)	1
AVeriTeC	2.873	claim reali, evidenza in forma domanda–risposta	2 (piccola)
HotpotQA, MuSiQue (**nuove**)	~90k / ~20k domande	non si usano direttamente: sono il materiale di partenza di CG2C-MHQA (02b, §3)	—

Fonte	Coppie train disponibili	Ruolo nel compito binario	Stadio (02e)
FactKG	81.342	solo dopo la trasformazione in prosa, ed è un esperimento (D-FKG)	1
SciFact	919	**test_ood**, non in training	—
WiCE, RAGTruth	—	esclusi (contaminazione con AggreFact)	—

Per HotpotQA e MuSiQue va aggiunto un builder in `build_pairs.py` (HF: `hotpotqa/hotpot_qa` config `distractor`, `bdsaglam/musique` o equivalente) e la decontaminazione: le loro pagine sono Wikipedia come FEVER e HoVer, il rischio verso AggreFact è basso ma va misurato.

3. ANLI difficile (come MiniCheck)

MiniCheck non usa tutto ANLI: usa **21k esempi su cui i loro modelli di entailment sbagliavano**. Il senso: gli esempi facili non insegnano nulla al modello e ne spostano la calibrazione.

Con il nostro modello di partenza:

1. Inferenza di JPT-9B (una domanda) su tutto ANLI train (162.865 righe, premesse corte: ~130 token p95 → ~1 h con vLLM su L40S).
2. Per ogni riga, `p` = P(supportato). Errore "sicuro" se label 1 e `p < 0,3`, oppure label 0 e `p > 0,7`. Errore "incerto" se `0,3 ≤ p ≤ 0,7`.
3. Si tengono tutti gli errori sicuri e incerti, più un 20% di esempi giusti scelti a caso (per non insegnare che "ANLI = sempre il contrario di quello che pensi").
4. Bilanciamento 50/50 e tetto a ~20k.

Attenzioni: - la selezione si fa **solo sul train** di ANLI; - se si sceglie con JPT e si addestra Winnow, gli esempi difficili sono un po' meno adatti a Winnow: va bene (MiniCheck usava modelli diversi da quelli addestrati); in alternativa una selezione per modello; - una parte degli errori "sicuri" sono **etichette sbagliate** di ANLI: con la CE spingono forte. Se la quota di errori sicuri supera ~30%, usare Brier o label smoothing su queste righe (04).

Esempio illustrativo (costruito nello stile di ANLI, non una riga reale; label entailment → 1):

> Premessa: "… The company reported a net loss of $2 million in the third quarter, compared with a profit a year earlier." Claim: "The company was profitable in the third quarter of the previous year."

Un modello che guarda la somiglianza lessicale tende a dire "no" (la premessa parla di perdita); ma "compared with a profit a year earlier" stabilisce proprio il claim. Errori così sono il materiale utile.

4. Le scorciatoie da tenere sotto controllo

Fonte	Scorciatoia	Controllo
FEVER	negazioni nel claim ("not", "never") → falso	test "solo claim"; esperimento senza negazioni esplicite
FEVER (NEI)	documento scelto per titolo → negativi facili	quota bassa (≤ 10% del mix)
VitaminC	evidenza di 1–2 frasi	quota ≤ 15%; documenti corti non rappresentano l'uso reale
ANLI	premesse corte	combinarlo con fonti lunghe
SummEdits	modifiche al limite dell'opinabile	Brier o smoothing se pesa

5. Comandi

```
conda run -n factcheck python data_prep/build_pairs.py all            # già fatto
conda run -n factcheck python data_prep/build_pairs.py hotpotqa musique  # da aggiungere
conda run -n factcheck python finetune/mine_hard.py --source anli --model jpt-9b   # da scrivere (§3)
```

Criteri per passare allo step successivo

- `anli_hard.jsonl` prodotto, con la distribuzione di `p` e la quota di errori sicuri registrate.
- Builder HotpotQA/MuSiQue scritti e decontaminati (se si fa CG2C-MHQA).
- 20 righe per fonte lette a mano, con attenzione ai negativi "non stabilito".