Step 7 — Piano degli esperimenti

Obiettivo

Arrivare alla configurazione finale con poche corse, una variazione alla volta, con criteri fissati prima. Rispetto al piano generale (../fine_tuning/07_esperimenti.md) c'è una fase nuova, **A** (**architettura**), che risponde con numeri propri alla domanda "decision model, LLM base o encoder stile FactCG?", e una fase **S** (**distillazione**) opzionale. Spariscono gli esperimenti su replay e oblio.

Regole

1. Ogni esperimento: ID, configurazione di riferimento, una sola variazione.
2. Si giudica su `dev_select` (BAcc macro, AUC, ECE, soglia ottimale, BAcc a 0,5) e sui test comportamentali. I test solo alla fine.
3. Una variazione si adotta se migliora la BAcc macro su `dev_select` di $\geq 0{,}5$ punti senza peggiorare l'ECE di più di 0,02.
4. Prima su JPT-9B; le scelte vincenti si ripetono su Winnow-12B.

Fase 0 — Baseline (senza training)

ID	Cosa	Costo
B1	decision model, una domanda (`support_simple`)	dalle cache sul dev di AggreFact già fatto; sul nostro dev ~1 h
B2	tre domande	stessa cache di B1
B3	formulazioni Q2/Q3 (02d)	~1 h ciascuna
B4	Gemma-4-12B e Qwen3.5-9B base, domanda scelta	~2 h
B5–B7	FactCG, MiniCheck, Bespoke-MiniCheck-7B	~2 h

Uscita: domanda di produzione scelta (B1 o B3); baseline vera congelata.

Fase 1 — Pilota (JPT, `fc_pilot`, uno stadio)

Riferimento **P0**: LoRA r16, lr 2e-5, 1 epoca, CE, 4.096 token, domanda scelta.

ID	Variazione	Domanda	Decisione
P0	—	il training funziona?	se non batte B1 su `dev_select`, fermarsi e ricontrollare rendering e loss
P1	lr 5e-5 / 1e-5	sensibilità	tenere il migliore
P2	Brier	calibrazione con dati rumorosi	se ECE migliora senza perdere BAcc
P-LS	CE con smoothing 0,05 su dati generati e ANLI difficile	rumore delle etichette	idem
P-KL	+ β·KL verso il modello di partenza ($\beta = 0{,}05$)	serve un ancoraggio?	solo se P0 peggiora test_ood-like (righe di `dev_select` delle fonti piccole) o l'ECE
P3	SFT classico sul token di risposta (vocabolario intero)	quanto vale la loss sulle lettere	conferma della scelta

ID	Variazione	Domanda	Decisione
P-VAR	10% di varianti di domanda	regolarizzazione	tenere solo se migliora `dev_select`

Fase A — Architettura (stessi dati: `fc_pilot`, poi il mix finale)

È la fase che risponde alla domanda di partenza (00a).

ID	Backbone	Uscita	Domanda
A1	JPT-9B (decision model)	lettere	riferimento (= P0 o migliore della Fase 1)
A2	Qwen3.5-9B base	lettere, stesso prompt	quanto vale partire da un decision model (controllo C1 anticipato)
A3	Qwen3.5-9B base	**testa nuova** `Linear(d→2)` sull'ultimo token	cambiare la testa aiuta o peggiora? (atteso: peggio o uguale ad A2, con più dati necessari)
A4	JPT-9B	testa nuova inizializzata da `w_vero − w_falso`	verifica pratica dell'equivalenza: deve dare lo stesso risultato di A1
A5	DeBERTa-v3-large, stile FactCG	testa nuova, chunk 550	quanto vale la taglia a parità di dati

Come leggere la fase A.

Esito	Conclusione
A1 > A2 di ≥ 0,5	il decision model aiuta: si prosegue con D1 (raccomandazione di 00a)
A1 ≈ A2	il vantaggio è nei dati; il backbone si sceglie per licenza e costo (un base Apache 2.0 può essere preferibile a JPT, CC BY-NC)
A3 < A2	conferma: non cambiare la testa
A1 ≈ A4	conferma dell'equivalenza: la testa estratta si può usare per servire il modello (08)
A5 ≥ A1 − 1	l'encoder è quasi equivalente a un costo di gran lunga minore: valutare seriamente la fase S o direttamente E1

Costo: 4 corse in più sul pilota (A2–A5), ~4 h ciascuna; A5 sul portatile.

Fase 2 — Dati (JPT, configurazione migliore)

ID	Variazione	Domanda
D-MC	solo MiniCheck + ANLI difficile (≈ ricetta Bespoke)	quanto si ottiene con la sola ricetta pubblica
D-HARD	ANLI difficile contro ANLI casuale (stessa quantità)	la selezione degli esempi difficili serve?
D-D2C	+ D2C esteso	migliorano le fonti di riassunti?
D-C2D	+ C2D esteso	migliora "claim parziale"?

ID	Variazione	Domanda
D-CG	+ CG2C-MHQA + CG2C-Doc	migliora il multi-hop (HoVer, "evidenza divisa")?
D-RE	+ `remove_evidence` su documenti lunghi	si abbassa la soglia ottimale? migliora "rimozione dell'evidenza"?
D-CUR	due stadi contro uno stadio con gli stessi dati	il curriculum serve?
D-SCALE	25k / 50k / 100k	curva di apprendimento
D-FKG	+ FactKG in prosa	aiuta?
D-NEG	FEVER senza negazioni esplicite	scorciatoie

Fase 3 — Winnow e formato

ID	Variazione	Domanda
W0	configurazione migliore di JPT su Winnow	il risultato si trasferisce?
F2	8.192 token invece di 4.096	documenti lunghi
F3	rank 8 / 32 / 64	capacità dell'adapter
K1	dimensione dei chunk in inferenza: 2k / 4k / 8k / intero	scelta di C su `dev_select`
K2	`min` sulle frasi del claim × `max` sui chunk (Bespoke)	risposte lunghe

Fase 4 — Contrastive (opzionale)

ID	Variazione
X1	+ `L_pair` sulle coppie C2D/CG2C/VitaminC ($\mu = 0{,}3$)
X2	$\mu \in \{0{,}1; 0{,}3\}$ e coppie generate

Fase S — Distillazione in un encoder (opzionale)

Solo se il costo d'inferenza è un requisito.

ID	Cosa	Domanda
S1	DeBERTa-v3-large addestrato sulle probabilità del modello finale sul mix (stesse righe di A5)	quanto recupera lo studente rispetto ad A5 (etichette dure)?
S2	S1 + 200–500k coppie in più etichettate solo dall'insegnante (VitaminC, FEVER, HoVer interi, D2C non verificato)	più dati morbidi aiutano?
S3	ModernBERT-large invece di DeBERTa	contesto 8k: meno chunk

Controlli finali (obbligatori)

ID	Cosa
C1	stessa ricetta finale su Gemma-4-12B base (per Winnow) e Qwen3.5-9B base (per JPT) — se la fase A è stata fatta sul pilota, va ripetuta sul mix finale
C2	3 seed della configurazione finale
C3	FactCG, MiniCheck, Bespoke-MiniCheck-7B sulla stessa suite

Calendario indicativo

Settimana	Lavoro
1	Step 0, Fase 0, `render.py`/`train.py`, ANLI difficile, `fc_pilot`
2	Fase 1 e Fase A su JPT
3	generazione D2C/C2D/CG2C (in parallelo dalla settimana 1 su un'altra GPU); Fase 2
4	Fase 3 su Winnow
5	C1–C3, congelamento, test, export; Fase S se richiesta

Registro degli esperimenti

`finetune/experiments_fc.md`, una riga per corsa:

ID	Modello	Mix	Variazione	BAcc dev	AUC dev	BAcc@0,5	Soglia ott.	ECE	Solo claim	Rimozione evid.	Durata	Decisione
B1	JPT	—	1 domanda								0	baseline
P0	JPT	fc_pilot	—									