Step 8 — Export e servizio: verdetto ed evidenza dallo stesso forward

Obiettivo

Mettere in produzione il modello del verdetto più la testa di evidenza in modo che **un solo forward** restituisca entrambe le cose, con la latenza di un decision model.

Input e output

Input	pesi fusi del verdetto (piano binario, claim → documento), eventuale adapter della fase 2, pesi della testa
Output	`finetune/release/<modello>-fc-ev-<versione>/`: pesi fusi, `evidence_head.safetensors`, `decision.json`, `frozen.json`, report, model card

1. Fusione

- Fase 1 (backbone congelato): i pesi del verdetto sono quelli già rilasciati dal piano binario; si aggiunge solo `evidence_head.safetensors` (~5–10 MB).
- Fase 2: si fonde l'adapter congiunto come nel piano generale (../fine_tuning/08_merge_export.md §1–2) e si verifica il verdetto (PEFT contro fuso su 200 righe).

2. Che cosa deve restituire il server

Da **un** forward sul prompt: 1. i logit delle due lettere in `Answer:` (o direttamente P(supportato)); 2. lo stato nascosto in `Answer:` (`q`); 3. gli stati nascosti nelle posizioni `sent_end_pos` (`h_k`), dal layer scelto in H2.

Poi, sulla stessa macchina, l'aggregatore (< 1 ms).

Server	Come	Note
Server proprio con transformers (più semplice)	forward con hook sul layer scelto; si prendono solo le posizioni necessarie; lettere dalle due righe della testa	pieno controllo; throughput inferiore a vLLM con molte richieste parallele
vLLM	le modalità di pooling restituiscono uscite per token; serve un modello registrato che restituisca stati in posizioni scelte e i logit delle lettere	velocità migliore; supporto per `gemma4_text` e per i layer DeltaNet di Qwen3.5 da verificare
llama.cpp (GGUF di Winnow)	embedding per token senza pooling	va verificato che la versione del fork di Winnow restituisca stati e logit dallo stesso passaggio; altrimenti non si usa per l'evidenza

Regola: **non** trasferire dalla GPU gli stati di tutti i token (decine di MB per richiesta), ma solo `q` e gli `h_k`.

3. Logica di risposta

```
p = p_supported(letter_logits, temperature)
supported = p > threshold
if not supported:
    return {"p_supported": p, "supported": False, "evidence": []}
scores = sigmoid(evidence_head(q, h, sent_mask))
chosen = [k for k in argsort_desc(scores) if scores[k] > tau_e][:max_evidence] or [argmax(scores)]
```

```
return {"p_supported": p, "supported": True,
        "evidence": [{"sentence": k, "start": spans[k][0], "end": spans[k][1], "score": scores[k]}
                     for k in sorted(chosen)]}
```

Gli offset `start`/`end` si riferiscono al **testo originale** del documento (non al JSON escapato), così il client evidenzia direttamente.

4. `decision.json`

```
{"model": "winnow-12b-fc-ev-v1",
 "question": "support_simple", "state_order": ["claim", "document"],
 "read": "P(B)", "temperature": 1.0, "threshold": 0.50,
 "evidence": {"layer": "last", "tau_e": 0.42, "max_evidence": 5, "min_evidence": 1,
              "segmenter": "finetune/sentences.py@<hash>"},
 "max_document_tokens": 32768}
```

(Valori di esempio.) Il segmentatore è parte del modello: cambiarlo cambia le posizioni e invalida la testa.

5. Verifiche prima del rilascio

Verifica	Soglia
Verdetto del server = verdetto in valutazione	differenza media di P $<$ 0,005 su 200 righe
Evidenza del server = evidenza in valutazione	stesse frasi su $\geq$ 199 di 200 righe
Latenza con testa vs senza	$\leq$ +3% p50 e p95
Documenti con virgolette, a capo, <, testo non latino	offset corretti sul testo originale

6. Congelamento, test, pacchetto

`frozen.json` con hash di pesi, testa, segmentatore, `question.json`, `decision.json`, mix e codice di valutazione; poi una sola esecuzione dei test (06).

Model card: verifica binaria documento–claim in inglese; **evidenzia solo quando il claim è supportato**; non indica cosa manca né cosa contraddice; segmentazione a livello di frase.

Licenze: come nel piano binario; la testa eredita i vincoli dei dati di evidenza (FEVER e HoVer CC BY-SA; SciFact e WiCE usati solo in test).

Criteri di completamento

- Verifiche di §5 superate.
- `frozen.json` prima del test; test una volta; report e model card pubblicati.